

iPAS AI 應用規劃師（中級）考綱教科書

含政府指引版

第 II 冊 L22 大數據處理分析與應用（選考）

版本：v0.2.0

資料截止日：中華民國 115 年 8 月 1 日

對應考綱：經濟部 iPAS 《評鑑內容範圍參考 115.02 版》

本冊涵蓋：L21101 -L21302，共 9 個評鑑內容代碼、9 章

適用路線：L21 為**必考**，兩條授證路線（數據分析／機器學習）皆須研讀本冊

本書為非官方備考教材。考試規則、評鑑範圍與法規條文均以主管機關及 iPAS 官方最新公告為準。

免責與使用聲明

請先閱讀

1. 本書為**非官方教材**，並非 iPAS 官方指定用書，亦**不保證考試通過**。
2. 官方學習指引是**學習方向**，並非完整官方題庫。本書同樣不是題庫。
3. 本書所有模擬題均為編者自編，題號以 SIM- 開頭，**絕非**歷屆試題。
4. 正式公告試題部分，本書僅提供**題旨摘述、考綱對位與考點拆解**，不重製官方題幹與選項全文。請自行至 iPAS 官網下載原卷對照。
5. 法規、政府指引、工具版本與考試規則均可能異動。凡標示 **版本敏感** 之內容，請以本書資料截止日（中華民國 115 年 8 月 1 日）之後的官方最新公告為準。
6. 本書明確區分「法律義務」「主管機關期待」「建議作法」與「編者建議」，不得將參考指引誤讀為法律強制條文。

內容分層標示說明

本書每一知識點皆標註下列標籤之一，請依標籤調整投入時間：

標籤	意義與讀法
核心必考	可直接對應官方評鑑範圍、學習指引或正式公告試題。 必須完全掌握 。
官方補充	出現在官方學習指引或政府文件，但非評鑑主題名稱本身。理解即可。
政府實務	與政府風險、治理、個資、資安或產業導入指引直接相關。須記住 文件性質與拘束力層級 。
產業延伸	對實務工作有價值，但 無充分證據顯示為官方核心考點 。時間有限時可略過。
版本敏感	工具、模型、法規或政策可能更新，附查核日期，應試前請自行複查。

導讀：中級考試的本質轉變

初級鑑定測的是「認知」——知道 AI 是什麼、有哪些類型、有什麼倫理風險。中級鑑定測的是「決策」——在給定的資料條件、預算限制、法規約束與時程壓力下，你要選哪一個方案，並且說得出為什麼不選另外三個。

這個轉變具體反映在三處：

- **題型轉為情境規劃題**。題幹會給一段營運背景（資料量、標註成本、延遲要求、合規紅線），四個選項看起來都「不算錯」。得分關鍵在於辨認**題幹埋設的限制條件**——那個條件通常只有一個選項能滿足。
 - **新增程式邏輯判斷題**。依官方公告，114 年第二次中級能力鑑定起，試題新增程式邏輯判斷題型，內容涵蓋 Python 語法與程式片段解析。此題型主要出現在科目二與科目三；本冊（L21）不含程式題。
- 版本敏感**
- **法規題已從「知道有這份文件」升級為「知道這份文件在這個情境下要求你做什麼」**。這是本書每章設有政府指引專節的原因。

本冊的定位

L21 是**必考共通科**。無論你選擇「數據分析」路線（L21 + L22）或「機器學習」路線（L21 + L23），本冊都必須讀完。L21 的特色是**廣而不深**：它不要求你手算統計量或讀 `scikit-learn` 程式碼，但要求你在 NLP、CV、生成式 AI、多模態、導入評估、風險治理、資料準備、系統部署八個面向上，都能做出正確的**選型與規劃判斷**。

每章的固定結構

1. 章節識別卡——代碼、來源、層級分布、先備知識、建議時數。
2. 學習目標——以可驗證動詞敘述（辨識、比較、計算、判讀、選擇、診斷、規劃、評估）。
3. 考綱對位表——官方代碼、官方主題、本章節點、正式題、政府文件。
4. 核心概念與技術原理——直觀說明先行，再給正式定義；含正例、反例與易混淆的鄰近概念。
5. 應用規劃與決策流程——情境判斷流程、技術選型表、七項折衷（成本、準確率、延遲、可解釋性、資安、隱私、維運）。
6. 常見陷阱與錯誤觀念。
7. 政府指引與產業落地實務——僅在有實質關聯時出現，並標明文件性質。
8. 正式公告試題——對位與考點拆解。
9. 自編模擬題——四選項逐一解析、干擾項設計理由、延伸考點。
10. 章末複習——一頁重點、必背名詞、五分鐘快速複習、跨章連結。
11. 來源與稽核紀錄。

授證路線導航

路線	科目組合	說明
數據分析路線	L21 + L22	取得「AI 應用規劃師（數據分析）」證書。 偏統計、資料處理與 BI。
機器學習路線	L21 + L23	取得「AI 應用規劃師（機器學習）」證書。 偏數學、模型訓練與調參。
三科全備	L21 + L22 + L23	屬自願擴充 ，須分兩梯次報考，且每次都必須併考 L21。 並非 取得單一證書的必經要求。

怎麼選第二科

日常工作涉及資料分析、報表、BI 者選 **L22**；對模型訓練、調參、深度學習有興趣者選 **L23**。兩科都含程式邏輯判斷題。 **版本敏感**

考試規則速覽

項目	規則
報考組合	L21 必考 ，L22 或 L23 擇一；僅考 L21 無法取證。
題數與時間	每科 50 題、90 分鐘（平均每題約 108 秒）。
及格標準	L21 與所選科目 均須 達 70 分。
單科保留	單科通過成績自應考日起保留 3 年。
證書效期	5 年；換證須於期間內累計 48 小時以上 AI 技術相關訓練（每年工作年資可折抵 8 小時）。
程式題	L22 / L23 含程式邏輯判斷題型；L21 不含。 版本敏感
計算機	須符合考選部核定之國家考試電子計算器型號，不得攜帶工程計算機或手機。

本節來源

IPAS-SYLLABUS-11504（115 年度能力鑑定簡章，115.04 版）、IPAS-EXEMPT-11501（中級科目抵免辦法，115.01 版）、IPAS-NOTICE-SAMPLE-1409（初級與中級考試樣題更新及新增中級考試題型說明）。
費用、日程與考區以官方最新公告為準。

考綱地圖：L22 大數據處理分析與應用

本冊涵蓋 4 項評鑑主題、13 項評鑑內容，一個代碼一章。

代碼	官方名稱	官方備註（評鑑內容）
L221 機率統計基礎		
L22101	敘述性統計與資料摘要技術	數據的集中趨勢、離散程度與分佈型態、數據清理與剖析
L22102	機率分佈與資料分佈模型	機率理論模型與分佈特性
L22103	假設檢定與統計推論	p 值判斷、Type I / II Error、顯著水準 α 、單尾與雙尾
L222 大數據處理技術		
L22201	數據收集與清理	數據預處理、特徵提取
L22202	數據儲存與管理	資料庫架構、儲存機制、模型訓練
L22203	數據處理技術與工具	Apache Spark、Hadoop、Kafka、批次 vs 串流處理
L223 大數據分析方法與工具		
L22301	統計學在大數據中的應用	數據轉換、縮放與分佈調整、特徵工程
L22302	常見的大數據分析方法	數據分析演算法、模式識別以及資料不平衡處理策略
L22303	數據可視化工具	資訊呈現的原則、圖表類型的選擇以及視覺化效能
L224 大數據在人工智慧之應用		
L22401	大數據與機器學習	大數據特性對機器學習演算法產生的底層影響與挑戰
L22402	大數據在鑑別式 AI 中的應用	大數據應用於預測、分類等鑑別式任務
L22403	大數據在生成式 AI 中的應用	生成式模型在處理大規模語料時的技術需求
L22404	大數據隱私保護、安全與合規	數據的安全性與法律合規技術

本冊定位

L22 為**選考科目**，與 L21（必考）組合後取得「AI 應用規劃師（數據分析）」證書。本科含**程式邏輯判斷題**，內容涵蓋 Python 語法與程式片段解析。**版本敏感**

L22 的難度不在數學深度，而在**三種能力的交叉**：統計判讀、分散式處理概念、以及 Python 片段的執行邏輯推演。

我國 AI 法制時間軸

法規題最常見的失分不是不知道內容，而是搞混**發布機關**與**拘束力層級**。請先建立這張表。政府實務

版本敏感

時間	文件	機關	文件性質	拘束力
112.08	行政院及所屬機關（構）使用生成式 AI 參考指引	行政院	行政規則／指引	拘束公務機關
113.03.14	金融機構運用人工智慧技術作業規範	銀行公會（金管會同意備查）	行政規則／指引（公會自律規範）	拘束會員機構
113.06.20	金融業運用人工智慧（AI）指引	金管會	行政規則／指引	監理期待
114.12.23	人工智慧基本法（三讀通過，共 20 條）	立法院；中央主管機關為國科會	法律	法律義務
115.07.07	人工智慧風險分類框架 v1.0	數位發展部	參考手冊	各目的事業主管機關間之共通指引；現階段對非公務機關不具直接拘束力

三個最容易記反的細節

- 主管機關**。《人工智慧基本法》的中央主管機關是**國科會**；而《人工智慧風險分類框架》是**數位發展部**依該法第 16 條所訂定。兩者常被混為一談。
- 拘束力**。《風險分類框架》是主管機關之間的共通語言，現階段對民間企業不具直接拘束力；真正產生拘束力的，是各目的事業主管機關依此框架轉化而成的領域管理規範（例如金管會之於金融業）。
- 風險衡量基準**。高風險認定採**客觀固有風險**：只要有造成危害之可能即為已足，不以實際發生損害為必要，且**不考慮**現有法規、行政措施或技術手段的緩解效果。考題常以「我們已加了防護措施所以不算高風險」設陷阱。

《人工智慧基本法》七大原則（必背）

永續發展與福祉、**人類自主**、隱私保護與資料治理、資安與安全、**透明與可解釋**、**公平與不歧視**、問責。

另須記住：行政院應設「**國家人工智慧戰略特別委員會**」；第 19 條要求政府使用 AI 執行業務或提供服務時應進行風險評估、規劃因應措施，並依業務性質訂定使用規範或內控管理機制。

本節來源與查核狀態

GOV-AI-BASIC-ACT（法律）、GOV-MODA-RISK-V1（參考手冊）、GOV-EY-GENAI（行政規則／指引）、GOV-FSC-AI（行政規則／指引）、GOV-BA-AI-RULES（公會自律規範經備查）。

查核日：中華民國 115 年 8 月 1 日。**待查證：**《人工智慧基本法》除第 16、17、19 條外之相關條次尚未逐條核對，本書不引用未經確認之條號。

L22 答題策略與命題密度

命題密度與研讀優先序

下表依 114 年第二次與 115 年第一次兩場次正式公告試題（L22 科目共 100 題）之實際分布統計。L 代碼為編者對位，非官方逐題分類。

優先	代碼	章名	題數	佔比	建議投入
1	L22203	數據處理技術與工具	20	20%	最高
2	L22302	常見的大數據分析方法	17	17%	最高
3	L22301	統計學在大數據中的應用	9	9%	高
4	L22201	數據收集與清理	8	8%	高
5	L22202	數據儲存與管理	8	8%	高
6	L22101	敘述性統計與資料摘要技術	7	7%	中
7	L22103	假設檢定與統計推論	7	7%	中
8	L22303	數據可視化工具	7	7%	中
9	L22402	大數據在鑑別式 AI 中的應用	6	6%	中
10	L22404	大數據隱私保護、安全與合規	5	5%	中
11	L22102	機率分佈與資料分佈模型	4	4%	中
12	L22401	大數據與機器學習	1	1%	低
13	L22403	大數據在生成式 AI 中的應用	1	1%	低

四個必須知道的分布事實

1. **L22203 (Spark / Hadoop / Kafka / 批次與串流) 單章 20 題**，是全科最大單一考點。分散式處理的概念題與程式片段判讀合計貢獻五分之一的分數。
2. **L22302 (分析方法與不平衡處理) 17 題**，居次。分群、關聯規則、時序與不平衡策略是密集出題區。
3. **L222 與 L223 兩個群組合計 69 題**，佔全科近七成。L221 統計基礎 18 題、L224 應用 13 題。
4. **L22401 與 L22403 各僅 1 題**。這兩章屬概念收尾，讀懂即可，不必深挖。

答題策略

1. **程式題先看回傳型別**，不要在腦中「執行」整段。多數程式題考的是「這行回傳 Series 還是 DataFrame」「是就地修改還是回傳新物件」「回傳陣列還是純量」，而非計算結果。
2. **Spark 題先分辨 Transformation 與 Action**。看到 filter、select、groupBy、withColumn 一律不執行；看到 count()、collect()、show()、write 才觸發運算。
3. **統計題先確認方向性**。偏態方向、 p 值定義、型一型二錯誤、PSI 與相關係數的高低意義，都是「方向記反就全錯」的題型。
4. **不平衡處理題先問「在哪一層動手」**。資料層（重採樣）／演算法層（權重）／決策層（閾值）／評估

層（換指標），四層各有適用時機。

5. **圖表題先看座標軸**。Y 軸是否從 0 起、是否為對數尺度、雙軸是否誤導，是視覺化題的固定考點。
6. **時間控管**。90 分鐘 50 題，程式題約 12–13 題且耗時較長。建議先掃完非程式題（約 40 分鐘），再回頭處理程式題。

本科最高頻的五個方向性陷阱

1. **右偏（正偏態）**：平均數 $>$ 中位數 $>$ 眾數。長尾在右，平均被拉高。
2. **p 值**：是「 H_0 為真時觀察到此結果或更極端的機率」，**不是**「 H_0 為真的機率」。
3. **降低 α** ：型一錯誤減少，但型二錯誤**增加**。
4. **提升度（Lift）**： > 1 才代表正關聯； ≈ 1 表示獨立，信賴度再高也無行動價值。
5. **Min-Max 正規化**：對離群值**極度敏感**，一個極端值就會把其餘資料壓到接近 0。

Contents

免責與使用聲明	i
導讀：中級考試的本質轉變	ii
授證路線導航	iii
考綱地圖：L22	iv
我國 AI 法制時間軸	v
L22 答題策略與命題密度	vii
I L221 機率統計基礎	1
1 敘述性統計與資料摘要技術	2
學習目標	2
考綱對位	2
1.1 核心概念與技術原理	2
1.2 程式判讀重點	4
1.3 常見陷阱與錯誤觀念	4
1.4 正式公告試題索引	4
1.5 自編模擬題	5
1.6 章末複習	7
2 機率分佈與資料分佈模型	9
學習目標	9
考綱對位	9
2.1 核心概念與技術原理	9
2.2 常見陷阱與錯誤觀念	11
2.3 正式公告試題索引	11
2.4 自編模擬題	11
2.5 章末複習	13
3 假設檢定與統計推論	14
學習目標	14
考綱對位	14
3.1 核心概念與技術原理	14
3.2 程式判讀重點	16
3.3 常見陷阱與錯誤觀念	16
3.4 政府指引與產業落地實務	17
3.5 正式公告試題索引	17

3.6	自編模擬題	18
3.7	章末複習	20
II	L222 大數據處理技術	21
4	數據收集與清理	22
	學習目標	22
	考綱對位	22
4.1	核心概念與技術原理	22
4.2	程式判讀重點	24
4.3	常見陷阱與錯誤觀念	24
4.4	政府指引與產業落地實務	24
4.5	正式公告試題索引	25
4.6	自編模擬題	25
4.7	章末複習	27
5	數據儲存與管理	29
	學習目標	29
	考綱對位	29
5.1	核心概念與技術原理	29
5.2	常見陷阱與錯誤觀念	31
5.3	政府指引與產業落地實務	31
5.4	正式公告試題索引	31
5.5	自編模擬題	32
5.6	章末複習	34
6	數據處理技術與工具	36
	學習目標	36
	考綱對位	36
6.1	核心概念與技術原理	37
6.2	程式判讀重點	40
6.3	常見陷阱與錯誤觀念	40
6.4	正式公告試題索引	40
6.5	自編模擬題	42
6.6	章末複習	45
III	L223 大數據分析方法與工具	47
7	統計學在大數據中的應用	48
	學習目標	48
	考綱對位	48
7.1	核心概念與技術原理	48
7.2	程式判讀重點	50

7.3	常見陷阱與錯誤觀念	50
7.4	正式公告試題索引	51
7.5	自編模擬題	51
7.6	章末複習	54
8	常見的大數據分析方法	56
	學習目標	56
	考綱對位	56
8.1	核心概念與技術原理	57
8.2	程式判讀重點	59
8.3	常見陷阱與錯誤觀念	60
8.4	政府指引與產業落地實務	60
8.5	正式公告試題索引	60
8.6	自編模擬題	61
8.7	章末複習	65
9	數據可視化工具	67
	學習目標	67
	考綱對位	67
9.1	核心概念與技術原理	67
9.2	程式判讀重點	68
9.3	常見陷阱與錯誤觀念	69
9.4	政府指引與產業落地實務	69
9.5	正式公告試題索引	70
9.6	自編模擬題	70
9.7	章末複習	72
IV	L224 大數據在人工智慧之應用	74
10	大數據與機器學習	75
	學習目標	75
	考綱對位	75
10.1	核心概念與技術原理	75
10.2	程式判讀重點	76
10.3	常見陷阱與錯誤觀念	77
10.4	正式公告試題索引	77
10.5	自編模擬題	77
10.6	章末複習	78
11	大數據在鑑別式 AI 中的應用	80
	學習目標	80
	考綱對位	80
11.1	核心概念與技術原理	80
11.2	程式判讀重點	81

11.3 常見陷阱與錯誤觀念	81
11.4 正式公告試題索引	82
11.5 自編模擬題	82
11.6 章末複習	84
12 大數據在生成式 AI 中的應用	85
學習目標	85
考綱對位	85
12.1 核心概念與技術原理	85
12.2 常見陷阱與錯誤觀念	86
12.3 政府指引與產業落地實務	87
12.4 正式公告試題索引	87
12.5 自編模擬題	88
12.6 章末複習	89
13 大數據隱私保護、安全與合規	90
學習目標	90
考綱對位	90
13.1 核心概念與技術原理	91
13.2 程式判讀重點	92
13.3 常見陷阱與錯誤觀念	93
13.4 政府指引與產業落地實務	93
13.5 正式公告試題索引	94
13.6 自編模擬題	95
13.7 章末複習	97
V 附錄	99
14 附錄 A：政府指引速查表	100
14.1 文件性質與拘束力對照	100
14.2 必背清單	101
14.3 三個最容易記反的細節	101
14.4 寫作與作答句型	101
15 附錄 D：勘誤、來源登錄與本冊建置狀態	103
15.1 已套用之勘誤	103
15.2 編號正規化紀錄	103
15.3 正式公告試題索引之採用與限制	103
15.4 L22 命題密度統計	104
15.5 未解決之資料缺口與補件流程	105
15.6 本冊建置狀態	105

Part I

L221 機率統計基礎

第 1 章

敘述性統計與資料摘要技術

章節識別卡

官方代碼	L22101
官方名稱	敘述性統計與資料摘要技術
官方備註	數據的集中趨勢、離散程度與分佈型態、數據清理與剖析
所屬	L22 / L221 機率統計基礎
授證路線	DATA_ANALYSIS
資料截止日	中華民國 115 年 8 月 1 日
對應來源	IPAS-SCOPE-11502、IPAS-GUIDE-L22（頁碼 PENDING ）
層級分布	核心必考 85% 官方補充 15% 政府實務 0% 產業延伸 0%
先備知識	高中數學；pandas DataFrame 基本操作
建議時數	2.5 小時
本版題數	模擬題 4 題（含程式判讀 2 題）

學習目標

1. 選擇適合資料型態與分布的集中趨勢統計量。
2. 判斷偏態方向與平均數、中位數、眾數的大小關係。
3. 計算變異數、標準差、四分位距與離群值上下界。
4. 比較 Pearson 與 Spearman 相關係數的適用條件。
5. 判讀 pandas 摘要統計輸出的型別與意義。

考綱對位

代碼	官方主題	本章節點	正式題	程式題	政府文件
L22101	敘述性統計與資料摘要技術	集中趨勢三統計量與選用	見索引	有	—
L22101	同上	離散程度與變異係數	見索引	有	—
L22101	同上	偏態方向與分佈型態	見索引	無	—
L22101	同上	箱型圖與離群值判定	見索引	有	—
L22101	同上	相關係數與其限制	見索引	無	—

1.1 核心概念與技術原理

1.1.1 集中趨勢：三個統計量的選用

核心必考

統計量	定義	對離群值	適用
平均數	總和除以個數	極度敏感	對稱分布、需可加總
中位數	排序後居中之值	穩健	偏態分布(所得、房價、等待時間)
眾數	出現次數最多之值	穩健	類別型資料的唯一選擇

偏態方向：必背的一句話

右偏（正偏態）：平均數 > 中位數 > 眾數。長尾拖向右側。典型例子為所得、理賠金額、網頁停留時間。

左偏（負偏態）：平均數 < 中位數 < 眾數。典型例子為及格率高的考試成績、設備壽命。

記憶法：平均數永遠被長尾拖走。尾巴在哪邊，平均數就往哪邊偏。因此描述所得水準應報**中位數**，用平均數會被少數極高所得者拉高而失真。

1.1.2 離散程度

核心必考

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} \quad s = \sqrt{s^2} \quad CV = \frac{s}{\bar{x}}$$

符號： s^2 為**樣本變異數**，分母 $n-1$ 為貝索校正，目的是得到母體變異數的**不偏估計**；CV 為變異係數。

- 全距：最大減最小，極易受離群值影響。
- 四分位距 $IQR = Q3 - Q1$ ，涵蓋中間 50% 的資料，穩健。
- 變異係數 CV：無單位，用於**比較不同尺度或不同單位**資料的相對變異程度。要比較股價（元）與交易量（股）的波動性，只能用 CV。

1.1.3 箱型圖與離群值判定

核心必考

五數概括：最小值、 $Q1$ 、中位數、 $Q3$ 、最大值。鬚延伸至距箱體 $1.5 \times IQR$ 內的最遠資料點，超出者標為離群值。

$$\text{下界} = Q1 - 1.5 IQR \quad \text{上界} = Q3 + 1.5 IQR$$

例： $Q1 = 20$ 、 $Q3 = 40 \Rightarrow IQR = 20$ ，界線為 $20 - 30 = -10$ 與 $40 + 30 = 70$ 。數值 75 即為離群值。此為本章高頻計算題。

1.1.4 相關係數

核心必考

	Pearson	Spearman
衡量	線性關聯	單調關聯（以等級計算）
資料要求	連續、近似常態	順序尺度即可
對離群值	敏感	穩健
值域	$[-1, 1]$	$[-1, 1]$

1.2 程式判讀重點

核心必考

pandas 摘要統計的回傳型別

```

1 df.describe() # -> DataFrame (僅數值欄；含 count/mean/std/min/25%/50%/75%/max)
2 df['sales'].describe() # -> Series
3 df.mean() # -> Series (各欄平均，自動略過 NaN)
4 df['sales'].mean() # -> numpy.float64 (純量)
5 df.median(numeric_only=True)

```

三個必考細節：(1) describe() 的 50% 就是中位數；(2) 聚合函式預設略過 NaN，因此 `df['x'].sum()/len(df)` 與 `df['x'].mean()` 在有缺值時不相等；(3) std() 預設 ddof=1（樣本標準差），而 `numpy.std()` 預設 ddof=0（母體），兩者結果不同。

1.3 常見陷阱與錯誤觀念

常見陷阱與錯誤觀念

- 相關不等於因果。冰淇淋銷量與溺水人數高度相關，共同原因是氣溫（干擾變數）。
- Pearson = 0 不等於獨立。若 $y = x^2$ 且 x 對稱分布於 0 兩側，Pearson 可為 0，但兩者完全相依。務必搭配散布圖檢視。
- 辛普森悖論。分組後每組趨勢與合併後趨勢相反，在比較分行或科別績效時極常見。
- 標準差為 0 代表該欄為常數，對模型毫無資訊量，應於前處理刪除。
- 以平均數描述偏態資料。所得、房價一律用中位數。
- 混淆母體與樣本標準差。pandas 預設 ddof=1，numpy 預設 ddof=0。

1.4 正式公告試題索引

本章命題密度

兩場次正式公告試題（114 年第二次、115 年第一次）之 L22 科目共 100 題，其中對位至本代碼者 7 題，佔 7%。

本索引之 L 代碼為編者對位，非官方逐題分類；官方答案則照錄官方公告。

題目 ID	場次	官方答案	原卷頁次	含圖表	對位備註
OFFICIAL-114-2-L22-Q01	114-2	D	p.1	—	—
OFFICIAL-114-2-L22-Q02	114-2	B	p.1	—	—
OFFICIAL-114-2-L22-Q03	114-2	A	p.1	是	須對照原卷圖表
OFFICIAL-114-2-L22-Q16	114-2	A	p.4	—	—
OFFICIAL-114-2-L22-Q27	114-2	D	p.7-8	—	—
OFFICIAL-115-1-L22-Q01	115-1	A	p.1	—	—
OFFICIAL-115-1-L22-Q05	115-1	A	p.2	—	—

著作權處理與使用方式

官方試題為受著作權保護之著作。本書不重製官方題幹與選項全文，僅提供題目 ID、場次、官方答案、原卷頁次與考綱對位。

請依上表之原卷頁次，至 iPAS 官網「AI 應用規劃師 → 學習資源」下載該場次公告試題 PDF 對照閱讀；本章前述之核心概念、決策表與陷阱清單即為該批題目的考點拆解。

1.5 自編模擬題

模擬題 SIM-L22101-001 | 計算題 | 難度：基礎 | 對應 L22101

某組資料之 $Q1 = 32$ 、 $Q3 = 68$ 。依 $1.5 \times IQR$ 準則判定，下列哪一個數值屬於離群值？

- (A) -20
- (B) 12
- (C) 100
- (D) 125

答案與逐項解析

答案：D

$IQR = 68 - 32 = 36$ ， $1.5 \times 36 = 54$ 。

下界 $= 32 - 54 = -22$ ；上界 $= 68 + 54 = 122$ 。

(A) $\times$ -20 大於下界 -22，落在界內，不是離群值。

(B) $\times$ 12 落在 $[-22, 122]$ 內。

(C) $\times$ 100 落在界內。

(D) $\checkmark$ 正解。125 超過上界 122，為離群值。

干擾項設計理由：(A) 利用「負值看起來就很異常」的直覺，實際上 -20 仍在下界之內；(C) 設在接近上界處，測試是否確實計算而非目測。

延伸考點： $1.5 \times IQR$ 為溫和離群值準則， $3 \times IQR$ 為極端離群值準則。若改以 3 倍計算，上界為 $68 + 108 = 176$ ，則 125 不再是離群值——命題若指定倍數，務必依題目所給者計算。

模擬題 SIM-L22101-002 | 觀念題 | 難度：基礎 | 對應 L22101

某縣市家戶年所得資料呈明顯右偏（少數極高所得者）。若欲向大眾說明「一般家庭的所得水準」，下列何者最為適當？

- (A) 使用平均數，因其利用了全部資料的資訊
- (B) 使用中位數，因平均數會被少數極高所得者拉高而失真
- (C) 使用全距，因其能呈現所得的完整範圍
- (D) 使用眾數，因其代表最多人擁有的所得

答案與逐項解析

答案：B

- (A) × 「利用全部資料」正是問題所在——右偏分布中，少數極端值會把平均數拉離多數人的實際水準。
- (B) ✓ **正解**。右偏時平均數 > 中位數 > 眾數；中位數對離群值穩健，最能代表「一般」家庭。
- (C) × 全距描述的是離散程度而非集中趨勢，且受兩個極端值完全支配。
- (D) × 連續型所得資料的眾數不穩定（需先分箱），且會低估整體水準。

延伸考點：官方統計常同時公布平均數與中位數，兩者差距本身即為**所得分配不均**的訊號——差距越大代表右偏越嚴重。

模擬題 SIM-L22101-003 | 程式判讀 | 難度：中級 | 對應 L22101

給定 df 有欄位 sales，其中含 3 筆 NaN，總列數為 100。執行下列程式後，a 與 b 的關係為何？

```
1 a = df['sales'].mean()
2 b = df['sales'].sum() / len(df)
```

- (A) $a == b$ ，因兩者皆為平均數
- (B) $a > b$ ，因 mean() 略過 NaN（分母為 97），而 b 的分母為 100
- (C) $a < b$
- (D) 兩者皆會因 NaN 而回傳 NaN

答案與逐項解析

答案：B

- (A) × 分母不同。
- (B) ✓ **正解**。mean() 與 sum() 皆預設略過 NaN，故分子相同；但 mean() 的分母是非缺失筆數 97，而 len(df) 是總列數 100。分子相同、分母較大者較小，故 $a > b$ （假設 sales 均為正值）。
- (C) × 方向相反。
- (D) × pandas 聚合函式預設 skipna=True，不會回傳 NaN。這與 numpy.mean() 不同——後者遇 NaN 會回傳 NaN，須改用 numpy.nanmean()。

干擾項設計理由：(D) 針對 pandas 與 numpy 對 NaN 處理差異的混淆。

延伸考點：若 sales 含負值， $a > b$ 的結論不必然成立——嚴格說法是「分母不同故通常不相等」。實務上要計算「含缺值視為 0 的平均」應寫 `df['sales'].fillna(0).mean()`，語意才明確。

模擬題 SIM-L22101-004 | 程式判讀 | 難度：中級 | 對應 L22101

關於下列程式之敘述，何者錯誤？

```
1 s1 = df['x'].std()
2 s2 = np.std(df['x'].values)
3 d = df.describe()
```

- (A) s1 為樣本標準差 (ddof=1)，s2 為母體標準差 (ddof=0)，兩者數值不同
- (B) d 為 DataFrame，其 50% 一列即為中位數
- (C) d 預設僅摘要數值型欄位
- (D) s1 與 s2 必定相等，因為兩者計算的都是同一欄的標準差

答案與逐項解析

答案：D

- (A) ✓ 正確。pandas 的 std() 預設 ddof=1 (分母 $n-1$)；numpy.std() 預設 ddof=0 (分母 n)。
- (B) ✓ 正確。
- (C) ✓ 正確。若要納入類別欄需傳 include='all'。
- (D) × 錯誤 (即為答案)。兩者分母不同，數值必然不同 (除非 $n \rightarrow \infty$ 時趨近)。樣本標準差略大於母體標準差。

延伸考點：貝索校正 ($n-1$) 的目的是讓樣本變異數成為母體變異數的不偏估計。當 n 很大時兩者差異可忽略，但在小樣本 (如 $n=10$) 差異明顯。此考點在 L23101 會以 ddof 參數形式再次出現。

1.6 章末複習

1.6.1 一頁重點

主題	必記結論
集中趨勢	偏態用中位數；類別型只能用眾數
偏態	右偏：平均 > 中位 > 眾數；平均被長尾拖走
變異數	樣本分母 $n-1$ (不偏估計)
CV	比較不同單位資料的相對變異
離群值	上下界 = $Q3 + 1.5IQR$ 、 $Q1 - 1.5IQR$
相關係數	Pearson 線性且敏感；Spearman 單調且穩健；相關 $\neq$ 因果， $0 \neq$ 獨立
程式	describe() 回 DataFrame；聚合預設略過 NaN；std 的 ddof pandas 為 1、numpy 為 0

1.6.2 必背名詞

集中趨勢、離散程度、偏態 (Skewness)、峰態 (Kurtosis)、四分位距 (IQR)、變異係數 (CV)、貝索校正、Pearson 相關、Spearman 等級相關、辛普森悖論。

1.6.3 五分鐘快速複習

1. 說出右偏分布中三個統計量的大小順序。
2. 手算一組 $Q1$ 、 $Q3$ 的離群值上下界。
3. 說出何時必須用變異係數而非標準差。
4. 說出 `df['x'].mean()` 與 `df['x'].sum()/len(df)` 為何可能不等。
5. 說出 Pearson 相關為 0 時能否推論兩變數獨立。

1.6.4 跨章連結

Chapter 7：轉換與縮放；Chapter 9：箱型圖與分布呈現；Chapter 3：由敘述統計進入推論統計。

來源與稽核紀錄

官方來源：IPAS-SCOPE-11502（L22101 備註欄）；IPAS-GUIDE-L22（頁碼 **PENDING**）。

編者推論／延伸：選用對照表、偏態記憶法、程式判讀重點、四題模擬題與干擾項設計。

未解決資料缺口：學習指引頁碼；中級勘誤表完整條目。

第 2 章

機率分佈與資料分佈模型

章節識別卡

官方代碼	L22102
官方名稱	機率分佈與資料分佈模型
官方備註	機率理論模型與分佈特性
所屬	L22 / L221 機率統計基礎
授證路線	DATA_ANALYSIS
資料截止日	中華民國 115 年 8 月 1 日
對應來源	IPAS-SCOPE-11502、IPAS-GUIDE-L22（頁碼 PENDING ）
層級分布	核心必考 85% 官方補充 15% 政府實務 0% 產業延伸 0%
先備知識	Chapter 1；排列組合與機率基礎
建議時數	2.5 小時
本版題數	模擬題 3 題（含程式判讀 1 題）

學習目標

1. 辨識給定隨機現象所對應的機率分佈。
2. 說明卜瓦松與指數分佈的互補關係。
3. 計算 Z 分數並套用經驗法則。
4. 說明中央極限定理的三項推論。

考綱對位

代碼	官方主題	本章節點	正式題	程式題	政府文件
L22102	機率分佈與資料分佈模型	六種常見分佈之辨識	見索引	有	—
L22102	同上	卜瓦松與指數的一體兩面	見索引	無	—
L22102	同上	常態分佈與 Z 分數	見索引	有	—
L22102	同上	中央極限定理	見索引	無	—

2.1 核心概念與技術原理

2.1.1 六種常見分佈的辨識

核心必考

分佈	描述的隨機現象	參數	典型場景
伯努利	單次二元試驗	p	單一客戶是否點擊
二項	n 次獨立試驗中的成功次數	n, p	100 次投放中的轉換數
卜瓦松	固定時間或空間內事件發生次數	λ	每小時來電數、每片晶圓瑕疵點數
常態	對稱鐘形連續量	μ, σ	身高、量測誤差、大樣本平均數
指數	事件之間的間隔時間	λ	兩次故障間的時間
均勻	區間內等機率	a, b	隨機取樣模擬

卜瓦松與指數：一體兩面

若「每小時來電次數」服從卜瓦松分佈（ $\lambda = 5$ 次／小時），則「兩次來電之間的等待時間」服從指數分佈，平均間隔 $1/\lambda = 0.2$ 小時。

題幹問「次數」用卜瓦松，問「時間間隔」用指數。

卜瓦松的另一特性：平均數等於變異數，皆為 λ 。若實際資料的變異數遠大於平均數（過度離散），應改用負二項分佈。

2.1.2 常態分佈與 Z 分數

核心必考

$$z = \frac{x - \mu}{\sigma}$$

經驗法則（68-95-99.7）：資料落在 $\mu \pm 1\sigma$ 、 $\mu \pm 2\sigma$ 、 $\mu \pm 3\sigma$ 的比例分別約為 68%、95%、99.7%。此為製程管制（ 3σ 界限）與異常偵測的基礎。

$z = 2$ 代表該值高於平均兩個標準差；標準常態分佈為 $N(0, 1)$ 。

2.1.3 中央極限定理

核心必考

不論母體為何種分佈，只要樣本量 n 足夠大（經驗上 $n \geq 30$ ），樣本平均數的抽樣分佈近似常態，其標準差（標準誤）為 $\sigma/\sqrt{n}$ 。

三個必考推論

1. 中央極限定理講的是樣本平均數的分佈，不是原始資料會變成常態。
2. 標準誤隨 $\sqrt{n}$ 縮小——要把誤差減半需把樣本量變為四倍。
3. 這是所有信賴區間與假設檢定的理論基礎。

2.2 常見陷阱與錯誤觀念

常見陷阱與錯誤觀念

- 以為中央極限定理會讓原始資料變常態。它描述的是樣本平均數的抽樣分佈。
- 混淆卜瓦松與指數。問次數用卜瓦松，問間隔時間用指數。
- 把二項與卜瓦松混用。二項有明確的試驗次數 n ；卜瓦松是在連續時間或空間上計次，沒有 n 。
- 忽略獨立性假設。卜瓦松要求事件獨立發生；若來電有明顯尖峰群聚，模型即不適用。
- 誤以為標準誤等於標準差。標準誤是樣本平均數的標準差，為 $\sigma/\sqrt{n}$ 。

2.3 正式公告試題索引

本章命題密度

兩場次正式公告試題（114 年第二次、115 年第一次）之 L22 科目共 100 題，其中對位至本代碼者 4 題，佔 4%。

本索引之 L 代碼為編者對位，非官方逐題分類；官方答案則照錄官方公告。

題目 ID	場次	官方答案	原卷頁次	含圖表	對位備註
OFFICIAL-114-2-L22-Q04	114-2	B	p.1-2	—	—
OFFICIAL-114-2-L22-Q15	114-2	C	p.4	—	—
OFFICIAL-114-2-L22-Q31	114-2	B	p.8-9	—	—
OFFICIAL-115-1-L22-Q03	115-1	B	p.1	—	—

著作權處理與使用方式

官方試題為受著作權保護之著作。本書不重製官方題幹與選項全文，僅提供題目 ID、場次、官方答案、原卷頁次與考綱對位。

請依上表之原卷頁次，至 iPAS 官網「AI 應用規劃師 → 學習資源」下載該場次公告試題 PDF 對照閱讀；本章前述之核心概念、決策表與陷阱清單即為該批題目的考點拆解。

2.4 自編模擬題

模擬題 SIM-L22102-001 | 辨識題 | 難度：基礎 | 對應 L22102

某客服中心平均每小時接到 6 通來電。若欲建模「連續兩通來電之間的等待時間」，最適當的機率分佈為何？

- (A) 二項分佈
- (B) 卜瓦松分佈
- (C) 指數分佈
- (D) 均勻分佈

答案與逐項解析

答案：C

- (A) × 二項分佈描述固定次數試驗中的成功次數，本題無「固定試驗次數」。
- (B) × 卜瓦松描述的是「每小時接到幾通」——即**次數**，不是間隔時間。
- (C) ✓ **正解**。事件發生次數服從卜瓦松時，事件**間隔時間**服從指數分佈。本題平均間隔為 $1/6$ 小時（10 分鐘）。
- (D) × 均勻分佈假設區間內等機率，與等待時間「短間隔較常見、長間隔較罕見」的實際型態不符。
- 延伸考點：**若題幹改問「一小時內接到超過 10 通的機率」，答案就變成卜瓦松。**次數** → 卜瓦松、**間隔** → **指數**是同一組現象的兩種問法。

模擬題 SIM-L22102-002 | 計算題 | 難度：中級 | 對應 L22102

某產線零件重量近似常態分佈， $\mu = 50$ 公克、 $\sigma = 2$ 公克。若品管規定重量須落在 46 至 54 公克之間，依經驗法則，約有多少比例的零件會被判定為不合格？

- (A) 約 0.3%
- (B) 約 5%
- (C) 約 32%
- (D) 約 68%

答案與逐項解析

答案：B

- $46 = 50 - 2 \times 2$ ， $54 = 50 + 2 \times 2$ ，即 $\mu \pm 2\sigma$ 。
- 依經驗法則， $\mu \pm 2\sigma$ 內約含 **95%** 資料，故落在區間外者約 $100\% - 95\% = 5\%$ 。
- (A) × 0.3% 對應 $\mu \pm 3\sigma$ 之外。
- (B) ✓ **正解**。
- (C) × 32% 對應 $\mu \pm 1\sigma$ 之外。
- (D) × 68% 是 $\mu \pm 1\sigma$ 之**內**的比例，方向與問法相反。
- 干擾項設計理由：**(D) 直接取用經驗法則的數字但未依題目所問的「之外」轉換。
- 延伸考點：**製程能力常以 $\pm 3\sigma$ （約 99.7%）為管制界限，界外約 0.3%。若規格改為 $\mu \pm 3\sigma$ ，不合格率降至約 0.3%——這也是六標準差管理的思路來源。

模擬題 SIM-L22102-003 | 程式判讀 | 難度：中級 | 對應 L22102

執行下列程式後，關於 m 之分佈的敘述何者最為正確？

```
1 import numpy as np
2 pop = np.random.exponential(scale=3, size=1000000) # 母體：右偏
3 m = [np.mean(np.random.choice(pop, 100)) for _ in range(5000)]
```

- (A) m 會呈現與母體相同的右偏分佈
- (B) m 的分佈近似常態，因為它是樣本平均數的抽樣分佈（中央極限定理）
- (C) m 的標準差會等於母體標準差
- (D) m 必為均勻分佈

答案與逐項解析

答案：B

(A) × 這是對中央極限定理最常見的誤解。母體雖為右偏的指數分佈，但 m 蒐集的是**每次抽 100 筆的平均數**，不是原始值。

(B) ✓ **正解**。樣本量 $n = 100 \geq 30$ ，樣本平均數的抽樣分佈近似常態。

(C) × m 的標準差是**標準誤**，約為 $\sigma/\sqrt{100} = \sigma/10$ ，遠小於母體標準差。

(D) × 無此結論。

干擾項設計理由：(A) 針對「抽樣不會改變分佈形狀」的錯誤直覺；(C) 針對標準誤與標準差的混淆。

延伸考點：若把 100 改為 4，樣本量過小，中央極限定理的近似效果會明顯變差， m 仍保有可見的右偏。這正是「 $n \geq 30$ 」經驗門檻的意義。

2.5 章末複習

2.5.1 一頁重點

主題	必記結論
分佈辨識	次數 → 二項／卜瓦松；間隔時間 → 指數；連續對稱 → 常態
卜瓦松	平均數 = 變異數 = λ ；過度離散改用負二項
常態	68-95-99.7； $z = (x - \mu)/\sigma$
中央極限定理	是 樣本平均數 近似常態；標準誤 = $\sigma/\sqrt{n}$ ；誤差減半需樣本四倍

2.5.2 必背名詞

伯努利、二項、卜瓦松、常態、指數、均勻分佈、Z 分數、標準常態、中央極限定理（CLT）、標準誤（Standard Error）、過度離散（Overdispersion）。

2.5.3 五分鐘快速複習

1. 說出卜瓦松與指數各自回答什麼問題。
2. 背出 68-95-99.7 並能反推「界外比例」。
3. 說出中央極限定理描述的是誰的分佈。
4. 說出把估計誤差減半需要多少樣本。

2.5.4 跨章連結

Chapter 3：中央極限定理是檢定與信賴區間的基礎；Chapter 8：分佈假設影響異常偵測門檻的設定。

來源與稽核紀錄

官方來源：IPAS-SCOPE-11502（L22102 備註欄「機率理論模型與分佈特性」）；IPAS-GUIDE-L22（頁碼 **PENDING**）。

編者推論／延伸：分佈辨識表、卜瓦松與指數對照、三題模擬題與干擾項設計。

未解決資料缺口：學習指引頁碼；中級勘誤表完整條目。

第 3 章

假設檢定與統計推論

章節識別卡

官方代碼	L22103
官方名稱	假設檢定與統計推論
官方備註	p 值判斷、Type I / II Error、顯著水準 α 、單尾與雙尾
所屬	L22 / L221 機率統計基礎
授證路線	DATA_ANALYSIS
資料截止日	中華民國 115 年 8 月 1 日
對應來源	IPAS-SCOPE-11502、IPAS-GUIDE-L22（頁碼 PENDING ）
層級分布	核心必考 85% 官方補充 15% 政府實務 0% 產業延伸 0%
先備知識	Chapter 1、Chapter 2（中央極限定理）
建議時數	3.0 小時
本版題數	模擬題 4 題（含程式判讀 1 題）
備註	官方備註欄逐項點名之考點， 方向性陷阱密集

學習目標

1. 陳述 p 值的正確定義，並辨識四種常見誤讀。
2. 區分型一與型二錯誤，並說明調整 α 對兩者的相反影響。
3. 判斷應採單尾或雙尾檢定。
4. 選擇適合情境的檢定方法。
5. 區分統計顯著與實務顯著。

考綱對位

代碼	官方主題	本章節點	正式題	程式題	政府文件
L22103	假設檢定與統計推論	檢定五步驟與 p 值定義	見索引	有	—
L22103	同上	型一／型二錯誤與檢定力	見索引	無	—
L22103	同上	顯著水準 α 之調整效果	見索引	無	—
L22103	同上	單尾與雙尾	見索引	無	—
L22103	同上	常見檢定選用與多重比較	見索引	有	GOV-FSC-AI

3.1 核心概念與技術原理

3.1.1 檢定五步驟

核心必考

1. 設定虛無假設 H_0 （通常為「沒有差異／沒有效果」）與對立假設 H_1 。
2. 選定顯著水準 α （通常 0.05），此即可容忍的型一錯誤機率。
3. 計算檢定統計量與 p 值。
4. 決策： $p < \alpha$ 則拒絕 H_0 ；否則不拒絕 H_0 。
5. 於業務脈絡解讀，並報告效果量與信賴區間。

p 值的正確定義（本科最高頻陷阱）

p 值是：假設 H_0 為真的前提下，觀察到目前結果或更極端結果的機率。

它不是「 H_0 為真的機率」；不是「 H_1 為假的機率」；不是效果大小；不是結果可重現的機率。

$p = 0.03$ 的意思是「若真的沒有差異，出現這麼大差異的機率只有 3%」，故我們傾向認為真的有差異。

另一鐵律：檢定結果只能說「拒絕」或「不拒絕」 H_0 ，永遠不能說「接受 H_0 」——證據不足不等於證明沒有差異。

3.1.2 兩類錯誤與檢定力

核心必考

	H_0 實際為真	H_0 實際為假
拒絕 H_0	型一錯誤 (α) 偽陽性——說有效其實無效	正確 (檢定力 = $1 - \beta$)
不拒絕 H_0	正確	型二錯誤 (β) 偽陰性——說無效其實有效

方向性必背

在其他條件不變下，調低 α （如 0.05 降至 0.01）會使型一錯誤減少，但型二錯誤增加，檢定力下降。

唯一能同時降低兩者的方法是增加樣本量。

檢定力 ($1 - \beta$) 受四項影響：樣本量（越大越高）、效果量（越大越高）、 α （越大越高）、資料變異（越小越高）。

3.1.3 單尾與雙尾

核心必考

研究問題為「有無差異」用雙尾；明確方向為「是否更高」用單尾。單尾在同一 α 下較容易達到顯著，因此方向必須事前決定——看到資料後才改成單尾屬於統計操弄。

3.1.4 常見檢定的選用

核心必考

情境	檢定	備註
兩組平均數比較	獨立樣本 t 檢定	母體變異未知、樣本較小
同一組前後比較	成對樣本 t 檢定	配對消除個體間變異，檢定力較高
三組以上平均數	變異數分析 (F 檢定)	直接兩兩 t 檢定會膨脹型一錯誤
兩類別變數關聯	卡方獨立性檢定	期望次數過小時改用精確檢定
分佈是否相同	KS 檢定	漂移偵測常用
不符常態假設	無母數檢定（等級法）	以等級取代原始值

3.2 程式判讀重點

核心必考

scipy 檢定的回傳型別

```

1 from scipy import stats
2 res = stats.ttest_ind(a, b) # -> 具名元組 (statistic, pvalue)
3 t, p = res # 可解包
4 print(p < 0.05) # 決策: True 表示拒絕 H0
5 stats.ks_2samp(x_train, x_live) # -> (statistic, pvalue); 漂移偵測

```

三個必考細節：(1) 回傳的是兩個值，第一個是檢定統計量、第二個才是 p 值，取錯順序即全錯；(2) `ttest_ind` 預設雙尾；(3) p value 小於 α 才拒絕 H_0 ，比較方向不可寫反。

3.3 常見陷阱與錯誤觀念

常見陷阱與錯誤觀念

- 把 p 值當成「 H_0 為真的機率」。條件方向完全相反。
- 說「接受 H_0 」。只能說「不拒絕」。
- 多重比較膨脹。同時做 20 個檢定，即使全無效果，平均也會有 1 個達到 $p < 0.05$ 。須以 Bonferroni (α/m) 或偽發現率校正。A / B 測試同時看 15 個指標正是此陷阱。
- 統計顯著 $\neq$ 實務顯著。樣本 100 萬時，轉換率 2.00% 對 2.01% 也會顯著，卻無商業價值。務必報告效果量與信賴區間。
- 偷看資料提前停止。每天看一次、一顯著就停，會嚴重膨脹偽陽性。應事先計算所需樣本量並跑滿。
- p 值大就宣稱「沒有效果」。可能只是樣本量不足、檢定力低。
- 看到資料後才改單尾。屬事後操弄。

3.4 政府指引與產業落地實務

政府指引與產業落地實務

文件	機關	日期	文件性質	本章意義
金融業運用人工智慧 (AI) 指引	金管會	113.06.20	行政規則／指引	公平性檢定與模型驗收之統計證據

統計推論在 AI 治理中的直接應用是**公平性檢定與模型驗收**：

- 金管會指引之公平性原則，實務落實方式即為對不同客群（性別、年齡層、地區）之核准率與誤判率進行**差異顯著性檢定**，並留存檢定結果作為稽核證據。此時**多重比較校正**尤為重要——同時比較數十個子群，未校正必然產生偽陽性警訊，反而稀釋治理效力。
- 模型上線前的 A / B 測試若涉及**直接影響客戶權益**（如核貸、保費定價），宜事先報請內部風控核准，並確保對照組客戶未因實驗而受不利待遇。
- 編者提醒**：評估報告中的統計證據應說明樣本代表性與檢定力，避免以低檢定力的「未達顯著」推論「無歧視」——這是「不拒絕 H_0 不等於接受 H_0 」在治理場景的直接後果。

3.5 正式公告試題索引

本章命題密度

兩場次正式公告試題（114 年第二次、115 年第一次）之 L22 科目共 100 題，其中對位至本代碼者 **7 題**，佔 **7%**。

本索引之 L 代碼為**編者對位**，非官方逐題分類；官方答案則照錄官方公告。

題目 ID	場次	官方答案	原卷頁次	含圖表	對位備註
OFFICIAL-114-2-L22-Q23	114-2	C	p.6	—	—
OFFICIAL-114-2-L22-Q38	114-2	B	p.10-11	是	—
OFFICIAL-115-1-L22-Q04	115-1	A	p.1-2	—	—
OFFICIAL-115-1-L22-Q06	115-1	D	p.2	—	—
OFFICIAL-115-1-L22-Q07	115-1	B	p.2	—	—
OFFICIAL-115-1-L22-Q08	115-1	D	p.2-3	是	須對照原卷圖表
OFFICIAL-115-1-L22-Q09	115-1	B	p.3	—	—

著作權處理與使用方式

官方試題為受著作權保護之著作。本書**不重製**官方題幹與選項全文，僅提供**題目 ID、場次、官方答案、原卷頁次與考綱對位**。

請依上表之**原卷頁次**，至 iPAS 官網「AI 應用規劃師 → 學習資源」下載該場次公告試題 PDF 對照閱讀；本章前述之核心概念、決策表與陷阱清單即為該批題目的考點拆解。

3.6 自編模擬題

模擬題 SIM-L22103-001 | **觀念題** | **難度：中級** | **對應 L22103**

某電商進行 A / B 測試，設定 $\alpha = 0.05$ 。結果顯示新版轉換率 3.42%、舊版 3.38%， p 值為 0.031，樣本數各 80 萬人。下列敘述何者最為正確？

- (A) $p = 0.031$ 表示新舊版無差異的機率為 3.1%
- (B) 結果達統計顯著，但效果量僅 0.04 個百分點，須另行評估實務顯著性與改版成本後再決策
- (C) 因 $p < 0.05$ ，可以接受對立假設並確認新版一定較優
- (D) 應將 α 調高至 0.10 以提高結論的可靠度

答案與逐項解析

答案：B

- (A) $\times$ p 值最經典的誤讀。它是「在 H_0 為真的前提下，觀察到此結果或更極端結果的機率」，而非「 H_0 為真的機率」。
- (B) $\checkmark$ **正解**。大樣本會使極小差異也達統計顯著，這正是「統計顯著不等於實務顯著」的教科書案例。0.04 個百分點是否值得改版工程與風險，須以商業角度評估。
- (C) $\times$ 兩處錯誤：統計檢定僅能「拒絕 H_0 」，不能宣稱「確認一定較優」；且單次實驗仍有型一錯誤可能。
- (D) $\times$ 調高 α 會增加型一錯誤機率，降低而非提高可靠度。

延伸考點：實驗前應以預期最小可偵測效果反推所需樣本量，而非先跑再看。報告應同時呈現點估計、95% 信賴區間與效果量，僅報 p 值是不完整的。

模擬題 SIM-L22103-002 | **方向題** | **難度：中級** | **對應 L22103**

某研究團隊原以 $\alpha = 0.05$ 進行檢定，為求結論更嚴謹而改用 $\alpha = 0.01$ ，其餘條件不變。下列敘述何者正確？

- (A) 型一錯誤機率降低，型二錯誤機率上升，檢定力下降
- (B) 型一與型二錯誤機率同時降低
- (C) 型一錯誤機率上升，型二錯誤機率下降
- (D) 兩類錯誤機率均不受影響，僅改變 p 值大小

答案與逐項解析

答案：A

- (A) $\checkmark$ **正解**。 α 就是型一錯誤的容忍上限，調低即降低偽陽性；但門檻變嚴會使真正存在的效果更難被偵測，型二錯誤 (β) 上升，檢定力 $1 - \beta$ 隨之下降。
- (B) $\times$ 在樣本量固定下，兩者是**此消彼長**。唯一能同時降低兩者的方法是**增加樣本量**。
- (C) $\times$ 方向完全相反。
- (D) $\times$ p 值由資料決定，不因 α 改變；改變的是**決策門檻**。

干擾項設計理由：(B) 利用「更嚴謹＝各方面都更好」的直覺；(D) 混淆 p 值與 α 的角色。

延伸考點：檢定力四因子——樣本量、效果量、 α 、資料變異。實務規劃實驗時，通常固定 $\alpha = 0.05$ 與目標檢定力 0.8，反推所需樣本量。

模擬題 SIM-L22103-003 | 情境題 | 難度：整合 | 對應 L22103

某銀行為驗證新版信用模型的公平性，同時對 25 個客群子群比較核准率差異，各以 $\alpha = 0.05$ 進行檢定，結果有 2 個子群達顯著。風控主管認為此結果不足以斷定存在歧視。下列理由何者最為適當？

- (A) 因為 p 值只要大於 0 就代表可能是巧合，任何顯著結果都不可信
- (B) 同時進行 25 次檢定會膨脹型一錯誤，即使全無差異，期望仍約有 1.25 個子群達顯著；應採 Bonferroni 或偽發現率校正後再判讀
- (C) 應改用單尾檢定，即可消除偽陽性
- (D) 子群數過多時應直接改看整體平均核准率，不必分群比較

答案與逐項解析

答案：B

- (A) × 敘述過度且錯誤； p 值的意義不是「大於 0 就不可信」。
- (B) ✓ **正解**。 $25 \times 0.05 = 1.25$ ，即在完全無差異的情況下，期望仍有約 1.25 個子群「達顯著」。觀察到 2 個並未明顯超出偶然範圍，須先做多重比較校正（如 Bonferroni 將門檻改為 $0.05/25 = 0.002$ ）再判讀。
- (C) × 單尾檢定會讓顯著更容易達成，反而增加偽陽性；且方向須事前決定。
- (D) × 只看整體平均正是公平性稽核最該避免的作法——整體良好而某子群顯著較差，正是彙總數字所掩蓋的問題。

干擾項設計理由：(D) 表面上「簡化問題」，實則違反公平性須分群檢視的核心原則。

延伸考點：多重比較校正是治理場景的必備動作，但校正過嚴也會漏掉真實的歧視。實務上常以偽發現率控制取代 Bonferroni，並輔以效果量（各群核准率的絕對差距）共同判斷。

模擬題 SIM-L22103-004 | 程式判讀 | 難度：中級 | 對應 L22103

執行下列程式後，關於輸出之敘述何者錯誤？

```
1 from scipy import stats
2 res = stats.ttest_ind(group_a, group_b)
3 print(res[0], res[1])
```

- (A) `res[0]` 為檢定統計量，`res[1]` 為 p 值
- (B) `ttest_ind` 預設進行雙尾檢定
- (C) 若 `res[1]` 為 0.002 且 $\alpha = 0.05$ ，應拒絕虛無假設
- (D) `res[0]` 為 p 值，其值越大代表兩組差異越顯著

答案與逐項解析

答案：D

- (A) ✓ 正確。回傳順序為 (statistic, pvalue)。
- (B) ✓ 正確。
- (C) ✓ 正確。 $0.002 < 0.05$ ，拒絕 H_0 。
- (D) × **錯誤（即為答案）**。兩處皆錯：`res[0]` 是檢定統計量而非 p 值；且 p 值越小才代表差異越顯著，方向寫反。

干擾項設計理由：(D) 同時包含索引錯置與方向錯置兩個高頻錯誤，是本題型的典型設計。

延伸考點：ttest_ind 預設假設兩組變異數相等；若不成立應設 equal_var=False (Welch 檢定)。另 ks_2samp 的回傳格式相同，常用於資料漂移偵測，與 L21302 的監控議題相通。

3.7 章末複習

3.7.1 一頁重點

主題	必記結論
p 值	H_0 為真時看到此結果或更極端的機率； 不是 H_0 為真的機率
決策用語	只能「拒絕」或「不拒絕」， 不能 「接受 H_0 」
兩類錯誤	調低 α ：型一降、型二升、檢定力降；同時降只能靠 增樣本
檢定力	樣本量、效果量、 α 、變異四因子
單雙尾	方向須 事前 決定
多重比較	m 次檢定的偽陽性期望約 $m\alpha$ ；須校正
顯著性	統計顯著 $\neq$ 實務顯著；務必報效果量
程式	(statistic, pvalue) 順序； $p < \alpha$ 才拒絕

3.7.2 必背名詞

虛無假設、對立假設、顯著水準 α 、 p 值、型一錯誤、型二錯誤、檢定力 (Power)、效果量 (Effect Size)、信賴區間、多重比較校正、無母數檢定。

3.7.3 五分鐘快速複習

1. 用一句話說出 p 值的正確定義，並指出兩種誤讀。
2. 說出調低 α 對兩類錯誤的相反影響。
3. 說出唯一能同時降低兩類錯誤的方法。
4. 計算做 20 次檢定時偽陽性的期望個數。
5. 說出為何不能講「接受 H_0 」。

3.7.4 跨章連結

Chapter 2：中央極限定理是檢定的理論基礎；Chapter 9：檢定結果的視覺化呈現與誤導；第 I 冊 L21203：公平性檢定與治理稽核。

來源與稽核紀錄

官方來源：IPAS-SCOPE-11502 (L22103 備註欄逐項列出 p 值判斷、Type I / II Error、顯著水準、單尾與雙尾)；IPAS-GUIDE-L22 (頁碼 **PENDING**)。

政府文件：GOV-FSC-AI (行政規則／指引)。查核日 中華民國 115 年 8 月 1 日。

編者推論／延伸：檢定選用表、程式判讀重點、公平性檢定之治理連結、四題模擬題與干擾項設計。

未解決資料缺口：學習指引頁碼；中級勘誤表完整條目。

Part II

L222 大數據處理技術

第 4 章

數據收集與清理

章節識別卡

官方代碼	L22201
官方名稱	數據收集與清理
官方備註	數據預處理、特徵提取
所屬	L22 / L222 大數據處理技術
授證路線	DATA_ANALYSIS
資料截止日	中華民國 115 年 8 月 1 日
對應來源	IPAS-SCOPE-11502、IPAS-GUIDE-L22（頁碼 PENDING ）
層級分布	核心必考 80% 官方補充 15% 政府實務 5% 產業延伸 0%
先備知識	pandas DataFrame 索引與切片
建議時數	2.5 小時
本版題數	模擬題 4 題（含程式判讀 2 題）

學習目標

1. 列舉資料品質六構面並設計自動檢核點。
2. 區分 MCAR、MAR、MNAR 三種缺失機制並選擇處置。
3. 比較 ETL 與 ELT 的適用情境。
4. 判讀 pandas 清理操作的列數變化與就地修改陷阱。

考綱對位

代碼	官方主題	本章節點	正式題	程式題	政府文件
L22201	數據收集與清理	資料品質六構面	見索引	無	—
L22201	同上	缺失機制與插補策略	見索引	有	—
L22201	同上	重複值、型別與一致性	見索引	有	—
L22201	同上	ETL 與 ELT	見索引	無	—
L22201	同上	特徵提取	見索引	無	GOV-PDPA

4.1 核心概念與技術原理

4.1.1 資料品質六構面

核心必考

構面	定義	自動檢核作法
完整性	該有的值是否都有	各欄缺失率門檻告警
正確性	是否符合真實	對照權威來源或業務規則
一致性	跨系統是否矛盾	交叉比對主檔與交易檔
時效性	是否夠新	最新資料時間戳與現在時間之落差
唯一性	是否重複	主鍵唯一性檢查
有效性	是否符合格式與值域	型別、範圍、正規表示式驗證

品質檢核應**自動化並納入管線**，於每次批次執行時產生報告，而非人工抽查。

4.1.2 三種缺失機制

核心必考

機制	定義	處置
MCAR 完全隨機缺失	缺失與任何變數皆無關	直接刪除仍不偏，但損失樣本
MAR 隨機缺失	缺失與 其他已觀測 變數有關	以模型插補（如以其他欄位預測）較佳
MNAR 非隨機缺失	缺失與 未觀測值本身 有關（高所得者不填所得）	最棘手 ；刪除或簡單插補均產生偏誤，須加「是否缺失」指示變數並謹慎解讀

缺失處理的實務判準

缺失率 < 5% 且近似 MCAR：可刪除或簡單插補。

缺失率 5%–40%：模型插補並**新增缺失指示欄**——缺失本身常帶有資訊（沒填手機號碼的客戶可能就是低黏著度客戶）。

缺失率 > 50%：多半刪除該欄位，或僅保留「是否有值」的二元特徵。

鐵律：插補的統計量必須**只從訓練集計算**，否則造成資料洩漏。

4.1.3 ETL 與 ELT

核心必考

	ETL（先轉換再載入）	ELT（先載入再轉換）
流程	擷取 → 轉換 → 載入	擷取 → 載入 → 轉換
適用	結構明確、需嚴格治理的資料倉儲	善用雲端彈性運算、保留原始資料以利回溯
優勢	進倉資料已清洗、品質可控	上線快、可重跑不同轉換邏輯
風險	轉換邏輯變更須重跑整條管線	治理不當易淪為資料沼澤

4.2 程式判讀重點

核心必考

清理操作的列數變化與就地修改

```
1 df.isna().sum() # -> Series (各欄缺失數)
2 df.dropna() # 預設 how='any': 任一欄為 NaN 即刪整列
3 df.dropna(subset=['a']) # 僅依 a 欄判斷
4 df.drop_duplicates() # 預設比對「所有欄位」，需整列相同才算重複
5 df.drop_duplicates(subset='id') # 依 id 去重
6 df = df.dropna(inplace=True) # 危險：inplace 回傳 None -> df 變成 None
```

三個必考細節：(1) `dropna()` 預設 `how='any'`，只要有一欄缺失就刪整列，殺傷力極大；(2) `drop_duplicates()` 預設比對全部欄位，只有整列完全相同才算重複，要依 `id` 去重須指定 `subset`；(3) `inplace=True` 就地修改並回傳 `None`，寫成 `df = df.xxx(inplace=True)` 會讓 `df` 變成 `None`。

4.3 常見陷阱與錯誤觀念

常見陷阱與錯誤觀念

- 以 0 填補數值型缺值。0 通常是合法值，模型會把「沒填」誤解為「數值為零」。
- 在切分前插補。統計量取自含測試集的全部資料，屬資料洩漏。
- 把 `dropna()` 當萬用。預設會因單一欄缺失而刪掉整列，可能一次砍掉七成資料。
- 把 MNAR 當 MCAR 處理。高所得者不填所得，刪除後樣本系統性偏低。
- 誤用 `inplace`。回傳 `None` 的經典錯誤。
- 只清理不記錄。清理決策（刪了哪些列、插補了什麼）必須留存，否則無法追溯。

4.4 政府指引與產業落地實務

政府指引與產業落地實務

文件	機關	日期	文件性質	本章意義
個人資料保護法	個資主管機關	現行有效	法律	蒐集之特定目的、安全維護義務
人工智慧基本法	立法院／國科會	114.12.23	法律	隱私保護與資料治理原則

一、在管線最前端就去識別化。最佳實務是在資料進入分析環境之前即完成遮罩或代碼化，使下游分析者永遠接觸不到原始識別資訊。此為《人工智慧基本法》「隱私保護與資料治理」原則所揭示之預設與設計精神的一種技術落實方式（編者整理之工程作法，非法條指定特定技術）。

二、蒐集目的須先確認。以某一特定目的蒐集的資料，若要用於訓練其他用途的模型，須檢視是否構成特定目的外利用而需另有法定事由或當事人同意。此判斷應在資料收集階段完成，而非清理完才發現不能用。

三、清理過程本身須可稽核。編者建議留存：資料版本、清理規則版本、各步驟前後筆數、刪除與插補的統計摘要。此為模型可重現性與問責原則的基礎。

4.5 正式公告試題索引

本章命題密度

兩場次正式公告試題（114 年第二次、115 年第一次）之 L22 科目共 100 題，其中對位至本代碼者 8 題，佔 8%。

本索引之 L 代碼為**編者對位**，非官方逐題分類；官方答案則照錄官方公告。

題目 ID	場次	官方答案	原卷頁次	含圖表	對位備註
OFFICIAL-114-2-L22-Q05	114-2	B	p.2	—	—
OFFICIAL-114-2-L22-Q06	114-2	C	p.2	—	—
OFFICIAL-114-2-L22-Q17	114-2	B	p.4-5	—	—
OFFICIAL-115-1-L22-Q11	115-1	C	p.3	—	—
OFFICIAL-115-1-L22-Q15	115-1	C	p.4	—	—
OFFICIAL-115-1-L22-Q17	115-1	D	p.5	—	—
OFFICIAL-115-1-L22-Q26	115-1	A	p.8	—	—
OFFICIAL-115-1-L22-Q39	115-1	C	p.12	是	信心 medium； 次代碼 L22203；須 對照原卷圖表

著作權處理與使用方式

官方試題為受著作權保護之著作。本書**不重製**官方題幹與選項全文，僅提供**題目 ID、場次、官方答案、原卷頁次與考綱對位**。

請依上表之**原卷頁次**，至 iPAS 官網「AI 應用規劃師 → 學習資源」下載該場次公告試題 PDF 對照閱讀；本章前述之核心概念、決策表與陷阱清單即為該批題目的考點拆解。

4.6 自編模擬題

模擬題 | SIM-L22201-001 | **程式判讀** | **難度：中級** | **對應 L22201**

df 有 1,000 列、5 欄。其中 age 欄有 40 筆 NaN、email 欄有 300 筆 NaN，其餘欄無缺失，且兩欄缺失位置不重疊。執行 `df2 = df.dropna()` 後，df2 的列數為何？

- (A) 1000
- (B) 960
- (C) 700
- (D) 660

答案與逐項解析

答案：D

`dropna()` 預設 `how='any'`：任一欄為 NaN 即刪除整列。

缺失位置不重疊，故受影響列數 = 40 + 300 = 340。1000 - 340 = 660。

- (A) × 未考慮刪除。
- (B) × 只算了 `age` 的 40 筆。
- (C) × 只算了 `email` 的 300 筆。
- (D) ✓ 正解。

干擾項設計理由：(B)(C) 針對「只想到自己關心的那一欄」的疏漏。

延伸考點：若缺失位置完全重疊，則僅刪 300 列，結果為 700。題幹是否說明重疊情形是關鍵資訊。若只想依 `age` 判斷應寫 `df.dropna(subset=['age'])`；若要「全部欄皆缺失才刪」則用 `how='all'`。本例 `email` 缺失率達 30%，實務上不應直接刪列，而應插補並新增缺失指示欄。

模擬題 SIM-L22201-002 | 程式判讀 | 難度：中級 | 對應 L22201

下列程式意圖「依 `customer_id` 去除重複客戶」，但結果不如預期。問題為何？

```
1 df_clean = df.drop_duplicates()
```

- (A) 沒有問題，`drop_duplicates()` 預設即依第一欄去重
- (B) `drop_duplicates()` 預設比對所有欄位，只有整列完全相同才算重複；同一客戶若其他欄位有任何差異就不會被去除，應指定 `subset='customer_id'`
- (C) 應改用 `df.dropna()`
- (D) 應加上 `inplace=True` 才會生效

答案與逐項解析

答案：B

- (A) × 預設不是依第一欄，而是比對全部欄位。
- (B) ✓ 正解。同一 `customer_id` 若在交易日期、金額等欄位有差異，整列就不相同，不會被視為重複。正確寫法為 `df.drop_duplicates(subset='customer_id', keep='first')`。
- (C) × `dropna()` 處理的是缺失值，與重複無關。
- (D) × `inplace` 只影響是否就地修改，不改變去重的比對邏輯；且本例已將結果指派給新變數，加 `inplace=True` 反而會讓 `df_clean` 變成 `None`。

干擾項設計理由：(D) 是實務上很常見的「加參數試試看」反應，正好踩中 `inplace` 回傳 `None` 的陷阱。

延伸考點：`keep` 參數可為 `'first'`（保留首筆）、`'last'`（保留末筆）、`False`（重複的全部刪除）。若要保留每位客戶最新一筆，須先 `sort_values` 再以 `keep='last'` 去重。

模擬題 SIM-L22201-003 | 情境題 | 難度：中級 | 對應 L22201

某問卷資料中，「月收入」欄位缺失率達 28%，且經分析發現高收入受訪者傾向不填此欄。下列處置何者最為適當？

- (A) 以全體平均收入填補缺失值，因平均數利用了全部可得資訊
- (B) 此屬 MNAR（缺失與未觀測值本身相關），簡單插補會系統性低估收入；應保留缺失指示欄、採

- 用適當的插補方法並於報告中揭露此偏誤風險
- (C) 直接刪除所有缺失列，即可得到乾淨資料
- (D) 以 0 填補，因為未填答代表沒有收入

答案與逐項解析

答案：B

- (A) × 以觀測到的平均填補，而觀測值本身已偏向中低收入，會使整體分布更向中低集中，偏誤加劇。
- (B) ✓ **正解。**「高收入者傾向不填」正是 MNAR 的定義——缺失與該欄未觀測到的值本身相關。此時任何僅依觀測值推估的方法都會低估，故須保留指示欄、選用適當方法並**明確揭露偏誤風險**。
- (C) × 刪除缺失列會直接移除高收入群體，樣本代表性嚴重受損。
- (D) × 「未填答」與「收入為 0」是完全不同的事，此填補會製造大量假的零收入樣本。

干擾項設計理由：(D) 是最常見的懶人作法，也是本章反覆強調的錯誤。

延伸考點：三種缺失機制的判別關鍵——與**任何變數**都無關為 MCAR；與**其他已觀測變數**有關為 MAR；與**該欄自身未觀測值**有關為 MNAR。MNAR 無法僅靠資料本身修正，須依賴領域知識或額外的抽樣設計。

模擬題 SIM-L22201-004 | **觀念題** | **難度：基礎** | **對應 L22201**

某企業建置雲端資料平台，希望先將各來源系統的原始資料完整落地保存，之後再依不同分析需求撰寫轉換邏輯，且允許重跑。此架構最接近下列何者？

- (A) ETL，因為資料最終仍會被轉換
- (B) ELT，先載入原始資料再於平台內轉換，保留原始資料以利回溯與多次重跑
- (C) 兩者皆非，此為串流處理架構
- (D) 兩者無實質差異，僅是名稱不同

答案與逐項解析

答案：B

- (A) × ETL 是在**載入前**完成轉換，進倉的已是清洗後資料，不保留原始樣態。
- (B) ✓ **正解。**「先完整落地、之後再依需求轉換、允許重跑」正是 ELT 的核心特徵，也是雲端資料湖與湖倉架構的典型作法。
- (C) × 題幹未提及連續事件流與低延遲需求。
- (D) × 轉換發生的**位置與時點**不同，直接影響治理方式、成本結構與可回溯性。

延伸考點：ELT 的代價是治理難度——原始資料若無中繼資料、無存取控制、無生命週期管理，資料湖會迅速退化為**資料沼澤**。此議題於 Chapter 5 完整處理。

4.7 章末複習

4.7.1 一頁重點

主題	必記結論
品質六構面	完整、正確、一致、時效、唯一、有效
缺失機制	MCAR 無關／MAR 與其他觀測值有關／MNAR 與自身未觀測值有關（最棘手）
缺失率門檻	< 5% 可刪；5–40% 插補＋指示欄；> 50% 刪欄
插補鐵律	統計量只能從訓練集計算
ETL ／ ELT	轉換在載入前／後；ELT 保留原始但須防資料沼澤
程式	dropna() 預設 any；drop_duplicates() 預設比對全欄；inplace 回傳 None

4.7.2 必背名詞

資料品質六構面、MCAR ／ MAR ／ MNAR、缺失指示欄、插補（Imputation）、ETL、ELT、資料沼澤（Data Swamp）、去識別化、資料血緣（Data Lineage）。

4.7.3 五分鐘快速複習

1. 說出三種缺失機制的判別關鍵。
2. 說出 dropna() 與 drop_duplicates() 的預設行為。
3. 說出為何插補統計量只能從訓練集計算。
4. 說出 ELT 相對 ETL 的優勢與風險。

4.7.4 跨章連結

Chapter 5：資料湖與治理；Chapter 6：大規模清理的執行環境；Chapter 7：清理後的轉換與縮放；Chapter 13：去識別化技術。

來源與稽核紀錄

官方來源：IPAS-SCOPE-11502（L22201 備註欄「數據預處理、特徵提取」）；IPAS-GUIDE-L22（頁碼 **PENDING**）。
 政府文件：GOV-PDPA（法律）、GOV-AI-BASIC-ACT（法律）。查核日 中華民國 115 年 8 月 1 日。
 編者推論／延伸：品質六構面檢核作法、缺失率門檻、程式判讀重點、四題模擬題與干擾項設計。
 未解決資料缺口：學習指引頁碼；中級勘誤表完整條目。

第 5 章

數據儲存與管理

章節識別卡

官方代碼	L22202
官方名稱	數據儲存與管理
官方備註	資料庫架構、儲存機制、模型訓練
所屬	L22 / L222 大數據處理技術
授證路線	DATA_ANALYSIS
資料截止日	中華民國 115 年 8 月 1 日
對應來源	IPAS-SCOPE-11502、IPAS-GUIDE-L22（頁碼 PENDING ）
層級分布	核心必考 75% 官方補充 15% 政府實務 5% 產業延伸 5%
先備知識	關聯式資料庫與 SQL 基本概念
建議時數	2.0 小時
本版題數	模擬題 4 題（含程式判讀 1 題）

學習目標

1. 比較資料倉儲、資料湖與湖倉一體的差異。
2. 區分 OLTP 與 OLAP，並說明列式與欄式儲存的取舍。
3. 選擇適合情境的 NoSQL 類型。
4. 說明 CAP 定理及其在實務上的取舍。

考綱對位

代碼	官方主題	本章節點	正式題	程式題	政府文件
L22202	數據儲存與管理	倉儲／湖／湖倉一體	見索引	無	—
L22202	同上	OLTP vs OLAP、列式 vs 欄式	見索引	有	—
L22202	同上	SQL 與 NoSQL 四型	見索引	無	—
L22202	同上	CAP 定理	見索引	無	—
L22202	同上	儲存與存取控制	見索引	無	GOV-PDPA GOV-CSMA

5.1 核心概念與技術原理

5.1.1 三種儲存架構

核心必考

	資料倉儲	資料湖	湖倉一體
資料型態	結構化為主	原始、任意格式	兩者兼容
寫入模式	Schema-on-Write	Schema-on-Read	開放表格式
主要用途	BI 報表、固定分析	探索分析、模型訓練	統一 BI 與 ML
風險	彈性低、變更成本高	治理不當淪為資料沼澤	架構複雜度較高

Schema-on-Write vs. Schema-on-Read

Schema-on-Write：寫入時就必須符合既定結構，不合格的資料進不來。優點是查詢時資料保證乾淨；缺點是新增欄位或改結構成本高。

Schema-on-Read：先原封不動存起來，讀取時才套用結構。優點是彈性極高、來得及保存原始樣態；缺點是資料品質問題被延後到查詢端，且若無中繼資料管理就沒人知道裡面有什麼。

5.1.2 OLTP 與 OLAP

核心必考

	OLTP（線上交易處理）	OLAP（線上分析處理）
典型操作	高頻小量讀寫、單筆查詢	大範圍掃描與彙總
儲存方式	列式	欄式
資料設計	正規化	星狀綱要（事實表＋維度表）
要求	ACID 交易一致性	查詢吞吐與壓縮率

為何分析型要用欄式儲存

分析查詢常是「掃描一億列但只用其中 3 個欄位」。列式儲存必須把整列讀進來才能取到那 3 欄；欄式只需讀取那 3 個欄位的資料塊，I/O 大幅減少。此外同一欄的資料型態與值域相近，壓縮率也遠優於列式。

反之，OLTP 常是「讀取或更新某一整筆訂單」，列式一次就能取得整列，效率較高。

5.1.3 NoSQL 四型與 CAP

核心必考

類型	資料模型	典型用途
鍵值	key → value	快取、工作階段狀態、計數器
文件	JSON 類文件	內容管理、商品目錄、結構常變的資料
欄族	依欄族分組的稀疏表	大規模時序或日誌寫入
圖	節點與邊	關係網路：詐欺共犯圈、供應鏈追溯、推薦關聯

CAP 定理：分散式系統在一致性（C）、可用性（A）、分區容忍性（P）三者中最多同時滿足兩項。

由於網路分區在分散式環境中無法避免，實務是在 P 必選的前提下於 C 與 A 之間取捨——金融交易偏 CP，社群動態偏 AP。

5.2 常見陷阱與錯誤觀念

常見陷阱與錯誤觀念

- 以為資料湖不需要治理。沒有中繼資料、存取控制與生命週期管理，資料湖會迅速變成資料沼澤。
- 把 OLAP 需求塞進 OLTP 資料庫。在正式交易庫上跑大範圍彙總查詢，會拖垮線上服務。
- 以為 CAP 可以三者兼得。在網路分區發生時，只能在一致性與可用性之間擇一。
- 以為 NoSQL 一定比 SQL 快。NoSQL 是以放寬某些保證換取特定場景的效能，並非全面較優；需要跨表交易一致性時關聯式資料庫仍是正解。
- 忽略欄式儲存不適合頻繁單列更新。欄式適合讀多寫少的分析場景。

5.3 政府指引與產業落地實務

政府指引與產業落地實務

文件	機關	日期	文件性質	本章意義
個人資料保護法	個資主管機關	現行有效	法律	安全維護義務、國際傳輸限制、保存期限
資通安全管理法	數位發展部	現行有效	法律	特定對象之資安責任等級與防護基準

一、**存取控制與最小權限**。資料湖若無列級或欄級權限控管，等同全公司可讀所有客戶資料。應以**資料分級**（公開／內部／機密／極機密）搭配角色權限，並定期複審。

二、**跨境傳輸**。使用境外雲端服務儲存或處理個資時，須確認是否符合個資法關於國際傳輸之規定與目的事業主管機關之限制；金融業另須納入委外管理（見金管會指引）。

三、**保存與刪除**。保存期限屆滿應可執行刪除，且須涵蓋**備份與衍生資料**。編者提醒：「模型已學進去的資料如何刪除」目前實務多以重新訓練因應，故架構設計時應預留可重訓的資料版本管理能力。

四、**資料血緣**。為滿足問責與可稽核性，應能回答「這份分析結果來自哪些來源表、經過哪些轉換」。此為模型文件與獨立稽核的基礎。

5.4 正式公告試題索引

本章命題密度

兩場次正式公告試題（114 年第二次、115 年第一次）之 L22 科目共 100 題，其中對位至本代碼者 8 題，佔 8%。

本索引之 L 代碼為**編者對位**，非官方逐題分類；官方答案則照錄官方公告。

題目 ID	場次	官方答案	原卷頁次	含圖表	對位備註
OFFICIAL-114-2-L22-Q07	114-2	C	p.2	—	—
OFFICIAL-114-2-L22-Q18	114-2	A	p.5	—	—
OFFICIAL-114-2-L22-Q34	114-2	B	p.9-10	—	—
OFFICIAL-114-2-L22-Q35	114-2	B	p.10	—	—
OFFICIAL-115-1-L22-Q13	115-1	B	p.4	—	—
OFFICIAL-115-1-L22-Q14	115-1	C	p.4	—	—
OFFICIAL-115-1-L22-Q31	115-1	B	p.9	—	—
OFFICIAL-115-1-L22-Q36	115-1	D	p.10-11	—	—

著作權處理與使用方式

官方試題為受著作權保護之著作。本書**不重製**官方題幹與選項全文，僅提供**題目 ID、場次、官方答案、原卷頁次與考綱對位**。

請依上表之**原卷頁次**，至 iPAS 官網「AI 應用規劃師 → 學習資源」下載該場次公告試題 PDF 對照閱讀；本章前述之核心概念、決策表與陷阱清單即為該批題目的考點拆解。

5.5 自編模擬題

模擬題 SIM-L22202-001 | **選型題** | **難度：中級** | **對應 L22202**

某電信商需分析三年份、每日數十億筆的通話明細，典型查詢為「依區域與月份彙總通話時長」，僅使用 50 個欄位中的 4 個。下列儲存設計何者最為適當？

- (A) 使用列式儲存的 OLTP 關聯式資料庫，並建立大量索引
- (B) 採用欄式儲存的分析型資料庫，並以星狀綱要組織事實表與維度表
- (C) 全部存入鍵值資料庫，以通話 ID 為 key
- (D) 存成大量小型 CSV 檔案，查詢時再逐一讀取

答案與逐項解析

答案：B

- (A) × 列式儲存必須讀取整列才能取得那 4 個欄位，在數十億筆規模下 I/O 成本極高；且 OLTP 資料庫的設計目標是交易一致性而非大範圍掃描。
- (B) ✓ **正解**。查詢型態是「大範圍掃描、少數欄位、彙總」，正是欄式儲存的最佳場景——只讀取需要的欄位、壓縮率高。星狀綱要則讓維度篩選（區域、月份）高效。
- (C) × 鍵值資料庫擅長依 key 單筆取值，無法有效支援跨區域與時間範圍的彙總查詢。
- (D) × 大量小檔案會造成嚴重的中繼資料負擔與 I/O 效率低落（小檔案問題），且無壓縮與述詞下推能力。

干擾項設計理由：(A) 利用「建索引就會快」的直覺，忽略了掃描型查詢與點查詢的本質差異。

延伸考點：欄式格式（如 Parquet 類）的兩項關鍵優勢為**欄位裁剪**與**述詞下推**，可在讀取階段就跳過不需要的資料塊。此與 Chapter 6 的 Spark 查詢優化直接相關。

模擬題 SIM-L22202-002 | 觀念題 | 難度：中級 | 對應 L22202

關於 CAP 定理之敘述，下列何者最為正確？

- (A) 分散式系統可以同時完全滿足一致性、可用性與分區容忍性
- (B) 由於網路分區無法避免，實務上是在保有分區容忍性的前提下，於一致性與可用性之間取捨
- (C) CAP 定理只適用於關聯式資料庫
- (D) 選擇可用性即代表系統永遠不會回傳錯誤資料

答案與逐項解析

答案：B

- (A) × CAP 定理明確指出三者最多同時滿足兩項。
- (B) ✓ **正解**。在真實網路中分區必然發生，因此 P 不是選項而是前提；真正的設計決策是分區發生時要「拒絕服務以保一致」(CP) 還是「先回應可能過時的資料」(AP)。
- (C) × CAP 是分散式系統的通則，與資料模型無關。
- (D) × 恰好相反——選擇可用性意味著在分區期間可能回傳**尚未同步的舊資料**。

干擾項設計理由：(D) 把「可用」誤解為「正確」，是本主題最常見的混淆。

延伸考點：金融轉帳偏 **CP**（寧可交易失敗也不能餘額不一致）；社群動態、商品瀏覽偏 **AP**（看到晚幾秒的資料無妨，但服務不能中斷）。命題常以業務情境要求判斷該偏哪一端。

模擬題 SIM-L22202-003 | 選型題 | 難度：中級 | 對應 L22202

某銀行欲建置系統，分析帳戶之間的轉帳網絡以找出可能的人頭帳戶集團，典型查詢為「找出與某帳戶在三層關係內相連的所有帳戶」。下列資料庫類型何者最為適當？

- (A) 鍵值資料庫
- (B) 欄族資料庫
- (C) 圖資料庫
- (D) 文件資料庫

答案與逐項解析

答案：C

- (A) × 鍵值只支援依 key 取值，無法表達與遍歷關係。
- (B) × 欄族擅長大量寫入與依列鍵查詢，不擅長多層關聯遍歷。
- (C) ✓ **正解**。「三層關係內相連」是典型的多跳圖遍歷。在關聯式資料庫中這需要三次自我聯結，成本隨層數指數上升；圖資料庫以節點與邊原生表達關係，遍歷效率高。
- (D) × 文件資料庫適合結構常變的獨立文件，跨文件關聯查詢並非其強項。

延伸考點：圖分析在金融犯罪防制的典型應用包括**社群偵測**（找出緊密相連的帳戶群）與**中心性分析**（找出集團中的關鍵節點）。此議題於 Chapter 8 有進一步處理。

模擬題 SIM-L22202-004 | 程式判讀 | 難度：基礎 | 對應 L22202

關於下列讀檔程式之敘述，何者錯誤？

```
1 df = pd.read_csv('log.csv', usecols=['ts', 'region', 'duration'], dtype={'region': 'category'})
2 print(df.dtypes)
3 print(df.memory_usage(deep=True).sum())
```

- (A) usecols 只讀取指定欄位，可顯著降低記憶體用量
- (B) 將 region 指定為 category 型別，在重複值多時可大幅節省記憶體
- (C) df.dtypes 回傳 Series，列出各欄型別
- (D) ts 欄會被自動解析為日期時間型別，無須額外指定

答案與逐項解析

答案：D

- (A) ✓ 正確，這是欄位裁剪概念在單機讀檔上的體現。
 - (B) ✓ 正確。category 以整數編碼加對照表儲存，重複值多時記憶體大幅下降。
 - (C) ✓ 正確。
 - (D) × 錯誤（即為答案）。read_csv 不會自動把字串欄解析為日期時間，預設會讀成 object 字串。須明確指定 parse_dates=['ts']，否則後續的時間運算與排序都會以字串處理而產生錯誤結果。
- 干擾項設計理由：(D) 利用「欄名叫 ts 應該會被認出來」的期待，這是實務上極常見的疏漏。
- 延伸考點：字串型日期的排序是字典序，在格式為 YYYY-MM-DD 時碰巧與時間序一致，但格式若為 M/D/YYYY 就會完全錯亂。這也是資料品質六構面中「有效性」的檢核重點。

5.6 章末複習

5.6.1 一頁重點

主題	必記結論
三種架構	倉儲 Schema-on-Write / 湖 Schema-on-Read / 湖倉一體
OLTP vs OLAP	交易用列式正規化；分析用欄式星狀綱要
欄式優勢	欄位裁剪＋高壓縮率；不適合頻繁單列更新
NoSQL 四型	鍵值／文件／欄族／圖（關係網路）
CAP	P 是前提，取捨在 C 與 A；金融偏 CP、社群偏 AP
治理	資料分級＋最小權限；跨境傳輸；保存與刪除須含備份

5.6.2 必背名詞

資料倉儲、資料湖、湖倉一體、Schema-on-Write / Read、OLTP、OLAP、列式與欄式儲存、星狀綱要、CAP 定理、資料沼澤、資料血緣。

5.6.3 五分鐘快速複習

- 說出欄式儲存為何適合分析型查詢。
- 說出 CAP 中哪一項在實務上是前提而非選項。
- 給定「找出三層關係內的相連帳戶」，說出應選哪種資料庫。
- 說出資料湖退化為資料沼澤的三個原因。

5.6.4 跨章連結

Chapter 4：ETL ／ ELT 與資料落地；Chapter 6：分散式運算引擎；Chapter 13：儲存層的隱私與合規；第 I 冊 L21302：雲端環境建置與委外。

來源與稽核紀錄

官方來源：IPAS-SCOPE-11502（L22202 備註欄「資料庫架構、儲存機制、模型訓練」）；IPAS-GUIDE-L22（頁碼 **PENDING**）。

政府文件：GOV-PDPA（法律）、GOV-CSMA（法律）。查核日 中華民國 115 年 8 月 1 日。

編者推論／延伸：三架構對照、欄式優勢說明、NoSQL 選型表、四題模擬題與干擾項設計。具體產品名稱已避免列舉，僅保留架構概念。

未解決資料缺口：學習指引頁碼；中級勘誤表完整條目。

第 6 章

數據處理技術與工具

章節識別卡

官方代碼	L22203
官方名稱	數據處理技術與工具
官方備註	Apache Spark、Hadoop、Kafka、批次 vs 串流處理
所屬	L22 / L222 大數據處理技術
授證路線	DATA_ANALYSIS
資料截止日	中華民國 115 年 8 月 1 日
對應來源	IPAS-SCOPE-11502、IPAS-GUIDE-L22（頁碼 PENDING ）
層級分布	核心必考 70% 官方補充 20% 政府實務 0% 產業延伸 10%
先備知識	Chapter 4、Chapter 5；分散式系統基本概念
建議時數	3.5 小時
本版題數	模擬題 7 題（含程式判讀 3 題）
備註	L22 命題密度最高之單一章節 ，官方備註欄逐項點名工具

學習目標

1. 比較批次處理與串流處理的適用情境與關鍵指標。
2. 說明 Hadoop MapReduce 與 Spark 的效能差異來源。
3. 判斷 Spark 操作屬 Transformation 或 Action，並預測運算何時真正發生。
4. 辨識會觸發 Shuffle 的操作，並診斷資料傾斜。
5. 說明 Kafka 在資料架構中的解耦與緩衝角色。
6. 區分事件時間與處理時間，並選擇適當的視窗型態。

考綱對位

代碼	官方主題	本章節點	正式題	程式題	政府文件
L22203	數據處理技術與工具	批次 vs 串流處理	見索引	無	—
L22203	同上	Hadoop MapReduce 與 HDFS	見索引	無	—
L22203	同上	Spark 惰性求值與 DAG	見索引	有	—
L22203	同上	Transformation vs Action	見索引	有	—
L22203	同上	Shuffle 與資料傾斜	見索引	有	—
L22203	同上	Kafka 與事件串流	見索引	無	—

代碼	官方主題	本章節點	正式題	程式題	政府文件
L22203	同上	事件時間、水位線與視窗	見索引	無	—

6.1 核心概念與技術原理

6.1.1 批次與串流

核心必考

	批次處理	串流處理
處理單位	有界資料集（一天、一個月）	無界的連續事件流
延遲	分鐘至小時	毫秒至秒
典型引擎	分散式批次運算框架	事件串流平台＋串流運算引擎
適用	月結報表、大規模模型訓練、歷史回溯	即時風控、物聯網告警、動態定價
關鍵指標	吞吐量、完成時間	端到端延遲、背壓處理

選型訊號

「每日凌晨統一計算」「重跑歷史三年資料」→ **批次**。

「交易發生當下就要判定」「感測器持續送出讀值」→ **串流**。

微批次（micro-batch）是折衷：把串流切成很短的批次處理，延遲通常在秒級，兼顧吞吐與實作簡易度。

6.1.2 Hadoop 與 Spark 的關鍵差異

核心必考

Hadoop MapReduce 每一階段的中間結果都要寫回磁碟（HDFS），而機器學習與圖演算法需要反覆掃描同一份資料，每次迭代都付出一次磁碟往返成本，因此極慢。

Spark 以記憶體中的分散式資料集進行運算，中間結果可保留在記憶體，迭代式任務可快上一至兩個數量級。

元件	角色	備註
HDFS	分散式檔案系統，資料分塊並多副本存放	提供容錯與高吞吐循序讀取
YARN	叢集資源排程	分配容器與記憶體
MapReduce	批次運算模型	中間結果落磁碟
Spark	記憶體運算引擎	可讀取 HDFS，取代 MapReduce 作為運算層

常見陷阱與錯誤觀念

常見誤述：「Spark 取代了 Hadoop」。正確理解是 **Spark 取代的是 MapReduce 這個運算層**，仍常搭配 HDFS 或物件儲存作為儲存層、YARN 或其他排程器作為資源層。

6.1.3 Spark 的三個必考特性**核心必考****6.1.3.1 一、惰性求值與 DAG**

filter、select、map、withColumn、join 等**轉換**（Transformation）不會立即執行，只建立執行計畫（有向無環圖）；直到遇到**行動**（Action）才真正計算。

此設計讓查詢優化器能重排、合併與下推運算——例如把 filter 推到讀取階段，直接少讀資料。

6.1.3.2 二、Transformation 與 Action 的分辨

Transformation（不執行）	Action（觸發執行）	易混淆者
select、filter、where	count()	df.count() 是 Action ，回傳整數
withColumn、drop	collect()	groupBy(...).count() 是 Transformation ，回傳 DataFrame
groupBy、agg、join	show()、take()	兩者名稱都有 count，作用完全不同
orderBy、distinct	write、foreach	write 本身即為 Action

本章第一名考點

df.count()→**Action**，立刻運算並回傳一個整數。
df.groupBy("region").count()→**Transformation**，回傳一個新的 DataFrame，什麼都還沒算。
這組對比在程式判讀題中出現頻率極高。

6.1.3.3 三、Shuffle 與資料傾斜

Shuffle 指跨節點的資料重分配。觸發者包括 groupBy、join、distinct、repartition、orderBy。它牽涉磁碟寫入與網路傳輸，是分散式作業中**最昂貴的操作**。

資料傾斜（Data Skew）指某一個 key 的資料量遠大於其他，導致單一 task 拖垮全局——其他 99 個 task 都完成了，就等那一個。

優化手段	作法	適用
減少 Shuffle	調整運算順序、先過濾再聚合	通用
廣播 join	將 小表 複製到各節點，避免大表重分配	大表 join 小維度表

優化手段	作法	適用
加鹽 (salting)	在傾斜 key 後加隨機後綴分散，單一 key 極端集中聚合後再合併	
預先分桶	依 join key 事先分桶儲存	反覆以同一 key 聯結

6.1.4 Kafka 與事件串流

核心必考

Kafka 是分散式事件串流平台，以主題 (Topic) 與分區 (Partition) 組織訊息，提供高吞吐、持久化與重放能力。

在資料架構中的三個核心價值：

1. **解耦**生產者（物聯網裝置、應用系統）與消費者（特徵計算、模型推論、資料湖寫入）——雙方不需彼此知道存在。
2. **緩衝**——下游故障或流量尖峰時，訊息仍保留在 Kafka 中不遺失。
3. **重放**——新的消費者可從頭讀取歷史訊息，便於補算或新增下游應用。

分區決定並行度與順序保證：Kafka 只保證**同一分區內**的訊息順序，跨分區無全域順序。若某類事件必須依序處理（如同一帳戶的交易），應以該帳戶 ID 作為分區鍵。

6.1.5 時間語意與視窗

核心必考

串流處理必須區分：

- **事件時間** (Event Time)：事件**實際發生**的時間（裝置產生讀值的時刻）。
- **處理時間** (Processing Time)：系統**收到**的時間。

網路延遲與離線緩衝會使事件亂序到達。正確的統計必須依**事件時間**，並設定**水位線** (Watermark)，容許一定程度的遲到資料——水位線越寬容，結果越正確但延遲越高。

視窗型態	定義	典型用途
滾動視窗	固定長度、 不重疊	每 5 分鐘的交易總額
滑動視窗	固定長度、 重疊	每 1 分鐘更新一次「過去 5 分鐘」的移動平均
會話視窗	依 活動間隔 切分，長度不固定	使用者一次瀏覽工作階段

產業延伸（非官方核心考點）

特定產品之組態參數（如分區數調校、消費者群組再平衡策略、串流引擎的檢查點設定、各家雲端託管服務比較）屬**產業延伸**。官方備註欄僅點名工具名稱與批次／串流概念，不需記憶產品參數。

版本敏感

6.2 程式判讀重點

核心必考

惰性求值：哪一行才真正運算

```
1 df2 = df.filter(df.status == "OK") # Transformation：不執行
2 df3 = df2.groupBy("region").count() # Transformation：不執行
3 df3.write.parquet("/out/result") # Action：此時才真正計算
```

判讀重點：前兩行執行後不會有任何資料被讀取，即使 `df` 有一兆列也是瞬間完成。第三行觸發整條 DAG，且 `groupBy` 會產生 **Shuffle**。

count 的兩種身分

```
1 n = df.count() # Action -> int
2 g = df.groupBy("city").count() # Transformation -> DataFrame
3 g.show() # Action -> 此時才運算
```

collect 的記憶體風險與正確除錯方式

```
1 rows = df.collect() # 危險：把「全部」資料拉回 driver，大表直接記憶體溢出
2 df.show(20) # 正確：只取前 20 列
3 df.limit(100).toPandas()
```

6.3 常見陷阱與錯誤觀念

常見陷阱與錯誤觀念

- 把 `groupBy(...).count()` 當成 **Action**。它回傳 `DataFrame`，是 **Transformation**。
- 以為 `filter` 執行後資料就被過濾了。惰性求值下什麼都還沒發生。
- 對大表呼叫 `collect()`。driver 記憶體溢出的頭號原因。
- 說「Spark 取代 Hadoop」。取代的是 MapReduce 運算層。
- 忽略 **Shuffle 成本**。在 `join` 前先過濾與投影，可大幅減少搬移的資料量。
- 以處理時間做視窗統計。事件亂序時結果會錯，且無法重現。
- 以為 **Kafka 保證全域順序**。只保證同一分區內有序。
- 把資料傾斜當成叢集資源不足。加機器無效，須從 `key` 分布著手。

6.4 正式公告試題索引

本章命題密度

兩場次正式公告試題（114 年第二次、115 年第一次）之 L22 科目共 100 題，其中對位至本代碼者 **20 題**，佔 **20%**。

本索引之 L 代碼為**編者對位**，非官方逐題分類；官方答案則照錄官方公告。

題目 ID	場次	官方答案	原卷頁次	含圖表	對位備註
OFFICIAL-114-2-L22-Q11	114-2	C	p.3	—	—
OFFICIAL-114-2-L22-Q19	114-2	C	p.5	—	—
OFFICIAL-114-2-L22-Q40	114-2	B	p.11-12	是	須對照原卷圖表
OFFICIAL-114-2-L22-Q41	114-2	A	p.12	—	須對照原卷圖表
OFFICIAL-114-2-L22-Q42	114-2	C	p.12-13	是	須對照原卷圖表
OFFICIAL-114-2-L22-Q43	114-2	B	p.14	是	—
OFFICIAL-114-2-L22-Q44	114-2	D	p.14	—	—
OFFICIAL-114-2-L22-Q45	114-2	A	p.14-15	—	—
OFFICIAL-114-2-L22-Q46	114-2	C	p.15	—	—
OFFICIAL-114-2-L22-Q47	114-2	B	p.15	—	須對照原卷圖表
OFFICIAL-114-2-L22-Q49	114-2	C	p.16-17	—	須對照原卷圖表
OFFICIAL-114-2-L22-Q50	114-2	B	p.17	是	須對照原卷圖表
OFFICIAL-115-1-L22-Q12	115-1	C	p.3-4	—	—
OFFICIAL-115-1-L22-Q21	115-1	D	p.6-7	—	—
OFFICIAL-115-1-L22-Q41	115-1	B	p.13-14	是	須對照原卷圖表
OFFICIAL-115-1-L22-Q45	115-1	C	p.15	—	—
OFFICIAL-115-1-L22-Q46	115-1	A	p.15	—	—
OFFICIAL-115-1-L22-Q47	115-1	C	p.15-16	—	—
OFFICIAL-115-1-L22-Q48	115-1	C	p.16	是	須對照原卷圖表
OFFICIAL-115-1-L22-Q49	115-1	B	p.16-17	是	須對照原卷圖表

著作權處理與使用方式

官方試題為受著作權保護之著作。本書不重製官方題幹與選項全文，僅提供題目 ID、場次、官方答案、原卷頁次與考綱對位。

請依上表之原卷頁次，至 iPAS 官網「AI 應用規劃師 → 學習資源」下載該場次公告試題 PDF 對照閱讀；本章前述之核心概念、決策表與陷阱清單即為該批題目的考點拆解。

6.5 自編模擬題

模擬題 SIM-L22203-001 | 程式判讀 | 難度：中級 | 對應 L22203

執行下列 PySpark 程式後，關於其行為之敘述何者正確？

```
1 df2 = df.filter(df.status == "OK")
2 df3 = df2.groupBy("region").count()
3 df3.write.parquet("/out/result")
```

- (A) 第一行執行時即完成全表掃描並產生中間結果集
- (B) 前兩行僅建構執行計畫不觸發運算，直到第三行的寫出動作才實際執行，且 groupBy 會觸發 Shuffle
- (C) groupBy 屬於 Action，故第二行即觸發完整運算
- (D) 三行皆為 Transformation，須另行呼叫 collect() 才會執行

答案與逐項解析

答案：B

- (A) × filter 為 Transformation，採惰性求值，不會立即掃描。
- (B) ✓ 正解。filter 與 groupBy 皆為 Transformation，Spark 僅記錄血緣關係建構 DAG；write 為 Action，此時優化器才產生實體執行計畫並實際運算。同時 groupBy 需將相同 region 的資料匯聚至同一節點，必然觸發 Shuffle，為此段程式的效能瓶頸。
- (C) × groupBy 回傳 GroupedData，接 count() 後仍是 DataFrame 轉換，不是 Action。務必區分 df.count()（Action，回傳整數）與 groupBy(...).count()（Transformation，回傳 DataFrame）。
- (D) × write 本身即為 Action；且對大表呼叫 collect() 會使 driver 記憶體溢出。

延伸考點：常見 Action：count()、collect()、show()、take()、write、foreach。常見 Shuffle 觸發者：groupBy、join、distinct、repartition、orderBy。

模擬題 SIM-L22203-002 | 診斷題 | 難度：整合 | 對應 L22203

某 Spark 作業共 200 個 task，其中 199 個在 3 分鐘內完成，剩下 1 個執行超過 40 分鐘。經查該作業以 customer_id 進行 groupBy，而某一個匿名帳戶 ID 佔全部資料的 35%。下列處置何者最為適當？

- (A) 增加叢集節點數量，讓運算資源更充裕
- (B) 此為資料傾斜；應對傾斜 key 加鹽分散後再聚合合併，或改以廣播 join 等方式避免單一 key 集中
- (C) 將 groupBy 改為 orderBy 即可避免
- (D) 對該 DataFrame 呼叫 collect() 後在 driver 端單機處理

答案與逐項解析

答案：B

- (A) × 資料傾斜的瓶頸是單一 task，加機器不會讓那一個 task 變快，其他節點只會閒置。這是最常見的錯誤處置。
- (B) ✓ 正解。典型資料傾斜。加鹽是在傾斜 key 後附加隨機後綴，把一個超大分組拆成多個小分組先各自聚合，最後再合併結果。

(C) × orderBy 同樣觸發 Shuffle，且無助於分散單一 key 的資料量，反而可能更慢。

(D) × 佔 35% 的資料量拉回 driver 幾乎必然記憶體溢出，且失去分散式運算的意義。

干擾項設計理由：(A) 是直覺反應——「慢就加機器」，但完全無效，屬本題最具鑑別力的誘答。

延伸考點：實務上「匿名帳戶」「未知」「其他」這類預設值最容易造成傾斜。除加鹽外，也可先將該 key 單獨抽出處理再與其餘結果聯集。診斷方法是查看各 key 的資料筆數分布。

模擬題 SIM-L22203-003 | **選型題** | **難度：中級** | **對應 L22203**

某支付平台需在交易發生的 500 毫秒內完成風險判定並決定是否放行，交易事件由前端系統持續產生。下列架構何者最為適當？

- (A) 每日凌晨以批次作業重算所有交易的風險分數
- (B) 以事件串流平台承接交易事件，搭配串流運算引擎即時計算特徵並呼叫模型判定
- (C) 將交易寫入資料倉儲後，由 BI 工具每小時產生風險報表
- (D) 以 MapReduce 逐筆處理每一筆交易

答案與逐項解析

答案：B

(A) × 每日批次的延遲以小時計，交易早已完成，無法達成「放行前判定」的目的。

(B) ✓ **正解**。題幹的兩項限制——**連續產生的事件與 500 毫秒延遲**——正是串流處理的定義場景。串流平台同時提供解耦與緩衝，下游模型服務短暫不可用時訊息不會遺失。

(C) × 每小時報表屬事後分析，與即時攔截無關。

(D) × MapReduce 的中間結果落磁碟、啟動開銷大，是為高吞吐批次設計，不適合毫秒級延遲。

延伸考點：此架構仍需批次管線並行——串流負責**即時判定**，批次負責**模型重訓與歷史回溯**。兩者並存的設計在實務上很常見，關鍵是確保兩邊的特徵計算邏輯一致，否則會產生訓練與服務偏斜（見第 I 冊 L21302）。

模擬題 SIM-L22203-004 | **觀念題（反向）** | **難度：中級** | **對應 L22203**

關於 Hadoop 與 Spark 之敘述，下列何者**錯誤**？

- (A) MapReduce 每階段中間結果寫回磁碟，故迭代式運算效率低
- (B) Spark 可將中間結果保留於記憶體，迭代任務效能顯著較佳
- (C) Spark 完全取代了 Hadoop，包含其分散式檔案系統與資源排程功能
- (D) Spark 可讀取 HDFS 上的資料，兩者常搭配使用

答案與逐項解析

答案：C

(A) ✓ 正確，這正是機器學習類工作負載在 MapReduce 上極慢的原因。

(B) ✓ 正確。

(C) × **錯誤（即為答案）**。Spark 取代的是 **MapReduce 這個運算層**，並未取代 HDFS（儲存層）或 YARN（資源排程層）。實務上 Spark 常搭配 HDFS 或物件儲存使用。

(D) ✓ 正確。

干擾項設計理由：(C) 利用「新技術取代舊技術」的籠統印象，忽略了 Hadoop 是一個**生態系**而非單一元件。

延伸考點：Hadoop 生態的三層分工——HDFS（儲存）、YARN（資源）、MapReduce（運算）。現代架構常見組合為「物件儲存 + Kubernetes + Spark」，三層皆可替換。

模擬題 SIM-L22203-005 | **程式判讀** | **難度：中級** | **對應 L22203**

下列程式意圖檢視資料，但在 5 億列的 DataFrame 上執行後導致程式崩潰。原因與修正為何？

```
1 rows = df.collect()
2 print(rows[:10])
```

- (A) collect() 語法錯誤，應改為 collect(10)
- (B) collect() 會把全部資料拉回 driver 節點，5 億列造成記憶體溢出；應改用 df.show(10) 或 df.limit(10).collect()
- (C) 應增加 executor 記憶體即可解決，程式寫法無誤
- (D) 因為 collect() 是 Transformation，須再加一個 Action 才會執行

答案與逐項解析

答案：B

- (A) × collect() 不接受筆數參數；限制筆數應用 take(n) 或先 limit(n)。
- (B) ✓ **正解。**collect() 是 Action，且會將所有分區的資料匯集到單一 driver 節點的記憶體中。切片 [:10] 發生在資料已全部拉回之後，完全來不及避免溢出。
- (C) × 崩潰的是 driver 而非 executor；且即使加大 driver 記憶體，把 5 億列放進單機仍不可行。
- (D) × collect() 是 Action，不是 Transformation。

干擾項設計理由：(C) 針對「記憶體不足就加記憶體」的直覺，忽略了問題出在架構層面的取用方式。

延伸考點：除錯時的正確取樣方式：df.show(n)（直接印出，不回傳）、df.take(n)（回傳前 n 列的清單）、df.limit(n).toPandas()（轉為本機表格）。三者都先在叢集端限制筆數。

模擬題 SIM-L22203-006 | **觀念題** | **難度：中級** | **對應 L22203**

某物聯網系統的感測器因網路不穩，讀值常延遲 30 至 90 秒才送達平台。若要正確計算「每 5 分鐘的平均溫度」，下列設計何者最為適當？

- (A) 以處理時間分視窗，因為系統收到的時間最準確
- (B) 以事件時間分視窗，並設定適當的水位線容許遲到資料，再輸出該視窗結果
- (C) 直接丟棄所有延遲超過 10 秒的讀值
- (D) 改用會話視窗，因其長度不固定可自動吸收延遲

答案與逐項解析

答案：B

- (A) × 以處理時間分窗，會把「10:04 產生但 10:06 才到」的讀值算進 10:05–10:10 這個視窗，統計結果錯誤且**無法重現**——重跑一次因網路狀況不同會得到不同答案。
- (B) ✓ **正解。**依**事件時間**（讀值產生時刻）分窗才符合物理意義；水位線用來宣告「事件時間早於此的資料視為已到齊」，在正確性與延遲之間取得平衡。本例延遲可達 90 秒，水位線應設得比 90 秒更寬鬆一些。

- (C) × 直接丟棄會系統性遺失網路較差區域的感測器資料，造成選擇偏誤。
- (D) × 會話視窗依活動間隔切分，用於使用者工作階段這類場景；本題要的是固定的 5 分鐘統計，應用滾動視窗。

干擾項設計理由：(A) 是實作上最省事的作法，也是實務中最常見的錯誤設計。

延伸考點：水位線的取舍——設得越寬鬆，遲到資料涵蓋越完整但結果輸出越晚；設得越緊，延遲低但可能漏算。此外還須決定遲到資料抵達後是丟棄、更新已輸出結果，還是送入側輸出另行處理。

模擬題 SIM-L22203-007 | **觀念題** | **難度：中級** | **對應 L22203**

某公司以 Kafka 承接各系統事件。工程師發現同一帳戶的兩筆交易被下游以錯誤順序處理。最可能的原因與修正為何？

- (A) Kafka 不保證任何順序，此問題無法解決
- (B) Kafka 僅保證同一分區內的順序；該帳戶的訊息被分散到不同分區，應以帳戶 ID 作為分區鍵使其進入同一分區
- (C) 應減少消費者數量至 1，才能保證順序
- (D) 應改用批次處理，因串流本質上無法保證順序

答案與逐項解析

答案：B

- (A) × Kafka 提供分區內的順序保證，並非完全無序。
- (B) ✓ **正解。**Kafka 的順序保證範圍是**分區**。若未指定分區鍵，訊息會被輪流分派到不同分區，同一帳戶的訊息因而可能被不同消費者以不同速度處理。以帳戶 ID 為分區鍵可確保同一帳戶的所有訊息落在同一分區，依序處理。
- (C) × 把消費者減為 1 雖能緩解，但會犧牲全部並行度與吞吐量，是以效能換正確性的下策；且若訊息本就分散在分區，單一消費者跨分區讀取仍無全域順序保證。
- (D) × 順序問題與批次或串流無關，而是分區設計問題。

延伸考點：分區鍵的選擇是**順序保證與負載平衡**的權衡——以帳戶 ID 分區可保證順序，但若某大戶交易量極高，會造成分區間的資料傾斜，與 Spark 的傾斜問題同源。

6.6 章末複習

6.6.1 一頁重點

主題	必記結論
批次 vs 串流	有界／無界；分鐘小時級／毫秒秒級
Hadoop vs Spark	MapReduce 中間結果落磁碟；Spark 記憶體運算；Spark 取代的是運算層
惰性求值	Transformation 只建 DAG，Action 才運算
最高頻考點	df.count() 是 Action；groupBy(...).count() 是 Transformation
Shuffle	groupBy / join / distinct / repartition / orderBy 觸發
資料傾斜	單一 key 過大拖垮單一 task； 加機器無效 ，須加鹽或廣播 join

主題	必記結論
collect	拉回全部資料至 driver，大表必爆；改用 show / take / limit
Kafka	解耦、緩衝、重放； 僅保證分區內順序
時間語意	依 事件時間 分窗＋水位線；滾動／滑動／會話三種視窗

6.6.2 必背名詞

HDFS、MapReduce、YARN、惰性求值（Lazy Evaluation）、DAG、Transformation、Action、Shuffle、資料傾斜（Data Skew）、加鹽（Salting）、廣播 join、Topic、Partition、事件時間、處理時間、水位線（Watermark）、滾動／滑動／會話視窗。

6.6.3 五分鐘快速複習

1. 列出五個 Action 與五個 Transformation，並說出 count 的兩種身分。
2. 說出哪些操作會觸發 Shuffle。
3. 說出資料傾斜為何加機器無效，以及正確的三種處置。
4. 說出 Kafka 的順序保證範圍。
5. 說出事件時間與處理時間的差異，以及水位線的作用。

6.6.4 跨章連結

Chapter 5：儲存格式與欄式優化；Chapter 7：大規模轉換與縮放；Chapter 10：分散式訓練；第 I 冊 L21302：串流推論與訓練服務偏斜。

來源與稽核紀錄

官方來源：IPAS-SCOPE-11502（L22203 備註欄逐項點名 Apache Spark、Hadoop、Kafka、批次 vs 串流處理）；IPAS-GUIDE-L22（頁碼 **PENDING**）。

層級判定：產品組態參數與雲端託管服務比較列為 **產業延伸**，已於 industrybox 隔離。

編者推論／延伸：選型訊號、Transformation/Action 對照表、傾斜優化表、程式判讀三則、七題模擬題與干擾項設計。

未解決資料缺口：學習指引頁碼；中級勘誤表完整條目。

Part III

L223 大數據分析方法與工具

第 7 章

統計學在大數據中的應用

章節識別卡

官方代碼	L22301
官方名稱	統計學在大數據中的應用
官方備註	數據轉換、縮放與分佈調整、特徵工程
所屬	L22 / L223 大數據分析方法與工具
授證路線	DATA_ANALYSIS
資料截止日	中華民國 115 年 8 月 1 日
對應來源	IPAS-SCOPE-11502、IPAS-GUIDE-L22（頁碼 PENDING ）
層級分布	核心必考 80% 官方補充 15% 政府實務 5% 產業延伸 0%
先備知識	Chapter 1；線性代數基礎（PCA 需要）
建議時數	2.5 小時
本版題數	模擬題 5 題（含程式判讀 2 題）

學習目標

1. 選擇適合資料特性的縮放與轉換方法。
2. 判斷哪些方法對離群值敏感。
3. 說明 PCA 的流程、前置要求與解釋變異比例的判讀。
4. 區分 PCA 與 t-SNE 的用途邊界。
5. 判讀 scikit-learn 轉換器的 fit / transform 語意。

考綱對位

代碼	官方主題	本章節點	正式題	程式題	政府文件
L22301	統計學在大數據中的應用	五種轉換與縮放方法	見索引	有	—
L22301	同上	對離群值的敏感度比較	見索引	無	—
L22301	同上	分佈調整（對數、分箱）	見索引	無	—
L22301	同上	PCA 流程與判讀	見索引	有	—
L22301	同上	t-SNE 的用途邊界	見索引	無	—

7.1 核心概念與技術原理

7.1.1 五種轉換與縮放方法

核心必考

方法	公式／作法	結果範圍	適用
標準化 (Z-score)	$(x - \mu) / \sigma$	均值 0、標準差 1	近似常態；PCA 前必做
正規化 (Min-Max)	$(x - \min) / (\max - \min)$	[0, 1]	需固定範圍(影像像素、神經網路輸入)；對離群值極敏感
穩健縮放	$(x - \text{中位數}) / \text{IQR}$	不固定	離群值多且不宜刪除時
對數轉換	$\log(x + 1)$	—	右偏資料(金額、次數)壓縮長尾
分箱	等寬／等頻／依業務切分	類別	提高穩健性、便於解釋(評分卡)

高頻考點：哪個對離群值敏感？

Min-Max 正規化極度敏感：只要有一個異常大值，其餘資料會被壓縮到接近 0 的極小區間，等於摧毀了大部分資料的鑑別力。

標準化雖也受影響（ μ 與 σ 皆被拉動），但程度較輕。

若資料含離群值且不宜刪除，應優先考慮**穩健縮放**（以中位數與 IQR 為基準，兩者本身對離群值穩健）或**對數轉換**。

對數轉換的兩個前提

1. 資料必須為**正值**。含 0 時用 $\log(x + 1)$ ；含負值則不能直接取對數，須改用其他轉換。
2. 對數轉換壓縮的是**右尾**。對左偏資料使用只會使偏態更嚴重。

7.1.2 主成分分析 (PCA)

核心必考

1. **標準化**（必要步驟）。
2. 計算共變異數矩陣。
3. 特徵分解取得特徵值與特徵向量。
4. 依特徵值降冪排序，計算解釋變異比例 $\lambda_i / \sum_j \lambda_j$ 。
5. 以累積解釋變異（如 $\geq 90\%$ ）或陡坡圖的轉折點決定保留維度數。

PCA 的四個陷阱

- **忘記標準化**——年收入（數值上萬）會完全主宰第一主成分，年齡（0-100）幾乎無貢獻。
- **PCA 是非監督式的**——它最大化的是特徵本身的變異，**不保證**保留對預測目標有用的資訊。被丟棄的低變異方向，有可能恰好最具鑑別力。
- **喪失可解釋性**——主成分是原特徵的線性組合，無法向業務單位說明「第二主成分增加代表什

麼」。

- 在測試集上重新擬合——必須以訓練集擬合的投影矩陣去轉換測試集。

7.1.3 t-SNE 與 UMAP 的用途邊界

核心必考

兩者為非線性降維，主要用於視覺化。

t-SNE 圖不能怎麼讀

t-SNE 只保留局部結構。圖上叢集之間的距離與叢集的大小不具實質意義——不能說「A 群和 B 群比較接近所以比較相似」，也不能說「這個群比較大所以樣本比較多」。

此外 t-SNE 不宜用於後續建模：它沒有穩定的投影函數可套用到新資料，且不同的隨機種子會產生不同的圖。需要可重複套用的降維請用 PCA。

7.2 程式判讀重點

核心必考

fit / transform / fit_transform 的語意

```
1 scaler = StandardScaler()
2 X_tr_s = scaler.fit_transform(X_tr) # 學習 mu、sigma 並轉換
3 X_te_s = scaler.transform(X_te) # 只轉換，沿用訓練集的 mu、sigma
```

必考：對測試集呼叫 fit_transform 是資料洩漏——測試集會用自己的統計量標準化，等於偷看了測試集分布。同理 PCA 也必須 fit 於訓練集、transform 於測試集。

PCA 的解釋變異判讀

```
1 pca = PCA(n_components=0.9) # 保留累積解釋變異達 90% 所需的成分數
2 Xp = pca.fit_transform(X_scaled) # 注意：X 必須先標準化
3 print(pca.n_components_) # 實際保留的成分數（整數）
4 print(pca.explained_variance_ratio_) # 各成分的解釋變異比例（陣列）
5 print(pca.explained_variance_ratio_.sum()) # 累積比例（純量）
```

必考：n_components 傳入 小數 代表「累積解釋變異的目標比例」，傳入 整數 才是「成分數」。兩者語意完全不同。

7.3 常見陷阱與錯誤觀念

常見陷阱與錯誤觀念

- 在切分前縮放。統計量取自全部資料，屬洩漏。
- 對測試集 fit_transform。同上。
- PCA 前未標準化。單位大的變數主宰主成分。
- 以為 PCA 一定提升模型效能。它是非監督式的，可能丟掉關鍵鑑別方向。
- 用 t-SNE 圖判斷群間距離或群大小。兩者皆無意義。

- 對含 0 或負值的資料直接取對數。會產生無定義值。
- 以 Min-Max 處理含極端值的金額欄位。其餘資料會被壓平。

7.4 正式公告試題索引

本章命題密度

兩場次正式公告試題（114 年第二次、115 年第一次）之 L22 科目共 100 題，其中對位至本代碼者 9 題，佔 9%。

本索引之 L 代碼為**編者對位**，非官方逐題分類；官方答案則照錄官方公告。

題目 ID	場次	官方答案	原卷頁次	含圖表	對位備註
OFFICIAL-114-2-L22-Q08	114-2	B	p.2-3	—	—
OFFICIAL-114-2-L22-Q09	114-2	C	p.3	—	—
OFFICIAL-114-2-L22-Q29	114-2	D	p.8	—	—
OFFICIAL-114-2-L22-Q30	114-2	C	p.8	—	—
OFFICIAL-114-2-L22-Q33	114-2	D	p.9	—	—
OFFICIAL-114-2-L22-Q36	114-2	B	p.10	—	—
OFFICIAL-115-1-L22-Q10	115-1	B	p.3	—	—
OFFICIAL-115-1-L22-Q16	115-1	A	p.4-5	—	—
OFFICIAL-115-1-L22-Q24	115-1	C	p.7-8	—	—

著作權處理與使用方式

官方試題為受著作權保護之著作。本書**不重製**官方題幹與選項全文，僅提供**題目 ID、場次、官方答案、原卷頁次與考綱對位**。

請依上表之**原卷頁次**，至 iPAS 官網「AI 應用規劃師 → 學習資源」下載該場次公告試題 PDF 對照閱讀；本章前述之核心概念、決策表與陷阱清單即為該批題目的考點拆解。

7.5 自編模擬題

模擬題 | SIM-L22301-001 | **選型題** | **難度：中級** | **對應 L22301**

某電商的「單筆訂單金額」欄位呈嚴重右偏，且含少數金額極高的企業採購訂單（不可刪除）。若欲將此欄位作為距離型模型的輸入特徵，下列前處理何者最為適當？

- Min-Max 正規化至 $[0, 1]$ ，因為模型需要固定範圍的輸入
- 先做對數轉換壓縮長尾，再視需要標準化；或直接採用穩健縮放
- 不做任何處理，因為金額本身就是有意義的數值
- 將所有超過 99 百分位的金額直接截斷為 99 百分位值

答案與逐項解析

答案：B

- (A) × Min-Max 對離群值**極度敏感**。少數極高的企業訂單會把 max 拉得很大，使絕大多數一般訂單的縮放值被壓縮到接近 0 的狹窄區間，鑑別力幾乎歸零。
- (B) ✓ **正解**。對數轉換是處理右偏金額資料的標準手段，可壓縮長尾並使分布趨近對稱；穩健縮放則以中位數與 IQR 為基準，兩者本身對離群值穩健。兩條路徑都能保留一般訂單之間的差異。
- (C) × 距離型模型（KNN、K-Means、SVM）對特徵尺度敏感，未縮放會讓金額欄主宰距離計算。
- (D) × 截斷會抹平企業採購與大額一般訂單的差異，且題幹明示這些訂單**不可刪除**（即其資訊有價值）。截斷等同於部分刪除資訊。

干擾項設計理由：(D) 提供了一個「保留樣本又消除離群」的假象，但實際上破壞了高價值訂單的區辨能力。

延伸考點：若模型改為**樹模型**（決策樹、隨機森林、梯度提升樹），則**完全不需要縮放**——樹依閾值切分，任何單調變換都不改變切點順序。因此「該不該縮放」的答案取決於後續用哪種模型。

模擬題 SIM-L22301-002 | **程式判讀** | **難度：中級** | **對應 L22301**

下列程式的問題為何？

```
1 scaler = StandardScaler()
2 X_train_s = scaler.fit_transform(X_train)
3 X_test_s = scaler.fit_transform(X_test)
```

- (A) 沒有問題，兩個資料集各自標準化較為公平
- (B) 第三行對測試集重新 fit，使用了測試集自身的統計量，屬資料洩漏且造成訓練與測試的尺度不一致；應改為 `scaler.transform(X_test)`
- (C) 應改用 `MinMaxScaler` 才不會有此問題
- (D) 應在兩行之前先對合併後的完整資料 fit，即可保持一致

答案與逐項解析

答案：B

- (A) × 「各自標準化」正是錯誤所在——同一個原始數值在訓練集與測試集會被映射成不同的縮放值，模型學到的關係在測試時失效。
- (B) ✓ **正解**。轉換器必須 fit 於訓練集、transform 於測試集，確保兩邊套用**同一組** μ 與 σ 。
- (C) × 換一種縮放器不改變「對測試集重新 fit」這個錯誤本質。
- (D) × 對合併資料 fit 雖能保持尺度一致，但統計量納入了測試集資訊，同樣構成**資料洩漏**，是更隱蔽的錯誤。

干擾項設計理由：(D) 是最具吸引力的誘答——它確實解決了「不一致」問題，卻引入了更嚴重的洩漏。

延伸考點：以管線（pipeline）封裝所有會學習參數的步驟，可在交叉驗證時自動於**每一折內**重新擬合，從結構上杜絕此類錯誤。此技巧在 L23301 有完整處理。

模擬題 SIM-L22301-003 | **程式判讀** | **難度：中級** | **對應 L22301**

關於下列程式之敘述，何者**錯誤**？

```
1 pca = PCA(n_components=0.95)
```

```
2 Xp = pca.fit_transform(X_scaled)
3 print(pca.n_components_)
```

- (A) `n_components=0.95` 代表保留累積解釋變異達 95% 所需的成分數
- (B) `pca.n_components_` 會印出實際保留的成分數（整數）
- (C) `X_scaled` 應為已標準化的資料，否則主成分會被尺度大的變數主宰
- (D) `n_components=0.95` 代表保留 95 個主成分

答案與逐項解析

答案：D

- (A) ✓ 正確。傳入 $0 < \text{值} < 1$ 的小數時，代表累積解釋變異的目標比例。
- (B) ✓ 正確，尾端底線的屬性為擬合後才產生。
- (C) ✓ 正確，PCA 前標準化是必要步驟。
- (D) × 錯誤（即為答案）。要保留 95 個主成分應傳入整數 `n_components=95`。小數與整數的語意完全不同，是本題型的核心考點。

延伸考點：決定保留維度數的三種常見方法——累積解釋變異門檻（如 90% 或 95%）、陡坡圖的轉折點、以及以下游模型效能作為選擇依據（此法最務實但成本最高）。

模擬題 SIM-L22301-004 | **觀念題** | **難度：中級** | **對應 L22301**

某分析師以 t-SNE 將 50 維客戶特徵降至 2 維並繪圖，觀察到左側有一個大叢集、右側有兩個小叢集，兩側相距甚遠。下列推論何者最為適當？

- (A) 左側叢集的客戶數量明顯多於右側，因為圖上面積較大
- (B) t-SNE 僅保留局部結構，叢集間的距離與叢集大小不具實質意義；圖僅能提示「可能存在分群結構」，須另以統計方法驗證
- (C) 兩側相距甚遠代表這兩群客戶的特徵差異達到統計顯著
- (D) 可直接將 t-SNE 產生的 2 維座標作為特徵訓練分類模型

答案與逐項解析

答案：B

- (A) × t-SNE 圖上的叢集面積不代表樣本數；演算法會依局部密度調整排布。
- (B) ✓ 正解。t-SNE 的設計目標是保留局部鄰域關係，全域幾何（群間距離、群大小）在轉換過程中不被保證。
- (C) × 圖上的距離不能推論統計顯著性；要驗證群間差異須用檢定或分群品質指標。
- (D) × t-SNE 沒有可套用到新資料的穩定投影函數，且不同隨機種子產生不同結果，不適合作為建模特徵。需要可重複套用的降維應使用 PCA。

干擾項設計理由：(A)(C) 都是把視覺印象直接當成量化結論，是 t-SNE 最常被誤用的兩種方式。

延伸考點：t-SNE 適合探索與溝通，PCA 適合建模與壓縮。若需要非線性降維又要能套用到新資料，可考慮 UMAP（具備 transform 能力）或自編碼器。

模擬題 SIM-L22301-005 | 觀念題（反向） | 難度：中級 | 對應 L22301

關於 PCA 之敘述，下列何者錯誤？

- (A) PCA 為非監督式方法，不使用標籤資訊
- (B) 執行 PCA 前應先標準化，否則單位大的變數會主宰主成分
- (C) 保留較多主成分可提高累積解釋變異比例
- (D) PCA 保證保留對預測目標最有鑑別力的資訊，因此降維後模型效能必然提升

答案與逐項解析

答案：D

- (A) ✓ 正確。
- (B) ✓ 正確。
- (C) ✓ 正確，累積解釋變異隨成分數單調遞增。
- (D) × 錯誤（即為答案）。PCA 最大化的是**特徵本身的變異**，與預測目標無關。變異小的方向有可能恰好是最具鑑別力的方向，被丟棄後模型效能反而下降。

干擾項設計理由：(D) 利用「降維＝去除雜訊＝效能提升」的普遍誤解。

延伸考點：若目標是**監督式降維**，應考慮線性判別分析（LDA，最大化類別可分性）或直接做特徵選擇。另須注意 PCA 會使模型**喪失可解釋性**，在需要向客戶說明決策依據的場景（信貸、保險）應謹慎使用。

7.6 章末複習

7.6.1 一頁重點

主題	必記結論
縮放方法	標準化／Min-Max／穩健縮放／對數／分箱
離群值敏感度	Min-Max 最敏感 ；離群多改用穩健縮放或對數
對數轉換	只對正值右偏資料有效
PCA 前置	必須標準化 ；fit 訓練集、transform 測試集
PCA 性質	非監督、不保證提升效能、喪失可解釋性
n_components	小數＝目標解釋變異比例 ； 整數＝成分數
t-SNE	僅供視覺化；群間距離與群大小 無意義 ；不宜用於建模
樹模型	不需要縮放

7.6.2 必背名詞

標準化、Min-Max 正規化、穩健縮放、對數轉換、分箱（Binning）、主成分分析（PCA）、解釋變異比例、陡坡圖（Scree Plot）、t-SNE、UMAP、資料洩漏。

7.6.3 五分鐘快速複習

- 說出哪一種縮放對離群值最敏感，以及替代方案。

2. 說出 PCA 前為何必須標準化。
3. 說出 $n_components=0.9$ 與 $n_components=9$ 的差異。
4. 說出 t-SNE 圖上哪兩件事不能解讀。
5. 說出哪一類模型完全不需要特徵縮放。

7.6.4 跨章連結

Chapter 1：分布與離群值判定；Chapter 8：距離型演算法為何需要縮放；第 I 冊 L21301：前處理順序與洩漏；L23 之 L23102 / L23301：PCA 的線性代數與管線實作。

來源與稽核紀錄

官方來源：IPAS-SCOPE-11502（L22301 備註欄「數據轉換、縮放與分佈調整、特徵工程」）；IPAS-GUIDE-L22（頁碼 **PENDING**）。

編者推論／延伸：縮放方法對照表、對數轉換前提、PCA 四陷阱、程式判讀二則、五題模擬題與干擾項設計。

未解決資料缺口：學習指引頁碼；中級勘誤表完整條目。

常見的大數據分析方法

章節識別卡

官方代碼	L22302
官方名稱	常見的大數據分析方法
官方備註	數據分析演算法、模式識別以及資料不平衡處理策略
所屬	L22 / L223 大數據分析方法與工具
授證路線	DATA_ANALYSIS
資料截止日	中華民國 115 年 8 月 1 日
對應來源	IPAS-SCOPE-11502、IPAS-GUIDE-L22（頁碼 PENDING ）
層級分布	核心必考 80% 官方補充 15% 政府實務 5% 產業延伸 0%
先備知識	Chapter 7；距離度量概念
建議時數	3.0 小時
本版題數	模擬題 7 題（含程式判讀 2 題）
備註	L22 命題密度第二高之章節

學習目標

1. 比較 K-Means、階層式分群與 DBSCAN 的假設與限制。
2. 計算關聯規則的支持度、信賴度與提升度，並判斷規則是否具行動價值。
3. 選擇圖分析中適合的中心性或社群偵測方法。
4. 說明時序分解與定態的意義。
5. 設計資料不平衡的四層處理策略。

考綱對位

代碼	官方主題	本章節點	正式題	程式題	政府文件
L22302	常見的大數據分析方法	分析四層次	見索引	無	—
L22302	同上	三種分群演算法	見索引	有	—
L22302	同上	關聯規則三指標	見索引	無	—
L22302	同上	圖分析與社群偵測	見索引	無	—
L22302	同上	時序分解與定態	見索引	無	—
L22302	同上	資料不平衡四層策略	見索引	有	GOV-FSC-AI

8.1 核心概念與技術原理

8.1.1 分析的四個層次

官方補充

描述性（發生了什麼）→ 診斷性（為什麼發生）→ 預測性（將會發生什麼）→ 指示性（該怎麼做）。

多數企業卡在前兩層；AI 的價值在後兩層。**指示性分析**通常需結合最佳化或因果推論，而非單純預測——「預測誰會流失」與「該對誰採取什麼挽留動作」是兩件事。

8.1.2 三種分群演算法

核心必考

	K-Means	階層式分群	DBSCAN
需先指定群數	是 (k)	否（可事後切樹狀圖）	否
群形狀	僅適合球形、大小相近	較有彈性	任意形狀
離群值	敏感（會被拉進某群）	敏感	自動標記為雜訊
關鍵參數	k	連結方式、距離	eps（鄰域半徑）、 min_samples
需縮放	需要	需要	需要
規模	大資料可行	計算成本高	中大型可行

選 k 的兩種方法

肘部法（Elbow Method）：畫出群內平方和隨 k 變化的曲線，取「下降趨緩的轉折點」。缺點是轉折常不明顯，判讀主觀。

輪廓係數（Silhouette Coefficient）：值域 $[-1, 1]$ ，衡量樣本與自己群的緊密度相對於與最近他群的分離度。**越接近 1 越好**，接近 0 表示在邊界上，負值表示可能被分錯群。

DBSCAN 的優勢正是**不需要先指定群數**，且能把不屬於任何密集區的點標為**雜訊**（在實作中通常標為 -1），因此常用於**異常偵測**。

8.1.3 關聯規則：三個指標

核心必考

對規則「 $A \Rightarrow B$ 」：

$$\text{支持度} = P(A \cap B) \quad \text{信賴度} = P(B|A) = \frac{P(A \cap B)}{P(A)} \quad \text{提升度} = \frac{P(B|A)}{P(B)} = \frac{\text{信賴度}}{P(B)}$$

指標	回答的問題	判讀
支持度	這個組合有多普遍？	用來篩掉罕見組合，避免挖出無意義的長尾規則
信賴度	買 A 的人有多少也買 B？	衡量規則的條件可靠性

指標	回答的問題	判讀
提升度	買 A 是否真的提高了買 B 的機率？	> 1 正關聯； $= 1$ 獨立； < 1 負關聯

本章第一名考點

高信賴度不等於有價值。若 B 本身就是人人都買的商品（如塑膠袋、牛奶），則 $P(B)$ 很高，信賴度自然高，但提升度會接近 1——代表買 A 完全沒有提高買 B 的機率，該規則**不具行動價值**。因此三個指標必須**一起看**，且提升度才是判斷「是否存在真實關聯」的關鍵。

8.1.4 圖分析

官方補充

方法	意義	應用
度中心性	直接連結數	交易對象最多的帳戶
介數中心性	位於多少條最短路徑上	資金流的中介者、供應鏈關鍵節點
特徵向量 / PageRank	與重要節點相連者也重要	影響力排序
社群偵測	找出內部緊密、對外稀疏的子群	詐欺共犯圈、客群分群
最短路徑	兩節點間最少跳數	物流路徑、關係追溯

8.1.5 時序分析

官方補充

時序可分解為**趨勢**、**季節**、**殘差**三個成分。傳統統計模型（如 ARIMA 家族）要求資料**定態**——平均數與變異數不隨時間改變，可透過**差分**達成。

常見陷阱與錯誤觀念

時序資料的驗證**絕不可隨機切分**，否則等於用未來預測過去，指標必然虛高。應採**時間切分**或**前向鏈式驗證**。此考點在 L23303 會再次出現。

8.1.6 資料不平衡：四層處理策略

核心必考

層次	方法	要點與風險
資料層	過採樣（隨機、合成插值如 SMOTE）、欠採樣	合成法以少數類樣本間插值產生新樣本； 只能對訓練集做 。欠採樣會丟失多數類資訊。
演算法層	類別權重、成本敏感學習、Focal Loss	不改變資料分布，直接調整損失函數對少數類的重視程度

層次	方法	要點與風險
決策層	閾值調整、依 PR 曲線選點	最簡單有效且可隨業務成本動態調整，卻最常被忽略
評估層	改用召回率、F1、 AUPRC 、G-mean	棄用準確率。極度不平衡下 AUPRC 比 AUROC 更具鑑別力

為何極度不平衡要看 AUPRC 而非 AUROC

AUROC 的橫軸是偽陽性率 $= FP/(FP + TN)$ 。在極度不平衡下 TN 極大，即使 FP 增加不少，偽陽性率的變動仍很小，因此 AUROC 會顯得過於樂觀。

PR 曲線的橫縱軸都聚焦於少數類（精確率與召回率皆不含 TN ），因此對少數類的表現變化更敏感。

合成過採樣的三個限制

1. 在高維空間中插值可能生成不真實的樣本。
2. 若少數類本身有多個子群，跨子群插值會產生錯誤樣本。
3. 對類別型特徵無法直接插值，須用支援類別的變體。

另須注意：合成後模型輸出的機率不再反映真實盛行率，若下游需要機率值（如期望損失計算），須另做機率校準。

8.2 程式判讀重點

核心必考

分群結果的判讀

```

1 km = KMeans(n_clusters=4, random_state=0).fit(X_scaled)
2 km.labels_ # 各樣本的群編號：0..3
3 km.inertia_ # 群內平方和（越小越緊密），用於肘部法
4
5 db = DBSCAN(eps=0.5, min_samples=5).fit(X_scaled)
6 set(db.labels_) # 可能含 -1，代表「雜訊點」，不屬於任何群

```

必考：DBSCAN 的標籤 -1 是雜訊而非第 -1 群；計算群數時須排除。K-Means 則不會產生雜訊標籤，每個點都會被指派到某一群。

不平衡處理的正確與錯誤時機

```

1 # 錯誤：切分前重採樣 -> 合成樣本同時進入訓練與測試集
2 X_res, y_res = SMOTE().fit_resample(X, y)
3 X_tr, X_te, y_tr, y_te = train_test_split(X_res, y_res)
4
5 # 正確：只對訓練集重採樣，或以 imblearn 的 Pipeline 封裝
6 X_tr, X_te, y_tr, y_te = train_test_split(X, y, stratify=y)
7 X_tr_res, y_tr_res = SMOTE().fit_resample(X_tr, y_tr)

```

必考：train_test_split 的 stratify=y 可維持切分後各集合的類別比例，在不平衡資料上是必要參數。

8.3 常見陷阱與錯誤觀念

常見陷阱與錯誤觀念

- 高信賴度就採取行動。須看提升度是否顯著大於 1。
- 以為 K-Means 能找出任意形狀的群。它假設球形且大小相近；環狀或彎月形資料應改用 DBSCAN。
- 把 DBSCAN 的 -1 當成一個群。那是雜訊標籤。
- 分群前未縮放。距離型演算法會被尺度大的變數主宰。
- 在切分前做重採樣。合成樣本洩漏至測試集。
- 極度不平衡時用準確率驗收。全猜多數類即可得高分。
- 時序資料隨機切分。用未來預測過去。
- 忘記閾值調整這一層。它成本最低、見效最快，卻最常被跳過。

8.4 政府指引與產業落地實務

政府指引與產業落地實務

文件	機關	日期	文件性質	本章意義
金融業運用人工智慧 (AI) 指引	金管會	113.06.20	行政規則／指引	閾值即業務決策；分群結果不得成為不當差別待遇

一、閾值是業務決策，須文件化。不平衡處理的決策層（調整判定閾值）直接決定誤報與漏報的比例。在詐欺偵測、洗錢防制等場景，閾值的選定依據與對客戶的影響評估應載明於文件，供內部稽核查核。

二、分群結果的公平性風險。以客戶分群作為差別定價或差別服務的依據時，須留意分群變數是否構成代理變數——郵遞區號、裝置型號等看似中性的欄位，可能間接反映受保護特徵。金管會指引就公平性有所要求（屬主管機關期待），實務上應對各分群的核准率與費率差距進行檢視。

三、編者提醒。以合成過採樣改善少數類表現後，模型輸出的機率不再反映真實盛行率。若該機率會被用於保費定價或預期損失計算，必須先做機率校準，否則將產生系統性偏誤。

8.5 正式公告試題索引

本章命題密度

兩場次正式公告試題（114 年第二次、115 年第一次）之 L22 科目共 100 題，其中對位至本代碼者 17 題，佔 17%。

本索引之 L 代碼為編者對位，非官方逐題分類；官方答案則照錄官方公告。

題目 ID	場次	官方答案	原卷頁次	含圖表	對位備註
OFFICIAL-114-2-L22-Q10	114-2	C	p.3	—	—
OFFICIAL-114-2-L22-Q12	114-2	A	p.3	—	—
OFFICIAL-114-2-L22-Q14	114-2	D	p.4	—	—

題目 ID	場次	官方答案	原卷頁次	含圖表	對位備註
OFFICIAL-114-2-L22-Q26	114-2	C	p.7	—	—
OFFICIAL-114-2-L22-Q28	114-2	A	p.8	—	—
OFFICIAL-114-2-L22-Q37	114-2	C	p.10	—	—
OFFICIAL-114-2-L22-Q39	114-2	D	p.11	—	—
OFFICIAL-115-1-L22-Q02	115-1	A	p.1	是	須對照原卷圖表
OFFICIAL-115-1-L22-Q18	115-1	D	p.5	—	—
OFFICIAL-115-1-L22-Q19	115-1	D	p.5-6	是	須對照原卷圖表
OFFICIAL-115-1-L22-Q20	115-1	B	p.6	—	—
OFFICIAL-115-1-L22-Q22	115-1	C	p.7	—	—
OFFICIAL-115-1-L22-Q25	115-1	C	p.8	—	—
OFFICIAL-115-1-L22-Q32	115-1	B	p.9-10	—	—
OFFICIAL-115-1-L22-Q34	115-1	C	p.10	—	—
OFFICIAL-115-1-L22-Q40	115-1	A	p.12-13	是	須對照原卷圖表
OFFICIAL-115-1-L22-Q42	115-1	D	p.14	—	—

著作權處理與使用方式

官方試題為受著作權保護之著作。本書不重製官方題幹與選項全文，僅提供題目 ID、場次、官方答案、原卷頁次與考綱對位。

請依上表之原卷頁次，至 iPAS 官網「AI 應用規劃師 → 學習資源」下載該場次公告試題 PDF 對照閱讀；本章前述之核心概念、決策表與陷阱清單即為該批題目的考點拆解。

8.6 自編模擬題

模擬題 SIM-L22302-001 | 判讀題 | 難度：中級 | 對應 L22302

某零售商挖掘出關聯規則「購買牛奶 $\Rightarrow$ 購買麵包」，支持度 0.30、信賴度 0.75、提升度 0.98。下列解讀何者最為正確？

- (A) 信賴度高達 0.75，應立即將牛奶與麵包相鄰陳列以促進交叉銷售
- (B) 提升度接近 1 表示兩者幾乎獨立，該規則雖信賴度高但缺乏商業行動價值，因為麵包本身即為高購買率商品
- (C) 支持度 0.30 偏低，代表此規則不可靠，應提高最小支持度門檻重新挖掘
- (D) 提升度小於 1 表示兩商品為互斥關係，應將其分開陳列

答案與逐項解析

答案：B

- (A) × 高信賴度可能只是因為後項商品本身普及。若原本就有 76% 的顧客會買麵包，那麼「買牛奶的人有 75% 買麵包」其實**略低於**平均，毫無促銷意義。
- (B) ✓ **正解**。由提升度 = 信賴度 ÷ $P(\text{麵包})$ 反推， $P(\text{麵包}) \approx 0.75/0.98 \approx 0.765$ ，代表麵包本身就是高購買率商品。提升度 ≈ 1 表示兩者**統計上近乎獨立**。
- (C) × 支持度 0.30 代表 30% 的交易同時包含兩者，在零售情境屬相當高。且支持度衡量的是**普遍性**而非可靠性。
- (D) × 0.98 僅略低於 1，屬統計上的獨立範圍，不足以宣稱互斥。真正的負關聯須顯著小於 1。

干擾項設計理由：(A) 是實務上最常見的誤用；(D) 針對「小於 1 就是負相關」的機械式判讀，忽略了 0.98 與 1 的差距在雜訊範圍內。

延伸考點：三指標的分工——支持度篩掉罕見組合、信賴度衡量條件可靠性、**提升度判斷是否有真實關聯**。命題最愛的陷阱正是「高信賴度但提升度 ≈ 1 」。

模擬題 SIM-L22302-002 | **選型題** | **難度：中級** | **對應 L22302**

某工廠感測資料在二維空間中呈現兩個彎月形的分布，另有少量散落各處的異常讀值。若欲同時完成分群與異常標記，下列演算法何者最為適當？

- (A) K-Means，設 $k = 2$
- (B) DBSCAN，調整鄰域半徑與最小點數
- (C) 階層式分群，取兩群
- (D) PCA 降維後再以 K-Means 分群

答案與逐項解析

答案：B

- (A) × K-Means 假設群為**球形**且以質心指派，面對彎月形會把兩個月牙從中間切開；且它會把散落的異常點強行歸入某一群，無法標記異常。
- (B) ✓ **正解**。DBSCAN 依**密度**分群，可找出任意形狀的群；不屬於任何密集區的點會被標為**雜訊**（-1），一次滿足題幹的兩項需求。
- (C) × 階層式分群較有彈性但仍以距離連結為主，對彎月形的效果取決於連結方式，且同樣不會自動標記雜訊；在大資料上計算成本也高。
- (D) × 降維不改變 K-Means 的球形假設，彎月形在低維空間仍是彎月形。

干擾項設計理由：(D) 利用「先降維再分群」的常見流程慣性，但沒解決核心的形狀假設問題。

延伸考點：DBSCAN 的兩個參數——`eps`（鄰域半徑）與 `min_samples`（形成核心點所需的鄰居數）。`eps` 太小會把整片資料都標為雜訊，太大則所有點併成一群。此外 DBSCAN 對**密度差異大**的資料表現不佳（各群密度不同時難以找到單一 `eps`）。

模擬題 SIM-L22302-003 | **程式判讀** | **難度：中級** | **對應 L22302**

執行下列程式後，`n_clusters` 的值為何？（假設 `db.labels_` 的相異值為 `{-1, 0, 1, 2}`）

```
1 db = DBSCAN(eps=0.5, min_samples=5).fit(X_scaled)
2 labels = db.labels_
3 n_clusters = len(set(labels)) - (1 if -1 in labels else 0)
```

- (A) 4
- (B) 3
- (C) 2
- (D) 無法判斷，因 DBSCAN 需先指定群數

答案與逐項解析

答案：B

相異標籤共 4 個 (-1, 0, 1, 2)；其中 -1 為雜訊標籤而非群，故扣除 1，得 $4 - 1 = 3$ 。

(A) × 誤把 -1 當成一個群。

(B) ✓ 正解。

(C) × 多扣了一個。

(D) × DBSCAN 的特點正是**不需要**先指定群數，群數由密度結構自動決定。

干擾項設計理由：(A) 是最常見的計算錯誤；(D) 針對 K-Means 與 DBSCAN 的混淆。

延伸考點：被標為 -1 的點在異常偵測中往往正是我們要找的目標。實務上可統計雜訊比例——若高達三成以上，通常代表 ϵ 設得太小，須重新調整。

模擬題 SIM-L22302-004 | 情境題 | 難度：整合 | 對應 L22302

某銀行的信用卡盜刷資料中，正樣本（盜刷）僅佔 0.4%。團隊以準確率作為驗收指標，模型達到 99.6% 而宣告成功。下列評論何者最為適當？

- (A) 99.6% 為極佳表現，可直接上線
- (B) 在 0.4% 的盛行率下，全部預測為「正常」即可得 99.6% 準確率；應改以召回率、F1 或 AUPRC 驗收，並依漏檢與誤報成本調整判定閾值
- (C) 應提高準確率目標至 99.9% 以確保品質
- (D) 應改用 AUROC，因其在任何情況下都優於 AUPRC

答案與逐項解析

答案：B

(A) × 準確率在極度不平衡下是**無效指標**。

(B) ✓ 正解。指出兩件事：驗收指標須改為聚焦少數類者，以及閾值應依業務成本決定（漏檢一筆盜刷的損失遠高於誤攔一筆正常交易的處理成本）。

(C) × 提高一個本來就無效的指標，只會讓模型更傾向全部預測為多數類。

(D) × 恰好相反。極度不平衡時 AUROC 會因大量真陰性使偽陽性率變動微小而顯得過於樂觀；**AUPRC 更具鑑別力**。

干擾項設計理由：(D) 利用 AUROC 較廣為人知的印象，測試考生是否理解兩者在不平衡下的差異。

延伸考點：四層策略中，**決策層（閾值調整）**成本最低卻最常被忽略。實務上應以期望成本選閾值：漏檢損失 × 漏檢數 + 誤報成本 × 誤報數，取最小者。

模擬題 SIM-L22302-005 | 程式判讀 | 難度：中級 | 對應 L22302

下列程式在不平衡資料上評估模型，其主要問題為何？

```
1 X_res, y_res = SMOTE().fit_resample(X, y)
2 X_tr, X_te, y_tr, y_te = train_test_split(X_res, y_res, test_size=0.2)
```

```
3 model.fit(X_tr, y_tr)
4 print(model.score(X_te, y_te))
```

- (A) 沒有問題，合成過採樣可有效解決類別不平衡
- (B) 重採樣在切分之前執行，由訓練資料插值產生的合成樣本會出現在測試集中，指標嚴重虛高；應先切分再僅對訓練集重採樣
- (C) 應把 test_size 改為 0.3 即可
- (D) model.score() 回傳的是 F1 分數，不適用於不平衡資料

答案與逐項解析

答案：B

- (A) × 合成過採樣本身沒錯，錯的是執行時機。
- (B) ✓ **正解**。合成樣本是由原始少數類樣本插值而來。若在切分前合成，某個原始樣本可能落在訓練集、而由它插值出的合成樣本落在測試集，模型等於看過測試答案的近似版本。
- (C) × 改變切分比例不觸及洩漏的本質。
- (D) × 分類器的 score() 預設回傳**準確率**而非 F1。這也是本程式的另一個問題——在不平衡資料上準確率無意義——但主要問題仍是洩漏。

干擾項設計理由：(D) 陳述了一個真實存在的次要問題但描述錯誤（誤稱回傳 F1），測試考生對 score() 預設行為的掌握。

延伸考點：正確作法是以 imblearn 的 Pipeline 封裝重採樣步驟，使其在交叉驗證的**每一折訓練部分**內才執行。另注意 train_test_split 應加 stratify=y 以維持類別比例。

模擬題 SIM-L22302-006 | **選型題** | **難度：中級** | **對應 L22302**

某洗錢防制團隊欲從轉帳網絡中找出「表面上交易量不大，但位於多條資金流動路徑上的中介帳戶」。下列圖分析方法何者最為適當？

- (A) 度中心性
- (B) 介數中心性
- (C) 最短路徑演算法
- (D) 社群偵測

答案與逐項解析

答案：B

- (A) × 度中心性只看直接連結數量。題幹明示該帳戶「交易量不大」，度中心性會低，正好抓不到。
- (B) ✓ **正解**。介數中心性衡量節點位於多少條**最短路徑**上，正是「中介者」的定義。資金必須經過的關鍵通道節點，即使自身交易筆數不多，介數中心性仍會很高。
- (C) × 最短路徑演算法計算的是兩節點之間的路徑，是介數中心性的計算基礎，但本身不直接回答「誰是中介者」。
- (D) × 社群偵測找的是緊密相連的**子群**（共犯圈），不是個別的中介節點。

干擾項設計理由：(A) 是最直覺的「重要節點」指標，但恰好與題幹的「交易量不大」矛盾——這是本題的鑑別點。

延伸考點：金融犯罪防制常組合使用：**社群偵測**找出可疑集團範圍，**介數中心性**在集團內找出核心中介者，**最短路徑**追溯資金流向。三者回答不同層次的問題。

模擬題 SIM-L22302-007 | 觀念題（反向） | 難度：中級 | 對應 L22302

關於資料不平衡處理，下列敘述何者**錯誤**？

- (A) 調整判定閾值屬決策層策略，成本低且可依業務成本動態調整
- (B) 設定類別權重屬演算法層策略，不改變原始資料分布
- (C) 合成過採樣後，模型輸出的機率仍準確反映真實盛行率，可直接用於期望損失計算
- (D) 極度不平衡時應改以召回率、F1 或 AUPRC 取代準確率作為驗收指標

答案與逐項解析

答案：C

(A) ✓ 正確，且這一層最常被忽略。

(B) ✓ 正確。

(C) × **錯誤（即為答案）**。合成過採樣人為改變了訓練資料中的類別比例，模型學到的機率是**重採樣**後的分布，會系統性高估少數類的發生機率。若要用於期望損失或保費定價，必須先做**機率校準**。

(D) ✓ 正確。

干擾項設計理由：(C) 是實務上極常見的疏漏——團隊改善了分類指標，卻沒發現輸出機率已失去校準，導致下游的金額計算全面偏誤。

延伸考點：四層策略可組合使用，但須注意順序與副作用。若下游需要**可信的機率值**，優先考慮演算法層（類別權重）與決策層（閾值），因為它們不扭曲資料分布。

8.7 章末複習

8.7.1 一頁重點

主題	必記結論
分群	K-Means 球形需指定 k ；階層式不需 k ；DBSCAN 任意形狀+自動標雜訊
選 k	肘部法、輪廓係數（越接近 1 越好）
關聯規則	提升度 > 1 才有價值；高信賴度可能只因後項本身普及
圖分析	中介者用 介數中心性 ；共犯圈用社群偵測
時序	趨勢+季節+殘差；需定態； 不可隨機切分
不平衡四層	資料／演算法／ 決策（閾值） ／評估
評估指標	棄用準確率；極度不平衡下 AUPRC > AUROC
重採樣	只對訓練集 ；合成後機率須校準

8.7.2 必背名詞

K-Means、肘部法、輪廓係數、階層式分群、DBSCAN、雜訊點、支持度、信賴度、提升度、度中心性、介數中心性、社群偵測、定態、差分、過採樣、欠採樣、類別權重、AUPRC、機率校準。

8.7.3 五分鐘快速複習

1. 說出三種分群演算法各自的假設與是否需先指定群數。
2. 說出提升度的判讀基準，以及「高信賴度但無價值」的成因。
3. 說出不平衡處理的四個層次各有哪些手段。
4. 說出極度不平衡時為何 AUPRC 優於 AUROC。
5. 說出重採樣為何必須在切分之後。

8.7.4 跨章連結

Chapter 7：距離型演算法為何需要縮放；Chapter 9：分群結果的視覺化；Chapter 11：不平衡在鑑別式任務中的實務影響；第 I 冊 L21102：閾值與漏檢誤報的商業折衷。

來源與稽核紀錄

官方來源：IPAS-SCOPE-11502（L22302 備註欄「數據分析演算法、模式識別以及資料不平衡處理策略」）；IPAS-GUIDE-L22（頁碼 **PENDING**）。

政府文件：GOV-FSC-AI（行政規則／指引）。查核日 中華民國 115 年 8 月 1 日。

編者推論／延伸：分群對照表、三指標分工、四層策略表、機率校準提醒、程式判讀二則、七題模擬題與干擾項設計。

未解決資料缺口：學習指引頁碼；中級勘誤表完整條目。

數據可視化工具

章節識別卡

官方代碼	L22303
官方名稱	數據可視化工具
官方備註	資訊呈現的原則、圖表類型的選擇以及視覺化效能
所屬	L22 / L223 大數據分析方法與工具
授證路線	DATA_ANALYSIS
資料截止日	中華民國 115 年 8 月 1 日
對應來源	IPAS-SCOPE-11502、IPAS-GUIDE-L22（頁碼 PENDING ）
層級分布	核心必考 80% 官方補充 15% 政府實務 5% 產業延伸 0%
先備知識	Chapter 1；matplotlib 基本用法
建議時數	2.0 小時
本版題數	模擬題 4 題（含程式判讀 1 題）

學習目標

1. 依分析目的選擇適當的圖表類型。
2. 辨識截斷軸、雙軸、3D 效果等誤導手法。
3. 說明大規模資料視覺化的效能策略。
4. 設計符合可及性與治理要求的呈現方式。

考綱對位

代碼	官方主題	本章節點	正式題	程式題	政府文件
L22303	數據可視化工具	圖表選型對照	見索引	有	—
L22303	同上	視覺化的誠信原則	見索引	有	—
L22303	同上	色彩可及性與資料墨水比	見索引	無	—
L22303	同上	大規模視覺化效能	見索引	無	—
L22303	同上	呈現與揭露之治理	見索引	無	GOV-FSC-AI GOV-PDPA

9.1 核心概念與技術原理

9.1.1 圖表選型對照

核心必考

分析目的	適合圖表	不適合／常見誤用
比較類別大小	長條圖（橫向適合長標籤）	圓餅圖類別超過 5 個即難以比較
呈現趨勢	折線圖	以長條圖表現連續時間
呈現分布	直方圖、箱型圖、小提琴圖	只報平均數而不呈現分布
兩變數關係	散布圖（可加趨勢線）	以相關係數取代散布圖檢視
組成比例	堆疊長條圖、100% 堆疊	多層堆疊難以比較中間層
地理分布	面量圖	未依人口標準化而僅呈現絕對數
關聯矩陣	熱力圖	色階選擇不當造成誤讀

9.1.2 視覺化的誠信原則

核心必考

五條必記規則

1. 長條圖的 Y 軸必須從 0 起。截斷軸會誇大差異，是最常見的誤導手法。折線圖為呈現變化細節可不從 0 起，但須明確標示。
2. 雙 Y 軸容易製造假關聯，應謹慎使用並標明各自單位。
3. 避免 3D 效果，透視會扭曲面積與長度的感知。
4. 色彩可及性：約 8% 男性有紅綠色覺辨識障礙，關鍵資訊不應僅以紅綠對比傳達，須輔以形狀或標籤。
5. 資料墨水比：刪除無資訊的格線、陰影與裝飾，讓版面留給資料本身。

9.1.3 大規模視覺化效能

核心必考

核心問題是不能把上億筆點全部畫出來——瀏覽器會當掉，且過度重疊的散布圖本身也無法閱讀。

策略	作法	備註
伺服器端預彙總	先 group by 到所需粒度再回傳	最有效；把運算留在資料端
抽樣	隨機或分層抽樣後繪製	須確保抽樣具代表性
分箱	以六角形分箱取代散布圖	保留密度資訊且不重疊
資料立方體／物化視圖	預先計算常用維度組合	加速互動式鑽取
前端虛擬捲動	只渲染可視範圍	適用於大型表格

儀表板設計應遵循「先總覽、再縮放與篩選、最後細節按需」的順序。

9.2 程式判讀重點

核心必考

座標軸設定與誤導

```

1 ax.bar(x, y)
2 ax.set_ylim(95, 100) # 危險：長條圖截斷 Y 軸，視覺上誇大微小差異
3 ax.set_yscale('log') # 對數尺度：須明確標示，否則讀者會誤判倍率
4 ax.set_ylim(bottom=0) # 長條圖的正確作法

```

必考：set_ylim 若用於長條圖並將下界設為非 0，即構成截斷軸；對數尺度雖合法但**必須標示**，否則等距的刻度代表的是倍數而非差額。

9.3 常見陷阱與錯誤觀念

常見陷阱與錯誤觀念

- 長條圖截斷 Y 軸。最經典的誤導。
- 圓餅圖塞入十幾個類別。人眼無法比較相近的扇形角度。
- 以絕對數繪製地圖。人口多的區域必然數字大，須先標準化為每萬人比率。
- 只呈現平均數。兩組平均相同但分布完全不同的情況極常見，須搭配箱型圖或直方圖。
- 對數尺度未標示。讀者會把倍數差異誤讀為差額。
- 把上億筆原始點直接送到前端。應在伺服器端先彙總。
- 僅以紅綠區分好壞。色覺辨識障礙者無法判讀。

9.4 政府指引與產業落地實務

政府指引與產業落地實務

文件	機關	日期	文件性質	本章意義
金融業運用人工智慧 (AI) 指引	金管會	113.06.20	行政規則／指引	透明性；模型監控儀表板為說明工具
個人資料保護法	個資主管機關	現行有效	法律	小樣本格之再識別風險

視覺化在 AI 治理中的角色常被低估，但它是**透明性原則**的主要載體。

- 金管會指引就透明性與可解釋性有所要求（屬主管機關期待），實務上模型監控儀表板（效能趨勢、漂移指標、分群公平性差距）即為向稽核與管理層說明模型狀態的標準工具。
- **公平性視覺化**應以分群並列呈現各群體的核准率與誤判率，而非只呈現整體平均——整體良好而某一子群顯著較差，正是彙總數字所掩蓋的問題。
- 對外揭露時**不得以圖表誤導**。截斷軸誇大模型改善幅度、只呈現有利期間的效能曲線，均可能構成不實陳述。
- **編者提醒：**呈現含個資的分析結果時，應避免**小樣本格**造成的再識別風險——某圖表格中僅 1 至 2 人時可反推個體。實務常設定最小顯示門檻（如樣本數低於某值即不顯示或合併）。

9.5 正式公告試題索引

本章命題密度

兩場次正式公告試題（114 年第二次、115 年第一次）之 L22 科目共 100 題，其中對位至本代碼者 7 題，佔 7%。

本索引之 L 代碼為**編者對位**，非官方逐題分類；官方答案則照錄官方公告。

題目 ID	場次	官方答案	原卷頁次	含圖表	對位備註
OFFICIAL-114-2-L22-Q21	114-2	B	p.6	—	須對照原卷圖表
OFFICIAL-114-2-L22-Q22	114-2	D	p.6	—	須對照原卷圖表
OFFICIAL-114-2-L22-Q25	114-2	A	p.7	—	—
OFFICIAL-114-2-L22-Q48	114-2	D	p.16	是	—
OFFICIAL-115-1-L22-Q27	115-1	D	p.8	—	須對照原卷圖表
OFFICIAL-115-1-L22-Q28	115-1	C	p.8-9	—	須對照原卷圖表
OFFICIAL-115-1-L22-Q29	115-1	D	p.9	—	須對照原卷圖表

著作權處理與使用方式

官方試題為受著作權保護之著作。本書**不重製**官方題幹與選項全文，僅提供**題目 ID、場次、官方答案、原卷頁次與考綱對位**。

請依上表之**原卷頁次**，至 iPAS 官網「AI 應用規劃師 → 學習資源」下載該場次公告試題 PDF 對照閱讀；本章前述之核心概念、決策表與陷阱清單即為該批題目的考點拆解。

9.6 自編模擬題

模擬題 | SIM-L22303-001 | **選型題** | **難度：基礎** | **對應 L22303**

某團隊欲比較 12 個產品線的年度營收占比。下列圖表何者最為適當？

- (A) 圓餅圖，因其最能表達「占比」概念
- (B) 橫向長條圖（依數值排序），必要時輔以百分比標籤
- (C) 3D 立體圓餅圖，視覺效果較佳
- (D) 折線圖

答案與逐項解析

答案：B

- (A) × 圓餅圖在類別超過約 5 個時，相近的扇形角度人眼難以區分；12 個類別會使圖形完全無法閱讀。
- (B) ✓ **正解**。長條圖以長度編碼數值，是人眼最精確的視覺通道；橫向排列可容納較長的产品線名稱；依數值排序讓比較更容易。加上百分比標籤即可同時傳達占比。
- (C) × 3D 透視會扭曲面積感知，前方扇形看起來比實際大，屬應避免的效果。
- (D) × 折線圖用於呈現**連續變化**（如時間趨勢），把類別用線連起來會暗示不存在的順序關係。

干擾項設計理由：(A) 利用「占比＝圓餅圖」的直覺聯想，是最常見的圖表誤用。

延伸考點：若同時要看「12 個產品線」與「跨 3 年變化」，應改用**分組長條圖**或**小型多重圖**，而非把 36 個資料點塞進單一圓餅或堆疊圖。

模擬題 SIM-L22303-002 | **程式判讀** | **難度：中級** | **對應 L22303**

下列程式繪製各分行的客戶滿意度（滿分 100，實際值介於 96 至 98 之間）。其主要問題為何？

```
1 ax.bar(branches, scores)
2 ax.set_ylim(95.5, 98.5)
```

- (A) 沒有問題，縮小範圍可看清細微差異
- (B) 長條圖截斷 Y 軸會使 96 與 98 的差距在視覺上被放大數倍，構成誤導；長條圖應從 0 起，若需強調細微差異應改用點圖或明確標示截斷
- (C) 應改用 set_xlim
- (D) 應加上 set_yscale('log') 即可解決

答案與逐項解析

答案：B

- (A) × 「看清細微差異」的需求是合理的，但用**長條圖**搭配截斷軸是錯誤手段——長條圖以**長度**編碼數值，截斷後長度比例不再等於數值比例。
- (B) ✓ **正解**。96 與 98 的實際差距是 2 分（約 2%），但在 95.5 至 98.5 的軸上，長條長度差距可達數倍，嚴重誇大。若確實要強調細微差異，應改用**點圖**（以位置而非長度編碼）或明確標示軸已截斷。
- (C) × X 軸是類別軸，與此問題無關。
- (D) × 對數尺度用於處理跨數量級的資料；本例數值範圍極窄，取對數毫無幫助，反而更難解讀。

干擾項設計理由：(A) 提出了一個真實存在的分析需求，測試考生能否區分「需求合理」與「手段正確」。

延伸考點：編碼通道的精確度排序大致為：位置 > 長度 > 角度 > 面積 > 顏色深淺。這解釋了為何長條圖優於圓餅圖，也解釋了為何強調細微差異時點圖（位置編碼）比截斷的長條圖更誠實。

模擬題 SIM-L22303-003 | **情境題** | **難度：中級** | **對應 L22303**

某分析師需在儀表板中呈現 2 億筆交易的「金額與交易時長」關係。直接繪製散布圖導致瀏覽器停止回應。下列處置何者最為適當？

- (A) 提高前端機器規格，即可繪製完整散布圖
- (B) 在伺服器端先以六角形分箱彙總密度，或採分層抽樣後繪製，並提供鑽取查看細節

- (C) 隨機刪除 99% 的資料後直接繪製，不需說明
(D) 改用長條圖呈現

答案與逐項解析

答案：B

- (A) × 這是架構問題而非硬體問題。即使能畫出來，2 億個重疊的點也無法閱讀——過度繪製會讓密集區變成一團實心色塊。
(B) ✓ **正解**。分箱在保留密度資訊的同時大幅降低繪製元素數量；分層抽樣則確保各區間都有代表性。搭配鑽取可在需要時查看明細，符合「先總覽、再篩選、最後細節」的原則。
(C) × 隨機抽樣本身可行，但**不說明**即構成資訊揭露不足；且對稀有但重要的高額交易，簡單隨機抽樣容易全部漏掉，應採分層抽樣。
(D) × 長條圖無法表達兩個連續變數之間的關係。

延伸考點：大規模視覺化的核心思維是**把運算留在資料端**——傳到前端的應該是彙總後的少量資料，而非原始明細。這與 Chapter 5 的欄式儲存、述詞下推是同一套邏輯。

模擬題 SIM-L22303-004 | 治理題 | 難度：中級 | 對應 L22303

某銀行的模型監控儀表板呈現「整體核准率」與「整體誤判率」兩條趨勢線，數值皆穩定良好。稽核人員認為此呈現不足以支持公平性宣稱。下列理由何者最為適當？

- (A) 應改用 3D 圖表以增加資訊量
(B) 整體平均會掩蓋子群差異；公平性檢視應以各群體**並列**呈現核准率與誤判率，並揭露群間差距
(C) 應將 Y 軸截斷以放大變化，讓趨勢更明顯
(D) 應只呈現表現最佳的季度，以增強說服力

答案與逐項解析

答案：B

- (A) × 3D 效果扭曲感知，且不解決「缺少分群資訊」的核心問題。
(B) ✓ **正解**。整體良好而某一子群顯著較差，正是彙總數字所掩蓋的典型問題。公平性檢視必須分群並列。
(C) × 截斷軸屬誤導手法，在對稽核揭露的場景中尤其不當。
(D) × 只呈現有利期間屬選擇性揭露，可能構成不實陳述。

干擾項設計理由：(C)(D) 兩者都是「讓數字更好看」的手法，正是治理場景中應被明確禁止者。

延伸考點：分群呈現時須留意**小樣本格的再識別風險**——某子群僅數人時，公開其核准率可能反推個體。實務上設定最小顯示門檻或合併相近群組。此議題與 L22404 的去識別化相通。

9.7 章末複習

9.7.1 一頁重點

主題	必記結論
選型	比較用長條、趨勢用折線、分布用箱型或直方、關係用散布

主題	必記結論
圓餅圖	類別 超過 5 個 即不適用
誠信	長條圖 Y 軸須從 0 起 ；雙軸慎用；避免 3D；對數須標示
可及性	不可僅以紅綠傳達關鍵資訊
效能	伺服器端預彙總 > 抽樣 > 分箱；先總覽再篩選再細節
治理	公平性須 分群並列 ；注意小樣本格再識別
編碼精確度	位置 > 長度 > 角度 > 面積 > 顏色

9.7.2 必背名詞

截斷軸、雙 Y 軸、資料墨水比、面量圖（Choropleth）、六角形分箱、過度繪製（Overplotting）、物化視圖、色彩可及性、小樣本格。

9.7.3 五分鐘快速複習

1. 說出長條圖 Y 軸的鐵律與其理由。
2. 說出圓餅圖的類別數上限。
3. 說出三種大規模視覺化的效能策略。
4. 說出公平性儀表板為何不能只看整體平均。

9.7.4 跨章連結

Chapter 1：箱型圖與分布；Chapter 8：分群結果呈現；第 I 冊 L21302：模型監控儀表板；L23 之 L23402：公平性指標。

來源與稽核紀錄

官方來源：IPAS-SCOPE-11502（L22303 備註欄「資訊呈現的原則、圖表類型的選擇以及視覺化效能」）；IPAS-GUIDE-L22（頁碼 **PENDING**）。

政府文件：GOV-FSC-AI（行政規則／指引）、GOV-PDPA（法律）。查核日 中華民國 115 年 8 月 1 日。

編者推論／延伸：圖表選型表、五條誠信規則、效能策略表、編碼精確度排序、四題模擬題與干擾項設計。

未解決資料缺口：學習指引頁碼；中級勘誤表完整條目。

Part IV

L224 大數據在人工智慧之應用

大數據與機器學習

章節識別卡

官方代碼	L22401
官方名稱	大數據與機器學習
官方備註	大數據特性對機器學習演算法產生的底層影響與挑戰
所屬	L22 / L224 大數據在人工智慧之應用
授證路線	DATA_ANALYSIS
資料截止日	中華民國 115 年 8 月 1 日
層級分布	核心必考 80% 官方補充 20% 政府實務 0% 產業延伸 0%
先備知識	L221-L223；NumPy 陣列運算
建議時數	1.5 小時
本版題數	模擬題 2 題（含程式判讀 1 題）
備註	兩場次官方命題僅 1 題，屬 概念收尾章 ，理解即可

學習目標

1. 說明 5V 特性各自對機器學習造成的具體挑戰與對應技術。
2. 說明維度詛咒的成因與緩解手段。
3. 判讀 NumPy 的形狀與聚合軸。

考綱對位

代碼	官方主題	本章節點	正式題	程式題	政府文件
L22401	大數據與機器學習	5V 對 ML 的底層影響	見索引	無	—
L22401	同上	分散式訓練與抽樣	見索引	無	—
L22401	同上	維度詛咒與緩解	見索引	有	—

10.1 核心概念與技術原理

10.1.1 5V 對機器學習的具體衝擊

核心必考

特性	對 ML 的挑戰	對應技術
Volume（量）	資料無法載入單機記憶體；訓練時間過長	分散式訓練（資料平行／模型平行）、增量學習、抽樣策略
Velocity（速度）	模型很快過時；須即時特徵	串流特徵計算、線上學習、特徵存放區的線上離線一致性
Variety（多樣性）	結構化與非結構化混合	多模態模型、湖倉架構、統一綱要管理
Veracity（真實性）	標籤雜訊、感測異常、重複紀錄	資料驗證管線、雜訊穩健損失、主動學習
Value（價值）	資料多但訊號稀疏	特徵選擇、領域知識、因果分析

資料多不等於效果好

在訊號稀疏的情況下，增加樣本量對效能的邊際貢獻會迅速遞減；此時真正有效的是**增加有用的特徵或改善標籤品質**，而非繼續堆資料量。

判斷方法是看**學習曲線**：若訓練誤差與驗證誤差都高且已收斂在一起，加更多資料**沒有用**，須改用更複雜的模型或更好的特徵。

10.1.2 分散式訓練的兩種切法

官方補充

- **資料平行**：每個節點放一份完整模型、處理不同批資料，再同步梯度。最常用，適合模型放得進單機的情況。
- **模型平行**：模型太大放不進單機，把模型不同層或不同部分切到不同節點。通訊成本高。

10.1.3 維度詛咒

核心必考

特徵數增加時，資料在高維空間中變得極度稀疏，任兩點的距離趨於相近，使**基於距離的方法**（KNN、K-Means）失效，且達到相同資料密度所需的樣本量呈指數成長。

緩解手段：特徵選擇（過濾式／包裹式／嵌入式）、降維（PCA）、正則化、以及改用對高維較穩健的模型（樹模型、加強正則化的線性模型）。

10.2 程式判讀重點

核心必考

形狀與聚合軸

```

1 X.shape # (1000, 20) -> 1000 列樣本、20 個特徵
2 X.mean(axis=0) # 沿「列」方向壓縮 -> 每個特徵的平均，形狀 (20,)
3 X.mean(axis=1) # 沿「欄」方向壓縮 -> 每個樣本的平均，形狀 (1000,)
4 X - X.mean(axis=0) # 廣播：(1000,20) - (20,) -> 逐特徵中心化，合法
5 X - X.mean(axis=1) # 錯誤：(1000,20) - (1000,) 形狀不相容

```

必考：`axis=0` 是「沿著第 0 軸做聚合」，結果會**消掉列**而留下欄——即得到**各特徵**的統計量。這是特徵標準化最常用的軸。廣播規則要求尾端維度相容，`axis=1` 的結果需 `reshape(-1,1)` 才能相減。

10.3 常見陷阱與錯誤觀念

常見陷阱與錯誤觀念

- 以為資料量越大效果一定越好。訊號稀疏時邊際貢獻迅速遞減。
- 在高維空間用距離型演算法。維度詛咒下距離失去鑑別力。
- 混淆 `axis=0` 與 `axis=1`。特徵標準化用 `axis=0`。
- 忽略 Veracity。標籤雜訊會設下效能天花板，再多資料也突破不了。
- 把分散式訓練當成萬靈丹。通訊成本可能抵銷平行帶來的加速。

10.4 正式公告試題索引

本章命題密度

兩場次正式公告試題（114 年第二次、115 年第一次）之 L22 科目共 100 題，其中對位至本代碼者 1 題，佔 1%。

本索引之 L 代碼為**編者對位**，非官方逐題分類；官方答案則照錄官方公告。

題目 ID	場次	官方答案	原卷頁次	含圖表	對位備註
OFFICIAL-115-1-L22-Q30	115-1	B	p.9	—	—

著作權處理與使用方式

官方試題為受著作權保護之著作。本書**不重製**官方題幹與選項全文，僅提供**題目 ID、場次、官方答案、原卷頁次與考綱對位**。

請依上表之**原卷頁次**，至 iPAS 官網「AI 應用規劃師 → 學習資源」下載該場次公告試題 PDF 對照閱讀；本章前述之核心概念、決策表與陷阱清單即為該批題目的考點拆解。

10.5 自編模擬題

模擬題 SIM-L22401-001 | 程式判讀 | 難度：中級 | 對應 L22401

`X` 為形狀 (1000, 20) 的 NumPy 陣列（1000 個樣本、20 個特徵）。若欲對**每個特徵**做中心化，下列何者正確？

- (A) `X - X.mean(axis=1)`
- (B) `X - X.mean(axis=0)`
- (C) `X - X.mean()`
- (D) `X.mean(axis=0) - X`

答案與逐項解析

答案：B

- (A) × $\text{axis}=1$ 得到形狀 (1000,)，是每個樣本的平均；與 (1000,20) 相減會因廣播規則不相容而報錯。
 (B) ✓ **正解**。 $\text{axis}=0$ 沿列方向聚合，得到形狀 (20,) 的各特徵平均；廣播後與每一列相減，達成逐特徵中心化。
 (C) × 不指定軸會得到全域單一平均值（純量），所有特徵減去同一個數，不是逐特徵中心化。
 (D) × 順序顛倒，得到的是負的中心化結果。

延伸考點：記憶法—— $\text{axis}=0$ 消掉列留下欄，因此得到「每欄（每個特徵）」的統計量； $\text{axis}=1$ 消掉欄留下行，得到「每行（每個樣本）」的統計量。標準化、PCA、特徵縮放一律用 $\text{axis}=0$ 。若真要用 $\text{axis}=1$ 的結果相減，須先 `reshape(-1, 1)`。

模擬題 SIM-L22401-002 | 診斷題 | 難度：中級 | 對應 L22401

某團隊的模型在 100 萬筆資料上訓練誤差與驗證誤差皆偏高且兩者接近。主管建議「再蒐集 500 萬筆資料」。下列評論何者最為適當？

- (A) 建議正確，資料量是模型效能最主要的決定因素
 (B) 兩條誤差曲線皆高且已收斂，屬高偏差（欠擬合）；增加資料量幫助有限，應改用更複雜的模型或增加更有資訊量的特徵
 (C) 應直接增加特徵數量至數千維，維度越高模型表達力越強
 (D) 應改用距離型演算法以充分利用大量資料

答案與逐項解析

答案：B

- (A) × 資料量的邊際貢獻取決於目前的瓶頸是偏差還是變異。
 (B) ✓ **正解**。訓練與驗證誤差皆高且接近是高偏差的典型徵狀——模型連訓練資料都學不好，再餵更多同類資料仍學不好。正確方向是提高模型複雜度、增加特徵，或減少正則化強度。
 (C) × 盲目增加維度會觸發**維度詛咒**：資料稀疏化、距離失效、所需樣本量指數成長，且過擬合風險升高。應增加的是**有資訊量**的特徵而非數量。
 (D) × 距離型演算法在高維與大規模資料上的表現與效率都更差。

延伸考點：學習曲線診斷法——兩線都高且收斂 → 高偏差，加資料無用；兩線間距大且未收斂 → 高變異，加資料有用。這個判斷直接決定「花錢買資料」還是「花時間換模型」，是規劃師的關鍵決策。此議題於 L23101 有完整處理。

10.6 章末複習

10.6.1 一頁重點

主題	必記結論
5V	Volume / Velocity / Variety / Veracity / Value 各有對應技術
資料量	高偏差時加資料 無用 ；看學習曲線決定
分散式訓練	資料平行（常用）／模型平行（模型太大時）

主題	必記結論
維度詛咒	距離失效、樣本需求指數成長；以特徵選擇、降維、正則化緩解
NumPy 軸	axis=0 得各特徵統計量（標準化用它）

10.6.2 必背名詞

5V、資料平行、模型平行、增量學習、維度詛咒、特徵選擇、學習曲線、高偏差、高變異。

10.6.3 五分鐘快速複習

1. 說出 5V 各自對 ML 的挑戰。
2. 說出何時「加更多資料」是無效的。
3. 說出 axis=0 與 axis=1 的差異。

10.6.4 跨章連結

Chapter 6：分散式運算的執行環境；Chapter 7：降維與特徵工程；Chapter 11：鑑別式任務的實際應用；L23 之 L23101：偏差-變異分解。

來源與稽核紀錄

官方來源：IPAS-SCOPE-11502（L22401 備註欄）；IPAS-GUIDE-L22（頁碼 **PENDING**）。

編者推論／延伸：5V 對照表、學習曲線診斷、程式判讀、二題模擬題與干擾項設計。

未解決資料缺口：學習指引頁碼；中級勘誤表完整條目。

大數據在鑑別式 AI 中的應用

章節識別卡

官方代碼	L22402
官方名稱	大數據在鑑別式 AI 中的應用
官方備註	大數據應用於預測、分類等鑑別式任務
所屬	L22 / L224 大數據在人工智慧之應用
授證路線	DATA_ANALYSIS
資料截止日	中華民國 115 年 8 月 1 日
層級分布	核心必考 80% 官方補充 20% 政府實務 0% 產業延伸 0%
先備知識	Chapter 10；監督式學習概念
建議時數	1.5 小時
本版題數	模擬題 3 題（含程式判讀 1 題）

學習目標

1. 區分鑑別式與生成式 AI 的學習目標。
2. 說明時間點正確性，並診斷時間洩漏。
3. 規劃典型鑑別式任務的資料需求。

考綱對位

代碼	官方主題	本章節點	正式題	程式題	政府文件
L22402	大數據在鑑別式 AI 中的應用	鑑別式與生成式之分野	見索引	無	—
L22402	同上	典型應用場景與資料需求	見索引	無	—
L22402	同上	時間點正確性與時間洩漏	見索引	有	—

11.1 核心概念與技術原理

11.1.1 鑑別式與生成式的分野

核心必考

鑑別式 AI 學習 $P(Y|X)$ ，也就是給定輸入後判斷類別或數值的決策邊界；生成式 AI 學習 $P(X)$ 或 $P(X|條件)$ ，即資料分布本身。

大規模資料對鑑別式模型的主要價值有三：涵蓋更多長尾情境、支撐更細的分群個人化、以及讓複雜模型不至於過擬合。

11.1.2 典型場景與共同資料需求

官方補充

信用風險評分、客戶流失預測、需求預測、詐欺偵測、精準行銷、預測性維護。
共同的資料需求是長時間跨度的標籤與時間點正確的特徵。

11.1.3 時間點正確性

核心必考

本章核心考點

時間點正確性（Point-in-time Correctness）：建模時只能使用**預測時點之前**已知的資訊。

判斷口訣：對每一個特徵問「在做出預測的那一刻，這個欄位的值已經存在了嗎？」答案為否者一律剔除。

典型的時間洩漏：以「催收次數」預測違約（催收發生在違約之後）；以「已核准金額」預測是否核准；以「結案狀態」預測是否結案；以「客戶終身價值」預測本季購買（終身價值涵蓋了未來）。

另一種隱蔽的時間洩漏

使用**當前快照**的維度表也會洩漏。例如以「客戶目前的信用等級」預測一年前的違約——該等級可能正是因為違約才被調降的。正確作法是使用**歷史版本**的維度資料（慢變維），或明確記錄每個欄位的有效時間區間。

11.2 程式判讀重點

核心必考

時序切分：不可隨機

```
1 # 錯誤：隨機切分時序資料 -> 用未來預測過去
2 X_tr, X_te = train_test_split(X, test_size=0.2, shuffle=True)
3
4 # 正確：依時間切分
5 cutoff = '2025-07-01'
6 train = df[df['event_date'] < cutoff]
7 test = df[df['event_date'] >= cutoff]
```

必考：train_test_split 的 shuffle 預設為 True。時序資料必須設 shuffle=False 或改用時間切分，否則測試指標必然虛高。

11.3 常見陷阱與錯誤觀念

常見陷阱與錯誤觀念

- **時間洩漏**。離線指標好到不真實時的第一嫌疑。
- **時序資料隨機切分**。shuffle 預設為 True。
- **使用當前快照的維度表**。須用歷史版本。
- **忽略標籤延遲**。違約標籤可能數月後才確定，建模的觀察期與表現期須明確定義。

- 把鑑別式與生成式混談。前者學決策邊界，後者學資料分布。

11.4 正式公告試題索引

本章命題密度

兩場次正式公告試題（114 年第二次、115 年第一次）之 L22 科目共 100 題，其中對位至本代碼者 6 題，佔 6%。

本索引之 L 代碼為**編者對位**，非官方逐題分類；官方答案則照錄官方公告。

題目 ID	場次	官方答案	原卷頁次	含圖表	對位備註
OFFICIAL-115-1-L22-Q23	115-1	C	p.7	是	須對照原卷圖表
OFFICIAL-115-1-L22-Q33	115-1	A	p.10	—	—
OFFICIAL-115-1-L22-Q35	115-1	D	p.10	—	—
OFFICIAL-115-1-L22-Q43	115-1	C	p.14	是	須對照原卷圖表
OFFICIAL-115-1-L22-Q44	115-1	A	p.14-15	—	—
OFFICIAL-115-1-L22-Q50	115-1	D	p.17	是	須對照原卷圖表

著作權處理與使用方式

官方試題為受著作權保護之著作。本書**不重製**官方題幹與選項全文，僅提供**題目 ID、場次、官方答案、原卷頁次與考綱對位**。

請依上表之**原卷頁次**，至 iPAS 官網「AI 應用規劃師 → 學習資源」下載該場次公告試題 PDF 對照閱讀；本章前述之核心概念、決策表與陷阱清單即為該批題目的考點拆解。

11.5 自編模擬題

模擬題 SIM-L22402-001 | 診斷題 | 難度：中級 | 對應 L22402

某電商建置「本月是否會流失」預測模型，測試 AUC 高達 0.98。特徵清單包含「本月客服申訴次數」「本月退貨金額」「帳號目前狀態」。下列判斷何者最為適當？

- (A) 指標優異，代表特徵工程成功
- (B) 三項特徵均可能發生在流失判定的**同時或之後**，屬時間洩漏；應僅使用預測時點之前已知的資訊重新評估
- (C) 應再增加更多特徵以提升 AUC
- (D) AUC 過高代表模型過於簡單

答案與逐項解析

答案：B

(A) × 離線指標**好到不真實**正是洩漏的警訊。

(B) ✓ **正解**。「本月申訴」「本月退貨」與流失可能同時發生甚至是流失的結果；「帳號目前狀態」更是明顯的當前快照——若客戶已流失，狀態欄位早已反映。三者預測時點都不可得。

(C) × 在洩漏未排除前增加特徵只會讓問題更難察覺。

(D) × 兩者無因果關係。

延伸考點：正確作法是明確定義**觀察期**（用來計算特徵的時間窗）與**表現期**（用來判定標籤的時間窗），兩者不得重疊。例如「以 1-3 月的行為預測 4-6 月是否流失」。

模擬題 SIM-L22402-002 | 程式判讀 | 難度：中級 | 對應 L22402

下列程式用於切分三年份的每日銷售資料以訓練需求預測模型。其問題為何？

```
X_tr, X_te, y_tr, y_te = train_test_split(X, y, test_size=0.2, random_state=42)
```

(A) 沒有問題，隨機切分可避免選擇偏誤

(B) **shuffle** 預設為 **True**，會把未來日期的資料混入訓練集而過去日期進入測試集，等於用未來預測過去；時序資料應依時間切分

(C) 應把 **random_state** 改為 **None**

(D) 應把 **test_size** 改為 0.3

答案與逐項解析

答案：B

(A) × 隨機切分適用於獨立同分布資料；時序資料的樣本之間有時間依賴，隨機切分會造成資訊從未來流向過去。

(B) ✓ **正解**。**train_test_split** 的 **shuffle** 預設為 **True**。時序資料應設 **shuffle=False**（取後段為測試集）或直接依日期切分；若需交叉驗證則用前向鏈式切分。

(C) × **random_state** 只影響隨機種子的可重現性，不改變隨機切分本身。

(D) × 切分比例與此問題無關。

干擾項設計理由：(C)(D) 都是「調參數」式的回應，用來測試考生是否抓到問題出在切分方式而非參數值。

延伸考點：時序驗證還須注意**間隔期**（gap）——若特徵計算需要 7 天的回看窗，訓練集結束與測試集開始之間應留 7 天空隙，避免測試期的特徵使用到訓練期末的資料。

模擬題 SIM-L22402-003 | 觀念題 | 難度：基礎 | 對應 L22402

下列何者屬於**鑑別式 AI** 的典型任務？

(A) 由文字描述生成商品圖片

(B) 依客戶歷史交易預測其下季是否流失

(C) 依既有語料續寫一段文案

(D) 由少量樣本合成新的訓練影像

答案與逐項解析

答案：B

(A) × 文生圖屬生成式，學習的是資料分布。

(B) ✓ **正解**。給定輸入特徵判斷「是否流失」的二元分類，學習的是 $P(Y|X)$ 的決策邊界，屬鑑別式。

(C) × 續寫文案屬生成式。

(D) × 合成訓練影像（資料增強或生成）屬生成式。

延伸考點：兩者可搭配使用——以生成式模型**合成少數類樣本**改善鑑別式模型的不平衡問題，即為典型組合。但須留意合成樣本的真實性，以及合成後模型輸出機率的校準問題（見 Chapter 8）。

11.6 章末複習

11.6.1 一頁重點

主題	必記結論
分野	鑑別式學 $P(Y X)$ 決策邊界；生成式學 $P(X)$ 資料分布
時間點正確性	只能用預測時點 之前 已知的資訊
時間洩漏	催收、已核准金額、結案狀態、當前快照維度
時序切分	shuffle 預設 True；須依時間切分並留間隔期
觀察期／表現期	兩者 不得重疊

11.6.2 必背名詞

鑑別式 AI、生成式 AI、時間點正確性、時間洩漏、觀察期、表現期、慢變維（Slowly Changing Dimension）、前向鏈式驗證。

11.6.3 五分鐘快速複習

1. 說出鑑別式與生成式各自學什麼。
2. 說出判斷時間洩漏的口訣。
3. 說出時序資料為何不能用預設的 `train_test_split`。

11.6.4 跨章連結

Chapter 12：生成式的對照；Chapter 8：不平衡處理；第 I 冊 L21202：標籤定義與標籤洩漏；L23 之 L23303：時序交叉驗證。

來源與稽核紀錄

官方來源：IPAS-SCOPE-11502（L22402 備註欄）；IPAS-GUIDE-L22（頁碼 **PENDING**）。

編者推論／延伸：時間洩漏例示、觀察期表現期設計、程式判讀、三題模擬題與干擾項設計。

未解決資料缺口：學習指引頁碼；中級勘誤表完整條目。

大數據在生成式 AI 中的應用

章節識別卡	
官方代碼	L22403
官方名稱	大數據在生成式 AI 中的應用
官方備註	生成式模型在處理大規模語料時的技術需求
所屬	L22 / L224 大數據在人工智慧之應用
授證路線	DATA_ANALYSIS
資料截止日	中華民國 115 年 8 月 1 日
層級分布	核心必考 65% 官方補充 20% 政府實務 10% 產業延伸 5%
先備知識	Chapter 10；第 I 冊 L21103（生成式架構）
建議時數	1.5 小時
本版題數	模擬題 2 題
備註	兩場次官方命題僅 1 題，屬概念章，理解即可

學習目標

- 1. 列舉大規模語料處理的六項技術需求。
- 2. 說明語料去重與品質過濾對模型的影響。
- 3. 評估訓練語料的授權與合規風險。

考網對位

代碼	官方主題	本章節點	正式題	程式題	政府文件
L22403	大數據在生成式 AI 中的應用	語料清洗與去重	見索引	無	—
L22403	同上	品質過濾與去毒去偏	見索引	無	—
L22403	同上	授權與來源合規	見索引	無	GOV-PDPA GOV- AI- BASIC-ACT
L22403	同上	繁中語料稀缺與在地化	見索引	無	—

12.1 核心概念與技術原理

12.1.1 大規模語料處理的六項技術需求

核心必考

1. **語料清洗與去重**。重複文本會被模型過度記憶，增加逐字複製與**訓練資料外洩**風險。須做精確去重與近似去重（以雜湊指紋比對相似文件）。
2. **品質過濾**。以分類器或啟發式規則濾除低品質、機器生成、廣告與有害內容。研究普遍顯示**資料品質對模型能力的影響常大於單純增加資料量**。
3. **去毒與去偏**。訓練前過濾仇恨與偏見語料；但**過度過濾會損害模型對相關議題的理解能力**，需權衡。
4. **授權與來源合規**。須確認語料的著作權與使用條款涵蓋 AI 訓練用途。
5. **繁體中文語料稀缺**。中文語料以簡體佔絕對多數，符合台灣用語習慣的高品質繁中語料稀少，是本土模型的核心瓶頸，也是在地化評測必要性的來源。
6. **基礎設施**。訓練需大規模加速器叢集與高速互連；資料須以**分片與串流**方式餵入，不可能一次載入記憶體。

去重為何是第一優先

重複文本帶來三個問題：(1) 模型對重複內容**過度記憶**，可能在生成時逐字吐出，構成訓練資料外洩；(2) 重複樣本等於變相加權，扭曲資料分布；(3) 若重複內容同時出現在訓練與評測集，會使**評測結果虛高**——這是語料層面的資料洩漏。

12.1.2 生成式與鑑別式的資料需求差異

官方補充

	鑑別式	生成式
學習目標	$P(Y X)$ 決策邊界	$P(X)$ 資料分布
標籤需求	需要人工標註	多為自監督，從語料本身構造
資料瓶頸	標註成本、標籤品質	語料規模與品質 、授權合規
洩漏風險	特徵含未來資訊	訓練語料被逐字還原

12.2 常見陷阱與錯誤觀念

常見陷阱與錯誤觀念

- **以為資料量越大越好**。品質過濾的效益常高於單純擴量；低品質語料會拉低模型能力。
- **忽略去重**。造成記憶化、分布扭曲與評測虛高。
- **過度去毒**。模型會連帶失去討論相關議題的能力。
- **假設公開即可自由使用**。公開不等於授權用於 AI 訓練，須檢視條款。
- **以簡體語料訓練後直接服務繁中使用者**。用語習慣、詞彙與法規名詞差異會造成明顯落差。
- **未評估語料中的個資**。大規模爬取的網頁語料可能含個人資料。

12.3 政府指引與產業落地實務

政府指引與產業落地實務

文件	機關	日期	文件性質	本章意義
個人資料保護法	個資主管機關	現行有效	法律	語料中的個資與特定目的
人工智慧基本法	立法院／國科會	114.12.23	法律	隱私保護與資料治理；智慧財產權維護

一、**語料來源的合法性是模型合規的前提**。使用網路爬取或第三方採購資料時，須確認授權範圍涵蓋 AI 訓練用途，避免著作權與契約風險。《人工智慧基本法》亦揭示應致力提升資料品質與數量，並**維護智慧財產權**。

二、**語料中的個資**。大規模爬取的語料可能含個人資料。除於前處理階段過濾外，亦須考量模型**記憶化**後可能在生成時還原的風險——這使得「刪除某人的資料」在模型已訓練完成後極為困難。編者建議在架構設計時即預留可重訓的資料版本管理能力。

三、**在地化評測**。數位發展部推動 AI 評測相關機制，方向包含發展適用於繁體中文與在地情境之評測參考。企業採購或自建生成式 AI 系統時，宜將**繁中在地化評測**納入驗收條件，而非僅引用英文基準分數。**版本敏感**

查證狀態

評測機制之正式名稱、評測項目與具體數量尚未經官方原文查核，本書**不列出**任何項目數或基準名稱。

12.4 正式公告試題索引

本章命題密度

兩場次正式公告試題（114 年第二次、115 年第一次）之 L22 科目共 100 題，其中對位至本代碼者 **1 題**，佔 **1%**。

本索引之 L 代碼為**編者對位**，非官方逐題分類；官方答案則照錄官方公告。

題目 ID	場次	官方答案	原卷頁次	含圖表	對位備註
OFFICIAL-114-2-L22-Q24	114-2	A	p.6-7	—	—

著作權處理與使用方式

官方試題為受著作權保護之著作。本書**不重製**官方題幹與選項全文，僅提供**題目 ID、場次、官方答案、原卷頁次與考綱對位**。

請依上表之**原卷頁次**，至 iPAS 官網「AI 應用規劃師 → 學習資源」下載該場次公告試題 PDF 對照閱讀；本章前述之核心概念、決策表與陷阱清單即為該批題目的考點拆解。

12.5 自編模擬題

模擬題 SIM-L22403-001 | **觀念題** | **難度：中級** | **對應 L22403**

某團隊蒐集了 10 TB 網路文本準備訓練語言模型。下列前處理步驟中，何者對**降低訓練資料外洩風險**最為直接有效？

- (A) 將所有文本轉為小寫並移除標點
- (B) 執行精確去重與近似去重，避免同一段文本反覆出現而被模型過度記憶
- (C) 增加語料總量至 50 TB，以稀釋個別文本的影響
- (D) 提高模型參數量，使記憶分散

答案與逐項解析

答案：B

- (A) × 大小寫與標點的正規化屬基本清理，與記憶化風險無關。
- (B) ✓ **正解**。文本重複次數是記憶化的主要驅動因素——出現越多次，模型越可能逐字複製。去重是最直接的緩解手段，同時也避免分布扭曲與評測虛高。
- (C) × 單純擴量不必然降低特定文本的重複次數；若新增語料同樣含大量重複，風險反而升高。
- (D) × 方向相反——參數量越大，模型記憶訓練資料的能力通常**越強**。

干擾項設計理由：(C)(D) 都利用「規模越大越好」的直覺，但兩者對記憶化風險的作用方向與題幹訴求不符。

延伸考點：降低記憶化風險的手段依有效性排序：**語料去重** → 個資過濾 → 差分隱私訓練 → 輸出端過濾。後兩者成本高，前兩者是必做的基本功。此議題與 Chapter 13 的訓練資料抽取攻擊直接相關。

模擬題 SIM-L22403-002 | **情境題** | **難度：中級** | **對應 L22403**

某公部門委外建置繁體中文客服語言模型。廠商提出以大量簡體中文語料訓練，並宣稱「以英文基準測試分數領先同業」。下列評估何者最為適當？

- (A) 英文基準分數領先即代表模型能力強，可直接採用
- (B) 應要求以繁體中文與在地情境之評測驗收，並確認語料授權涵蓋 AI 訓練用途；簡體語料在用語習慣與法規名詞上與繁中存在落差
- (C) 只要模型能輸出繁體字即無問題
- (D) 應要求廠商公開全部訓練語料，否則不予採用

答案與逐項解析

答案：B

- (A) × 英文基準無法反映繁中在地情境的表現；用語、法規名詞、公文格式的差異都無從檢驗。
- (B) ✓ **正解**。同時指出兩件事：驗收應採**繁中在地化評測**，以及語料**授權合規**須確認。這兩點都是採購階段就該寫入契約的要求。
- (C) × 字形轉換（簡轉繁）不等於用語在地化。「軟件／軟體」「信息／資訊」「質量／品質」的差異在公部門文件中尤其明顯。
- (D) × 要求公開全部訓練語料在商業上通常不可行，也非必要。合理作法是要求廠商提出**授權來源聲明**與合規承諾，並以評測驗收成果。

干擾項設計理由：(D) 立場看似最嚴格，但屬不可行的過度要求，測試考生能否分辨「嚴格」與「可執行」。

延伸考點：公部門採購生成式 AI 另須留意行政院《使用生成式 AI 參考指引》——涉及機密或未公開個資者不得提供予外部生成式 AI 處理，必要時應評估封閉環境部署。此議題於第 I 冊 L21103 有完整處理。

12.6 章末複習

12.6.1 一頁重點

主題	必記結論
六項需求	去重／品質過濾／去毒去偏／授權合規／繁中稀缺／基礎設施
去重	防記憶化、防分布扭曲、防評測虛高
品質 vs 數量	品質影響常大於單純擴量
去毒	過度過濾會損害理解能力，需權衡
合規	公開不等於授權訓練；語料可能含個資
在地化	簡體語料無法直接服務繁中；驗收須用在地評測

12.6.2 必背名詞

語料去重、近似去重、品質過濾、去毒（Detoxification）、記憶化（Memorization）、訓練資料外洩、分片（Sharding）、在地化評測。

12.6.3 五分鐘快速複習

1. 說出去重要解決的三個問題。
2. 說出「品質」與「數量」何者影響較大。
3. 說出去毒過度的副作用。
4. 說出以簡體語料服務繁中使用者的三個風險。

12.6.4 跨章連結

Chapter 11：鑑別式的對照；Chapter 13：訓練資料抽取攻擊與隱私技術；第 I 冊 L21103：生成式架構與幻覺。

來源與稽核紀錄

官方來源：IPAS-SCOPE-11502（L22403 備註欄「生成式模型在處理大規模語料時的技術需求」）；IPAS-GUIDE-L22（頁碼 **PENDING**）。

政府文件：GOV-PDPA（法律）、GOV-AI-BASIC-ACT（法律）。查核日 中華民國 115 年 8 月 1 日。

編者推論／延伸：六項需求整理、去重優先性論述、二題模擬題與干擾項設計。

未解決資料缺口：學習指引頁碼；中級勘誤表完整條目；數位發展部評測機制之正式名稱與項目。

大數據隱私保護、安全與合規

章節識別卡

官方代碼	L22404
官方名稱	大數據隱私保護、安全與合規
官方備註	數據的安全性與法律合規技術
所屬	L22 / L224 大數據在人工智慧之應用
授證路線	DATA_ANALYSIS
資料截止日	中華民國 115 年 8 月 1 日
對應來源	IPAS-SCOPE-11502、IPAS-GUIDE-L22（頁碼 PENDING ）
層級分布	核心必考 50% 官方補充 15% 政府實務 30% 產業延伸 5%
先備知識	Chapter 4、Chapter 5
建議時數	3.0 小時
本版題數	模擬題 4 題（含程式判讀 1 題）
備註	本冊政府指引密度最高之章節

學習目標

1. 比較七種隱私強化技術的保護對象與代價。
2. 說明差分隱私中 ϵ 的意義與隱私效用權衡。
3. 辨識聯邦學習的殘餘風險與非獨立同分布挑戰。
4. 判斷去識別化是否足以脫離個資範疇。
5. 規劃四層資料合規檢核。

考綱對位

代碼	官方主題	本章節點	正式題	程式題	政府文件
L22404	大數據隱私保護、安全與合規	去識別化與 k -匿名性	見索引	有	GOV-PDPA
L22404	同上	差分隱私與 ϵ	見索引	無	—
L22404	同上	聯邦學習與殘餘風險	見索引	無	—
L22404	同上	同態加密、安全多方計算、可信執行環境	見索引	無	—

代碼	官方主題	本章節點	正式題	程式題	政府文件
L22404	同上	四層資料合規檢核	見索引	無	GOV-PDPA GOV-FSC-AI GOV-AI-BASIC-ACT

13.1 核心概念與技術原理

13.1.1 七種隱私強化技術

核心必考

技術	原理	保護對象	代價
去識別化／假名化	移除或替換直接識別欄位	直接識別資訊	仍可能被再識別
k -匿名性	每筆紀錄至少與 $k - 1$ 筆在準識別欄位上無法區分	再識別風險	不防同質性攻擊，故有 l -多樣性、 t -封閉性補強
差分隱私	在查詢結果或訓練梯度中加入校準雜訊，使單一個體的加入與否不影響輸出分布	個體是否在資料集中	ϵ 越小越隱私但準確度損失越大
聯邦學習	資料留在本地，只上傳模型更新至中央聚合	原始資料不出境／不出院	通訊成本；非獨立同分布造成收斂困難
同態加密	直接在密文上運算，解密後結果正確	運算過程中的資料	運算開銷極大
安全多方計算	多方共同計算而不揭露各自輸入	各方私有資料	通訊回合多、延遲高
可信執行環境	硬體隔離的加密記憶體區	執行中的資料	依賴硬體信任、有側信道風險

三組必記對應

「資料不能集中」→ 聯邦學習。
「發布統計結果怕被反推個體」→ 差分隱私。
「多方要共同計算但都不想給對方看」→ 安全多方計算。
三者可疊加使用，並非互斥。

13.1.2 差分隱私的 ϵ

核心必考

ϵ （隱私預算）量化「有無某一個體」對輸出分布的最大影響。

方向性必記

ϵ 越小 = 隱私保護越強 = 雜訊越大 = 效用越低。

這是隱私與效用的**根本性權衡**，無法兩全。實務上 ϵ 常取 1 至 10 之間。

另須注意：隱私預算會隨**查詢次數累加消耗**（組合性）。同一份資料被查詢越多次，累積的 ϵ 越大、實際保護越弱，因此必須有預算管理機制——但許多系統並未實作預算追蹤，形同虛設。

13.1.3 聯邦學習不等於絕對安全**核心必考**

聯邦學習雖不傳輸原始資料，但仍有殘餘風險：

- **梯度可能洩漏資訊**。攻擊者可透過梯度反演部分重建訓練樣本。
- **成員推論攻擊**。判斷某筆特定資料是否曾參與訓練——在醫療場景，光是「這個人的資料在糖尿病研究集中」本身就是敏感資訊。
- 因此實務上聯邦學習常須**疊加安全聚合與差分隱私**才足夠。

另一項挑戰是**非獨立同分布**（Non-IID）：各參與方的資料分布差異大（不同醫院的病患組成、不同設備廠牌），會導致全域模型收斂困難或對少數參與方效果不佳。緩解方向包括調整聚合策略、個人化聯邦學習，或讓各方保留本地微調層。

13.1.4 去識別化的限度**核心必考****常見陷阱與錯誤觀念**

單純移除姓名與身分證字號常**不足以**達成去識別——透過生日、性別、郵遞區號等**準識別欄位**的組合，仍可能唯一定位個人。

是否構成個資法所稱之個人資料，須以**再識別可能性**實質判斷，而非以「已移除姓名」形式認定。

模型本身可能是個資載體

訓練資料可能透過模型被還原（訓練資料抽取攻擊），大型語言模型對**重複出現**的內容尤其如此。這使得「刪除某人的資料」在模型訓練完成後極為困難——目前實務多以**重新訓練**因應，故架構設計時應預留可重訓的資料版本管理能力。

13.2 程式判讀重點**核心必考****去識別化的常見不足**

```
1 df = df.drop(columns=['name', 'national_id']) # 只移除直接識別欄位
2 # 仍保留：birth_date、gender、zipcode -> 準識別欄位組合可能唯一定位個人
3 df['birth_year'] = df['birth_date'].dt.year # 泛化：日 -> 年
4 df['zip3'] = df['zipcode'].astype(str).str[:3] # 泛化：完整郵遞區號 -> 前三碼
5 grp = df.groupby(['birth_year', 'gender', 'zip3']).size()
6 print((grp < 5).sum()) # 檢查有多少組合的人數少於 k=5
```

必考：drop 直接識別欄位不等於去識別化。應進一步對準識別欄位做泛化或抑制，並驗證每個組合的人數是否達到 k 的門檻。

13.3 常見陷阱與錯誤觀念

常見陷阱與錯誤觀念

- 「已去識別化」常是假象。準識別欄位組合仍可再識別。
- 把 ε 的方向記反。 ε 越小保護越強、效用越低。
- 以為聯邦學習就安全。梯度反演與成員推論攻擊仍存在。
- 忽略隱私預算的累加。多次查詢會耗盡預算。
- 以為加密等於合規。加密保護機密性，不解決蒐集目的、告知同意、保存期限等法遵義務。
- 忽略非獨立同分布。聯邦學習在各方資料異質時可能對少數參與方效果極差。
- 以為刪除資料庫紀錄就完成刪除。模型權重可能已記憶該資料。

13.4 政府指引與產業落地實務

四層資料合規檢核

文件	機關	日期	文件性質	本章意義
個人資料保護法	個資主管機關	現行有效	法律	特定目的、告知義務、當事人權利、國際傳輸、安全維護
人工智慧基本法	立法院／國科會	114.12.23	法律	隱私保護與資料治理原則
金融業運用人工智慧 (AI) 指引	金管會	113.06.20	行政規則／指引	資料最小化、委外與第三方風險管理
金融機構運用人工智慧技術作業規範	銀行公會（金管會同意備查）	113.03.14	行政規則／指引（公會自律規範）	客戶資料保護之具體作業要求
人工智慧風險分類框架 v1.0	數位發展部	115.07.07	參考手冊	風險識別之三大類 20 項子類型

第一層：法源。《個人資料保護法》規範蒐集、處理、利用之特定目的與法定事由、告知義務、當事人權利（查閱、更正、刪除、停止處理）、國際傳輸限制與安全維護義務。《人工智慧基本法》七大原則中之「隱私保護與資料治理」，其精神在於避免不必要之個資蒐集處理利用，並促進將個資保護納入預設與設計。

第二層：行業。金管會《金融業運用 AI 指引》就資料最小化與客戶權益保護有所要求，並要求將第三方 AI 服務納入**委外及第三方風險管理**（屬主管機關期待，受規範對象依適用法規辦理）。銀行公會之作業規範就客戶資料保護訂有更具體之要求，性質為**同業公會自律規範經備查**，拘束會員機構。

第三層：技術。編者建議依資料敏感度選擇隱私強化技術——內部分析可用去識別化加存取控制；跨機構合作以**聯邦學習**避免資料集中；統計發布以**差分隱私**防再識別；極敏感運算考慮可信執行環境或安全多方計算。技術選擇的成本應在導入評估階段即納入總持有成本（見第 I 冊 L21201）。

第四層：治理。建立資料分級、資料血緣、保存與刪除政策、跨境傳輸清單，並**定期複評**。《人工智慧風險分類框架》第四步驟「應對風險」即要求定期評估、檢討及修正；其風險類型表所列三大類（AI 系統本身之技術設計缺陷／部署後操作及人機互動問題／社會結構與環境衝擊）中，資料相關風險可能同時落在前兩類。

查證狀態

《人工智慧風險分類框架》所列 **20 項風險子類型之逐項名稱**尚未經原文逐條核對，本書僅陳述三大類與總項數，不列出個別子類型名稱。

13.5 正式公告試題索引

本章命題密度

兩場次正式公告試題（114 年第二次、115 年第一次）之 L22 科目共 100 題，其中對位至本代碼者 **5 題**，佔 **5%**。

本索引之 L 代碼為**編者對位**，非官方逐題分類；官方答案則照錄官方公告。

題目 ID	場次	官方答案	原卷頁次	含圖表	對位備註
OFFICIAL-114-2-L22-Q13	114-2	D	p.3-4	—	—
OFFICIAL-114-2-L22-Q20	114-2	D	p.5-6	—	—
OFFICIAL-114-2-L22-Q32	114-2	A	p.9	—	—
OFFICIAL-115-1-L22-Q37	115-1	A	p.11	—	—
OFFICIAL-115-1-L22-Q38	115-1	B	p.11-12	—	—

著作權處理與使用方式

官方試題為受著作權保護之著作。本書**不重製**官方題幹與選項全文，僅提供**題目 ID、場次、官方答案、原卷頁次與考綱對位**。

請依上表之**原卷頁次**，至 iPAS 官網「AI 應用規劃師 → 學習資源」下載該場次公告試題 PDF 對照閱讀；本章前述之核心概念、決策表與陷阱清單即為該批題目的考點拆解。

13.6 自編模擬題

模擬題 SIM-L22404-001 | 情境題 | 難度：整合 | 對應 L22404

三家醫學中心欲共同訓練罕見疾病影像判讀模型。依法規與院內政策，病歷影像不得離開各院區；同時各院的病患族群組成與造影設備廠牌差異明顯。下列技術架構何者最為適當？

- (A) 各院將影像去識別化後上傳至共用雲端儲存空間集中訓練
- (B) 採聯邦學習架構，各院於本地訓練後僅上傳模型更新，並輔以安全聚合與差分隱私；同時針對各院資料非獨立同分布的問題調整聚合策略
- (C) 採用同態加密，將全部影像加密後上傳雲端進行深度學習訓練
- (D) 由其中一家醫院訓練模型後，將模型權重分享給另兩家直接使用，不需任何調整

答案與逐項解析

答案：B

- (A) × 直接違反「影像不得離開院區」的硬性限制。且醫學影像的去識別化困難（影像標頭資訊、頭部影像可三維重建臉部），去識別化不等於可自由外傳。
- (B) ✓ **正解**。完整對應題幹兩項限制：資料不出院 → 聯邦學習；梯度可能洩漏訓練樣本 → 疊加安全聚合與差分隱私；各院族群與設備差異 → 明確處理非獨立同分布問題。
- (C) × 同態加密的運算開銷極大，目前尚不足以支撐深度學習模型的完整訓練；且此方案仍需將（加密的）影像上傳，與「不得離開院區」的精神有落差。
- (D) × 這只是模型分享而非協同訓練，無法利用另兩院的資料提升罕病樣本量；且因設備與族群差異存在領域偏移，直接套用效能會顯著下降。

干擾項設計理由：(C) 提出了一個技術上「聽起來最安全」的方案，測試考生是否了解其可行性限制。

延伸考點：聯邦學習的兩大實務難題為 **Non-IID**（資料異質）與**系統異質**（各方算力與網路差異造成的落後者問題）。醫療 AI 另須留意屬醫療器材管理範疇，且依《人工智慧風險分類框架》涉及生命安全法益。

模擬題 SIM-L22404-002 | 觀念題 | 難度：中級 | 對應 L22404

關於差分隱私之敘述，下列何者正確？

- (A) ϵ 越大代表隱私保護越強、加入的雜訊越多
- (B) ϵ 越小代表隱私保護越強、雜訊越大、資料效用越低；且隱私預算會隨查詢次數累加消耗
- (C) 差分隱私可在不損失任何準確度的前提下完全消除再識別風險
- (D) 只要使用差分隱私，即可免除個資法上的所有義務

答案與逐項解析

答案：B

- (A) × 方向完全相反。 ϵ 是「有無某個體對輸出分布的最大影響上限」，值越大代表允許的影響越大、保護越弱。
- (B) ✓ **正解**。同時涵蓋方向性與**組合性**——多次查詢會累加消耗隱私預算，這是實務上最常被忽略的性質。
- (C) × 隱私與效用是**根本性權衡**，不存在「零損失」的方案。

(D) × 技術措施不免除法遵義務。蒐集目的、告知同意、保存期限等要求不因採用某項技術而消失。

干擾項設計理由：(A) 針對方向記反；(C)(D) 針對「用了先進技術就沒事」的心態。

延伸考點：實務上 ε 常取 1 至 10 之間，但沒有放諸四海皆準的「安全值」——須依資料敏感度、查詢次數與可接受的效用損失共同決定，並書面記錄選擇理由以供稽核。

模擬題 SIM-L22404-003 | **程式判讀** | **難度：中級** | **對應 L22404**

某團隊執行下列程式後宣稱資料「已完成去識別化，可自由提供予外部分析」。下列評論何者最為適當？

```
1 df = df.drop(columns=['name', 'national_id', 'phone'])
2 df.to_csv('anonymized.csv')
```

- (A) 正確，直接識別欄位已全部移除
- (B) 移除直接識別欄位不等於去識別化；剩餘的準識別欄位（如生日、性別、郵遞區號）組合仍可能唯一定位個人，須進一步泛化或抑制並驗證 k -匿名性
- (C) 應改用 `df.replace()` 將姓名替換為隨機字串即可
- (D) 只要檔案加密儲存即可視為去識別化

答案與逐項解析

答案：B

- (A) × 這是實務上最常見的誤判。是否仍屬個人資料，應以**再識別可能性**實質判斷。
- (B) ✓ **正解**。正確流程是：移除直接識別欄位 → 辨識準識別欄位 → 泛化（生日改為年、郵遞區號取前三碼）或抑制 → 驗證每個準識別組合的人數是否達到 k 的門檻。
- (C) × 以隨機字串替換屬**假名化**，若保有對照表仍可還原，且未處理準識別欄位問題。
- (D) × 加密保護的是**機密性**（未經授權者看不到），與去識別化（授權者看到也無法識別個人）是不同層次的措施。

干擾項設計理由：(C)(D) 分別代表「假名化＝匿名化」與「加密＝去識別」兩種常見混淆。

延伸考點： k -匿名性不防**同質性攻擊**——若某個 k -匿名群組內所有人的疾病欄位都相同，攻擊者不需區分個體也能得知該群任一成員的病況。補強方法為 l -多樣性（敏感欄位須有足夠多樣性）與 t -封閉性（群內分布須接近整體分布）。

模擬題 SIM-L22404-004 | **法遵題** | **難度：整合** | **對應 L22404**

某銀行擬將客戶交易資料提供予境外雲端服務商進行模型訓練。下列評估何者最為適當？

- (A) 只要與服務商簽署保密協議，即可自由傳輸客戶資料
- (B) 須確認是否符合個資法關於國際傳輸之規定與主管機關限制，並將第三方 AI 服務納入委外及第三方風險管理，含資料留存地點、加密方式、次委外揭露與退場機制；亦應評估以聯邦學習或地端部署替代
- (C) 因資料已去識別化，故不受任何規範拘束
- (D) 因金管會指引僅為監理期待而非法律，銀行可自行決定是否遵循

答案與逐項解析

答案：B

(A) × 保密協議屬契約層面的風險移轉，無法免除機構本身的法遵義務與委外監督責任。

(B) ✓ **正解**。完整涵蓋三個層次：法源（個資法之國際傳輸限制）、行業（金管會指引之委外與第三方風險管理）、技術（以聯邦學習或地端部署作為替代方案）。

(C) × 去識別化的程度須以再識別可能性實質判斷；且即使確實去識別，仍可能受營業秘密、契約與行業規範拘束。

(D) × 指引屬行政規則／指引，對受監理對象具拘束力。「非法律」不等於「可自行決定是否遵循」。

干擾項設計理由：(D) 針對「指引＝建議＝可不理會」的誤讀，是法規題最常見的失分點。

延伸考點：此題整合了第 I 冊 L21201（自建／採購決策與委外風險）與 L21302（雲端環境建置）。實務上的常見解法是**混合策略**——通用任務使用外部服務，涉及客戶資料的敏感任務採地端或聯邦架構。

13.7 章末複習

13.7.1 一頁重點

主題	必記結論
三組對應	不能集中 → 聯邦；怕反推個體 → 差分隱私；多方共算 → 安全多方計算
差分隱私	ϵ 越小越隱私、雜訊越大、效用越低 ；預算隨查詢累加
聯邦學習	資料不出境，但 梯度可能洩漏 ；須疊加安全聚合與差分隱私；Non-IID 是主要難題
去識別化	移除直接識別欄位 不等於 去識別；須處理準識別欄位並驗證 k
k -匿名	不防同質性攻擊，故有 l -多樣性、 t -封閉性
模型	模型權重可能 記憶 訓練資料，刪除困難
加密	保護機密性， 不等於 合規
四層檢核	法源／行業／技術／治理

13.7.2 必背名詞

去識別化、假名化、準識別欄位、 k -匿名性、 l -多樣性、 t -封閉性、差分隱私、隱私預算 ϵ 、聯邦學習、安全聚合、梯度反演、成員推論攻擊、同態加密、安全多方計算、可信執行環境、Non-IID。

13.7.3 五分鐘快速複習

1. 說出三組情境與其對應的隱私技術。
2. 說出 ϵ 的方向性與組合性。
3. 說出聯邦學習的兩項殘餘風險與兩大實務難題。
4. 說出「移除姓名與身分證字號」為何不足以去識別。
5. 說出四層合規檢核各是什麼。

13.7.4 跨章連結

Chapter 4：管線前端的去識別化；Chapter 5：儲存層存取控制與跨境；Chapter 12：語料中的個資與記憶化；第 I 冊 L21203：風險分類框架與六大法益；L23 之 L23401：機器學習專屬攻擊面。

來源與稽核紀錄

官方來源：IPAS-SCOPE-11502(L22404 備註欄「數據的安全性與法律合規技術」)；IPAS-GUIDE-L22(頁碼 **PENDING**)。
政府文件：GOV-PDPA（法律）、GOV-AI-BASIC-ACT（法律）、GOV-FSC-AI（行政規則／指引）、GOV-BA-AI-RULES（公會自律規範經備查）、GOV-MODA-RISK-V1（參考手冊）。查核日 中華民國 115 年 8 月 1 日。
編者推論／延伸：七技術對照表、三組對應口訣、四層合規檢核、程式判讀、四題模擬題與干擾項設計。
未解決資料缺口：(1) 學習指引頁碼；(2) 中級勘誤表完整條目；(3) 風險分類框架 20 項風險子類型逐項名稱——查證前不列出個別名稱。

Part V

附錄

附錄 A：政府指引速查表

考前十分鐘請只看這一頁。

14.1 文件性質與拘束力對照

文件	機關	日期	性質	拘束力
人工智慧基本法	立法院三讀；中央主管機關國科會	114.12.23	法律	法律義務；行政院設國家人工智慧戰略特別委員會
人工智慧風險分類框架 v1.0	數位發展部（依基本法第 16 條）	115.07.07	參考手冊	各目的事業主管機關間之共通指引；對非公務機關無直接拘束力；不適用軍事
行政院使用生成式 AI 參考指引	行政院	112.08	行政規則／指引	拘束公務機關
金融業運用人工智慧（AI）指引	金管會	113.06.20	行政規則／指引	監理期待
金融機構運用人工智慧技術作業規範	銀行公會（金管會同意備查）	113.03.14	行政規則／指引（公會自律規範）	拘束會員機構
個人資料保護法	個資主管機關	現行有效	法律	法律義務
資通安全管理法	數位發展部	現行有效	法律	法律義務（特定對象）
製造業 AI 導入相關資源	經濟部產業發展署	持續更新	產業導入指引	建議性
EU AI Act ／ GDPR ／ NIST AI RMF ／ ISO 42001	國外或國際組織	—	國際法規或標準	僅供比較，非我國普遍義務

14.2 必背清單

基本法七大原則

永續發展與福祉、人類自主、隱私保護與資料治理、資安與安全、透明與可解釋、公平與不歧視、問責。

風險分類框架：四步驟、三大類、20 項、六大法益

四步驟：盤點應用情境 → 識別風險 → 評估風險 → 應對風險。

三大類（共 20 項子類型）：AI 系統本身之技術設計缺陷／部署後操作及人機互動問題／社會結構與環境衝擊。

六大法益：國家安全、人民基本權利、生命安全、財產保障、社會秩序、生態環境。

附錄：一為主管機關風險管理措施檢核表，二為造成嚴重危害例示表。

客觀固有風險三要件

(1) 有造成危害之可能即為已足；(2) 不以實際發生損害為必要；(3) 不考慮現有法規、行政措施或技術手段之緩解效果。

金管會六項高風險判斷指標

(1) 直接提供客戶服務或對營運有重大影響；(2) 使用個人資料程度高；(3) 系統自主決策程度高；(4) 系統複雜性高；(5) 影響利害關係人程度深且廣度大；(6) 救濟選項之程度不完整。

高風險之進階管理措施：日誌紀錄、監控機制、嚴謹的審查及核准程序、獨立稽核或評測機制。

公務機關使用生成式 AI 的三條紅線

(1) 國家機密、公務機密、未經公開之個人資料不得提供予生成式 AI 處理；(2) 業務需求下應評估封閉環境部署；(3) 產出須經人工查證，責任不因使用 AI 而移轉。

14.3 三個最容易記反的細節

常見陷阱與錯誤觀念

1. 主管機關：基本法 → 國科會；風險分類框架 → 數位發展部（依第 16 條訂定）。
2. 拘束力：框架對非公務機關無直接拘束力，但各目的事業主管機關會轉化為具拘束力的領域規範；「無直接拘束力」≠「可不理會」。
3. 緩解措施：高風險認定階段不考慮人工複檢、加密等緩解措施。緩解措施是「應對風險」步驟的產物，不是「評估風險」的折扣。

14.4 寫作與作答句型

允許	禁止
「該指引建議……」	「法律規定所有 AI 都必須……」（無法條支持時）
「主管機關要求受規範對象依適用法規……」	「不符合指引即違法。」
「本文件屬參考手冊，並非法律條文。」	「官方要求固定使用某模型／雲端／框架。」
「以下為編者將原則轉換成專案檢查點之整理。」	將歐盟或美國規範描述為我國組織普遍適用之義務

附錄 D：勘誤、來源登錄與本冊建置狀態

15.1 已套用之勘誤

編號	科目	項目	原內容	更正後	影響
ERR-L23-001	L23	召回率 (Recall) 公式	$TP/(TP+FP)$	$TP/(TP+FN)$	主要影響 L23；本冊 L22302 之不平衡評估亦援用正確式

勘誤表狀態

官方已公告《AI 應用規劃師（中級）學習指引內容勘誤》，並有版本標記（115.04.10）。本書目前僅收錄上述一項高影響條目，完整條目尚未逐條取得。

在完整條目補入前，本書引用學習指引之公式與統計定義時，均另以獨立權威來源交叉驗算。應試前請自行至 iPAS 官網確認最新勘誤公告。**版本敏感**

15.2 編號正規化紀錄

來源原始寫法	本書正規化代碼	理由
L22303（列於 L233 群組下）	L23303	本冊之 L22303 為「數據可視化工具」；若 L233 群組亦使用此代碼即形成重號
L22304（列於 L233 群組下）	L23304	L224 群組起始於 L22401，編制上不存在 L22304

此為編者編號正規化，本書未代替官方進行正式勘誤。本冊（L22）之 **L22303** 指「數據可視化工具」，請勿與 L233 群組下的誤植代碼混淆。

15.3 正式公告試題索引之採用與限制

已採用

本冊各章之「正式公告試題索引」採用下列欄位：題目 ID、場次、官方答案、編者 L 代碼、原卷起訖頁次、含圖標記、對位信心。涵蓋 114 年第二次與 115 年第一次共 100 題 L22 試題。

未採用及其理由

著作權判斷

本書不重製官方題幹與選項全文，亦不嵌入官方試題原頁。理由：

1. 公告試題為受著作權保護之著作，將 100 題題幹與選項全文重製於教材屬大量重製。
2. 原頁整頁嵌入同樣構成重製，且會使教材淪為題本影印。
3. 本書之教學價值來自**考點拆解與決策框架**；讀者可自官方免費下載原卷，重製並未增加實質效用。

本書因此採「索引＋官方答案＋原卷頁次＋考點拆解」模式。

L22 資料品質備註

- L22 之 100 題中，**18 題含圖表**（114-2 場次 7 題、115-1 場次 11 題），另有 2 題題幹字元數偏低，顯示文字擷取不完整，須以原卷為準。
- 來源清單列出 **23 題不適合脫離原頁純文字重排**（114-2-L22 計 9 題、115-1-L22 計 14 題），已於各章索引表之「對位備註」欄標示為「須對照原卷圖表」。
- 對位信心為 medium 者 1 題（115-1-L22-Q39，主代碼 L22201、次代碼 L22203），已於索引表標示。
- L 代碼為**編者對位**，非官方逐題分類，不得對外宣稱為官方考綱歸類。

15.4 L22 命題密度統計

群組	代碼與題數	群組小計	佔比
L221 機率統計基礎	L22101 (7)、L22102 (4)、L22103 (7)	18	18%
L222 大數據處理技術	L22201 (8)、L22202 (8)、 L22203 (20)	36	36%
L223 分析方法與工具	L22301 (9)、 L22302 (17) 、L22303 (7)	33	33%
L224 大數據在 AI 之應用	L22401 (1)、L22402 (6)、L22403 (1)、L22404 (5)	13	13%

研讀資源配置建議

L222 與 L223 合計 69%，應投入約七成的準備時間。其中 **L22203 (20 題)** 與 **L22302 (17 題)** 合計 **37%**，是最高投資報酬的兩章。

L22401 與 L22403 各僅 1 題，讀懂概念即可，不宜深挖。

15.5 未解決之資料缺口與補件流程

四項待補項目

1. 中級學習指引勘誤表完整條目——未取得（已知版本標記 115.04.10）。
2. 三科學習指引內文與頁碼——未取得，各章來源方塊之頁碼欄位維持 PENDING。
3. 程式題型比重說明原文——未取得，「約 25%」維持版本敏感標示。
4. 風險分類框架 20 項風險子類型逐項名稱——未取得，本書僅記載三大類與總項數。

補件步驟

1. 至 iPAS 官網「AI 應用規劃師 → 學習資源」下載三科學習指引、中級勘誤表、考試樣題與正式公告試題。
2. 至「下載專區」下載最新版《評鑑內容範圍參考》，核對版本號。
3. 建立代碼對頁碼索引，填入 references/source_registry.yaml。
4. 逐條讀入勘誤表四欄，寫入 references/errata.yaml。
5. 重新編譯並執行覆蓋稽核。

15.6 本冊建置狀態

稽核項目	結果	說明
考綱覆蓋 (L22)	PASS	13/13 代碼、4/4 評鑑主題，一代碼一章
來源與版本	PARTIAL	學習指引頁碼與勘誤完整條目待補
題目完整性	PASS	100 題正式題索引已併入；自編題獨立編號 SIM-
程式題正確性	PASS	13 題程式判讀，逐行推演驗證回傳型別與執行邏輯
政府與法遵	PASS	全數標明文件性質與拘束力；未證實之評測項目未列出
LaTeX 建置	PASS	XeLaTeX 可編譯，交互參照正常
教材一致性	PASS	章節固定結構、四層標籤與術語一致

版本資訊

本冊版本 v0.2.0 | 資料截止日 中華民國 115 年 8 月 1 日 | 對應 評鑑內容範圍參考 115.02 版
 下次複審觸發：官方發布新版評鑑範圍、新梯次試題公告、勘誤表更新，或 AI 相關法規異動。